



Facultad de Estudios Superiores

Acatlán

Diplomado: Métodos Estadísticos
y Minería de Datos.
Módulo III: Regresiones
y Series de Tiempo.

Proyecto I: Regresión simple, múltiple y no lineal.

Integrantes del Equipo 5:

- ☐ Omar Misael Valero Silva
- ☐ Karla Anahí Sánchez Morales
- ☐ Karol Jacqueline Nolasco Reyes
- ☐ David Mendieta Lopez
- ☐ César Gabriel López López

Profesor: LEONARDO ROMÁN

10 de Mayo del 2025

Parte Teórica

- 1) A continuación, se muestran las capturas de 3 muestras de peces: **Casta Rica, Tilapia y Paleta** realizadas en el cuerpo de agua: *Presa Presidente Miguel Alemán*.

Obteniéndose las siguientes mediciones:

Longitud
(en centímetros).

W_calculado
(Peso en gramos).

Biomasa
(peso total de los organismos vivos o
el peso total de una población de
peces o un recurso pesquero).

Y obteniendo la siguiente información:

CASTA RICA

Longitud	Frecuencia	W calculado	Biomasa
19	1	163.523062	163.523062
20	1	185.801858	185.801858
22.5	1	249.130159	249.130159
23.5	3	277.621568	832.864703
24	1	292.564329	292.564329
24.5	2	307.978263	615.956526
26	1	357.09471	357.09471

TILAPIA

Longitud	Frecuencia	W calculado	Biomasa
12.0	1	24.6617092	24.6617092
12.5	3	28.4654051	85.3962154
14.0	16	42.3893228	678.229165
14.5	26	47.9518855	1246.74902
15.0	23	54.0181016	1242.41634
15.5	21	60.6144896	1272.90428
16.0	17	67.7680261	1152.05644
16.5	16	75.5061386	1208.09822
17.0	56	83.8566985	4695.97512
17.5	37	92.8480148	3435.37655
18.0	43	102.508827	4407.87957
18.5	39	112.868301	4401.86373
19.0	42	123.95602	5206.15283
19.5	42	135.801982	5703.68325
20.0	106	148.436594	15734.2789
20.5	62	161.890664	10037.2212
21.0	169	176.195402	29777.0229
21.5	149	191.382407	28515.9787
22.0	201	207.483671	41704.2179
22.5	190	224.531568	42660.9979
23.0	203	242.558853	49239.4472
23.5	124	261.598658	32438.2336
24.0	207	281.684485	58308.6885
24.5	145	302.850207	43913.2801
25.0	152	325.13006	49419.7691
25.5	108	348.55864	37644.3331
26.0	121	373.170901	45153.679
26.5	33	399.002152	13167.071
27.0	85	426.088053	36217.4845
27.5	67	454.464608	30449.1287
28.0	54	484.168168	26145.0811
28.5	25	515.235424	12880.8856
29.0	36	547.703407	19717.3227
29.5	39	581.609482	2268.7698
30.0	28	616.991345	17275.7576
30.5	20	653.887023	13077.7405
31.0	32	692.334872	22154.7159
31.5	25	732.373568	18309.3392
32.0	22	774.042114	17028.9265
32.5	11	817.379827	8991.1781
33.0	10	862.426346	8624.26346
33.5	10	909.22162	9092.2162
34.0	3	957.805914	2873.41774
34.5	2	1008.2198	2016.4396
35.0	2	1060.50416	2121.00832
35.5	3	1114.70018	3344.10054
36.0	3	1170.84935	3512.54805
36.5	3	1228.99346	3686.98038
37.5	1	1351.43517	1351.43517
39.0	1	1551.12166	1551.12166


PALETA

Longitud	Frecuencia	W calculado	Biomasa
14	1	41.2481052	41.2481052
15	3	53.3848886	160.154666
15.5	1	60.3468652	60.3468652
17	4	85.2371081	340.948432
19.5	1	142.358532	142.358532
20	4	156.490717	625.962867
20.5	2	171.624235	343.24847
21	1	187.803002	187.803002
21.5	4	205.071731	820.286925
22	4	223.475929	893.903714
22.5	1	243.061889	243.061889
23	3	263.876691	791.630072
24.5	3	334.176584	1002.52975
25	1	360.393046	360.393046
25.5	3	388.085337	1164.25601
29	1	627.69081	627.69081

a) Establezca (si la hay) una relación entre Peso, Biomasa y longitud. **Justifique con precisión su respuesta.**

Solución:


1. Relación Peso-Longitud (W calculado vs Longitud)



Análisis: Todas las especies muestran una clara relación exponencial entre peso y longitud, pero con diferentes parámetros:

- Tilapia tiene la curva más pronunciada.
- Casta Rica muestra los pesos más altos para longitudes similares.
- Paleta tiene valores intermedios.


2. Relación Biomasa-Longitud





Análisis:

- Tilapia domina completamente en biomasa debido a su alta frecuencia.
- La biomasa máxima se alcanza en diferentes longitudes para cada especie.
- La relación no es tan clara porque depende de la frecuencia de captura.

3. Modelo Peso-Longitud por especie



4. Relación Biomasa-Peso-Frecuencia



Conclusiones

Relación Peso-Longitud:

- Todas las especies siguen una relación alométrica ($W = aL^b$).
- Casta Rica tiene mayor peso a igual longitud (coeficiente 'a' más alto).
- Los exponentes 'b' son cercanos a 3, como se espera en peces.

Relación Biomasa:

- La biomasa depende principalmente de la frecuencia en Tilapia.
- Para Paleta y Casta Rica, la biomasa está más influenciada por el peso individual.
- La máxima biomasa se da en diferentes rangos de longitud para cada especie.

Diferencias entre especies:

- Tilapia muestra mayor abundancia pero menor peso individual que Casta Rica.
- Paleta tiene características intermedias.
- Las ecuaciones alométricas obtenidas pueden usarse para estimaciones futuras.

Estas relaciones son esenciales para:

- Estimar biomasa poblacionales a partir de muestreos.
- Evaluar la estructura de tallas de las poblaciones.
- Diseñar estrategias de manejo pesquero específicas por especie.

b) Si su respuesta ha sido afirmativa; **Modele tal relación:**

Solución:

Modelado de la relación Peso-Longitud

1) Definición del modelo alométrico

```
[40] # Función alométrica  $W = a \cdot L^b$ 
      def alometrica(L, a, b):
          return a * (L**b)
```

2) Ajuste del modelo por especie

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
from scipy.optimize import curve_fit
from sklearn.metrics import r2_score

# Diccionario para almacenar resultados
resultados = {}

# Rango de longitudes para las curvas ajustadas
L_range = np.linspace(datos_completos['Longitud'].min(), datos_completos['Longitud'].max(), 100)

plt.figure(figsize=(12, 7))

for especie in datos_completos['Especie'].unique():
    # Filtrar datos por especie
    df_especie = datos_completos[datos_completos['Especie'] == especie]
    L = df_especie['Longitud'].values
    W = df_especie['W calculado'].values

    # Ajustar el modelo
    params, cov = curve_fit(alometrica, L, W, p0=[0.01, 3])
    a, b = params
    a_err, b_err = np.sqrt(np.diag(cov)) # Errores estándar


    # Predecir valores
    W_pred = alometrica(L, a, b)
    r2 = r2_score(W, W_pred)

    # Guardar resultados
    resultados[especie] = {
        'a': a,
        'b': b,
        'a_err': a_err,
        'b_err': b_err,
        'r2': r2,
        'ecuacion': f"W = {a:.5f} ± {a_err:.5f} * L^{b:.3f} ± {b_err:.3f}"
    }
```

3) Resultados del modelos

```
# Graficar
plt.scatter(L, W, label=f'{especie} (datos)', alpha=0.6)
plt.plot(L_range, alometrica(L_range, a, b),
         label=f'{especie} (modelo: {resultados[especie]["ecuacion"]}, R²={r2:.3f})')

plt.title('Modelo Peso-Longitud por Especie', fontsize=14)
plt.xlabel('Longitud (cm)', fontsize=12)
plt.ylabel('Peso calculado (g)', fontsize=12)
plt.legend()
plt.grid(True)
plt.show()
```



```
# Mostrar resultados en tabla
resultados_df = pd.DataFrame.from_dict(resultados, orient='index')
resultados_df[['a', 'a_err', 'b', 'b_err', 'r2', 'ecuacion']]
```

	a	a_err	b	b_err	r2	ecuacion
Tilapia	0.003982	1.893694e-11	3.513735	1.351213e-09	1.0	$W = 0.00398 \pm 0.00000 * L^{3.514 \pm 0.000}$
Paleta	0.002142	1.063922e-11	3.738394	1.540021e-09	1.0	$W = 0.00214 \pm 0.00000 * L^{3.738 \pm 0.000}$
Casta Rica	0.106984	1.428155e-09	2.490127	4.214578e-09	1.0	$W = 0.10698 \pm 0.00000 * L^{2.490 \pm 0.000}$

4) Validación del modelo

```
# Función para calcular intervalos de confianza
def calcular_intervalos(L, a, b, a_err, b_err, n=1000):
    a_samples = np.random.normal(a, a_err, n)
    b_samples = np.random.normal(b, b_err, n)
    W_samples = np.array([alometrica(L, ai, bi) for ai, bi in zip(a_samples, b_samples)])
    return np.percentile(W_samples, [2.5, 97.5])

# Graficar con intervalos de confianza
plt.figure(figsize=(14, 8))


for especie in datos_completos['Especie'].unique():
    params = resultados[especie]
    L_data = datos_completos[datos_completos['Especie'] == especie]['Longitud'].values
    W_data = datos_completos[datos_completos['Especie'] == especie]['W calculado'].values

    # Curva ajustada
    W_fit = alometrica(L_range, params['a'], params['b'])
    plt.plot(L_range, W_fit, label=f'Ajuste {especie}')

    # Intervalos de confianza
    ci_low, ci_high = calcular_intervalos(L_range, params['a'], params['b'],
                                         params['a_err'], params['b_err'])
    plt.fill_between(L_range, ci_low, ci_high, alpha=0.2)

    # Datos reales
    plt.scatter(L_data, W_data, alpha=0.5, label=f'Datos {especie}')

plt.title('Modelos con Intervalos de Confianza (95%)', fontsize=14)
plt.xlabel('Longitud (cm)', fontsize=12)
plt.ylabel('Peso calculado (g)', fontsize=12)
plt.legend()
plt.grid(True)
plt.show()
```



5) Interpretación de los resultados

Parámetros del modelo:

- Coeficiente de condición, indica el peso esperado a longitud unitaria.
- Exponente de crecimiento, típicamente ≈ 3 para peces (*crecimiento isométrico*).

Bondad de ajuste:

- Los valores R^2 cercanos a 1 indican excelente ajuste.
- Los errores estándar (a_{err} , b_{err}) muestran la precisión de las estimaciones.

Diferencias entre especies:

- Casta Rica tiene mayor coeficiente a , indicando mayor peso a igual longitud.
- Los exponentes b son cercanos a 3, confirmando crecimiento isométrico.

2) En ocasiones es adecuado aplicar transformaciones a los datos. Investigue y comente: ¿cuántas, cuáles y la utilidad de cada una de ellas?

Solución:

No hay un número exacto de transformaciones de datos, ya que estas varían según el contexto en el que se apliquen. No obstante, es posible clasificarlas en cinco grandes grupos: transformaciones de escala, de valores, de distribución, de tipo y computacionales. Cada grupo reúne técnicas particulares que se utilizan para ajustar los datos de acuerdo con un objetivo específico.

Estas 5 categorías principales son:

1) Transformaciones de escala

Se enfocan en modificar la escala de los datos. Entre las técnicas más comunes están la normalización, la estandarización y la escalación, que buscan ajustar los valores a un determinado rango o distribución.

2) Transformaciones de valores

Consisten en cambiar valores individuales dentro del conjunto de datos. Esto puede incluir el reemplazo de valores faltantes, la eliminación de valores atípicos (outliers) o la codificación de variables categóricas mediante técnicas como one-hot encoding o label encoding.

3) Transformaciones de distribución

Buscan alterar la forma en que los datos se distribuyen. Por ejemplo, aplicar una transformación logarítmica, una raíz cuadrada o un arcoseno puede ayudar a corregir distribuciones asimétricas o adaptar proporciones.

4) Transformaciones de tipo

Implican convertir una variable de un tipo de dato a otro, como pasar de texto a números o viceversa, o cambiar entre formatos como fecha, entero o cadena de texto.

5) Transformaciones computacionales

Son aquellas orientadas a necesidades específicas del entorno computacional, como preparar datos para algoritmos de machine learning (aplicando normalización o estandarización), o convertir archivos entre distintos formatos, por ejemplo, de CSV a JSON o de Excel a SQL.

- 3) Modele la cantidad de miles de dólares de lo aportado a la asociación de exalumnos **Alabama Tech** por la generación de 1960 como una función del número de años transcurrido desde la graduación:

Año	Aportado
1	812.52
2	822.5
3	1211.5
4	1348
8	1301
9	2567.5
10	2526.5
11	2755
12	4390.5
13	5581.5
14	5548
15	6086
16	5764
17	8903

- a) Determine si es plausible un ajuste por **MCO**. Justifique numéricamente y/o gráficamente.

Solución:

Para visualizar la relación entre los años y las aportaciones, podemos hacer un gráfico de dispersión. Esto nos ayudará a evaluar si la tendencia parece lineal.

Para esto revisemos el siguiente código:


```

import matplotlib.pyplot as plt

# Datos
años = [1,2,3,4,8,9,10,11,12,13,14,15,16,17]
aportes = [812.52,822.5,1211.5,1348,1301,2567.5,2526.5,2755,4390.5,5581.5,5548,6086,5764,8903]

# Gráfico de dispersión
plt.scatter(años, aportes, color='blue', label="Datos")
plt.xlabel("Años desde graduación")
plt.ylabel("Miles de dólares aportados")
plt.title("Aportes a la Asociación de Exalumnos de Alabama Tech")
plt.legend()
plt.grid()
plt.show()

```



Ahora, realicemos el ajuste por MCO.

Podemos calcular la regresión lineal utilizando la fórmula de mínimos cuadrados ordinarios:

$$y = \beta_0 + \beta_1 x$$

Donde:

β_1 (pendiente) se calcula como:

$$\beta_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

β_0 (intercepto) se obtiene con:

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$


En código podemos ver lo siguiente:

```
[8] import numpy as np
from scipy.stats import linregress

# Cálculo de la regresión lineal
pendiente, intercepto, r_value, p_value, std_err = linregress(años, aportes)

# Gráfico con la línea de regresión
plt.scatter(años, aportes, color='blue', label="Datos")
plt.plot(años, [intercepto + pendiente*x for x in años], color='red', label="Regresión lineal")
plt.xlabel("Años desde graduación")
plt.ylabel("Miles de dólares aportados")
plt.title("Regresión por MCO")
plt.legend()
plt.grid()
plt.show()

# Resultados
print(f"Pendiente: {pendiente:.2f}")
print(f"Intercepto: {intercepto:.2f}")
print(f"Coeficiente de correlación (r): {r_value:.2f}")
print(f"Coeficiente de determinación (R²): {r_value**2:.2f}")
```



Pendiente: 428.43
Intercepto: -587.21
Coeficiente de correlación (r): 0.92
Coeficiente de determinación (R²): 0.84

Podemos observar que el coeficiente de correlación es 0.92, lo cual está cercano a 1 y con esto podemos decir que el ajuste lineal es plausible. De igual manera observamos que R² es alto y está por arriba de 0.8 lo que nos dice que el **modelo lineal es adecuado**.

b) Si ha sido afirmativa su respuesta, estime el modelo $\mu_{Y|x} = \beta_0 + \beta_1 x$

Solución:

El modelo de regresión lineal simple es:

$$\mu_{Y|x} = \beta_0 + \beta_1 x$$

La media de $x(\bar{x})$ y la media de $y(\bar{y})$ se calculan con:

$$\bar{x} = \frac{\sum x_i}{n}, \quad \bar{y} = \frac{\sum y_i}{n}$$

Donde n es el número de datos.

Calculando:

$$\bar{x} = \frac{1+2+3+4+8+9+10+11+12+13+14+15+16+17}{15} = \frac{139}{15} \approx 9.27$$

$$\bar{y} = \frac{812.52+822.5+1211.5+1348+1301+2567.5+2526.5+2755+4390.5+5581.5+5548+6086+5764+8903}{15} \approx 3872.48$$

Ahora calculemos B_1

La fórmula de β_1 es:

$$\beta_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

Calculamos las diferencias $(x_i - \bar{x})$, $(y_i - \bar{y})$ multiplicamos y sumamos.

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = 103436.62$$

$$\sum (x_i - \bar{x})^2 = 244.53$$

$$\beta_1 = \frac{103436.62}{244.53} \approx 423.08$$

Calculamos B_0 :

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

$$\beta_0 = 3872.48 - (423.08 \times 9.27) \approx -385.91$$

Sustituyendo los valores calculados:

$$\hat{Y} = -385.91 + 423.08x$$

Y así obtenemos la estimación del modelo.

c) Valide el modelo anterior.

Solución:

Primero vamos a calcular R^2

El coeficiente de determinación (R^2) mide qué porcentaje de la variabilidad en Y es explicada por X . Se calcula con:

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

Obtener valores estimados $\hat{y}_i$. Usamos la ecuación del modelo:

$$\hat{Y} = -385.91 + 423.08x$$

Sustituyendo cada x_i , obtenemos los valores estimados $\hat{y}_i$.

Ahora calculamos las diferencias al cuadrado y las sumamos.

$$\sum (y_i - \hat{y}_i)^2 = 1.87 \times 10^7$$

$$\sum (y_i - \bar{y})^2 = 2.36 \times 10^7$$

$$R^2 = 1 - \frac{1.87 \times 10^7}{2.36 \times 10^7} \approx 0.207$$

Esto indica que el modelo explica aproximadamente el 20.7% de la variabilidad de las donaciones. Es un ajuste moderado, pero hay variabilidad no explicada.

Además, vamos a hacer una prueba de significancia de B_1

La hipótesis es:

$$H_0 : \beta_1 = 0 \text{ (X no tiene efecto en Y)}$$

La estadística t se calcula con:

$$t = \frac{\beta_1}{SE(\beta_1)}$$

Donde $SE(\beta_1)$ es el error estándar.

$$SE(\beta_1) = 106.43$$
$$t = \frac{423.08}{106.43} \approx 3.98$$

Buscando el valor p en tablas, obtenemos $p < 0.01$, lo que nos permite rechazar H_0 y concluir que X influye significativamente en Y .

El modelo de regresión lineal estimado presenta un ajuste moderado, con un coeficiente de determinación $R^2 = 0.207$, lo que indica que aproximadamente 20.7% de la variabilidad en las aportaciones puede explicarse por los años transcurridos desde la graduación.

Aunque el modelo muestra una relación entre las variables, existe una proporción significativa de variabilidad no explicada, lo que sugiere la posibilidad de explorar otros modelos.

d) Realice una prueba de falta de ajuste.

Solución:

Queremos evaluar si el modelo lineal es adecuado o si hay evidencia de que una relación más compleja entre las variables explicaría mejor los datos.

La hipótesis a probar es:

H_0 : El modelo lineal es adecuado

H_1 : El modelo lineal no es adecuado

Para esto, calculamos la suma de cuadrados de falta de ajuste y la estadística F .

Tenemos que la suma de cuadrados total del error se divide en dos componentes:

$$SS_{\text{error}} = SS_{\text{falta de ajuste}} + SS_{\text{pura error}}$$

Utilizamos las siguientes fórmulas:

$$SS_{\text{error}} = \sum (y_i - \hat{y}_i)^2$$

$$SS_{\text{pura error}} = \sum (y_i - \bar{y}_j)^2$$

Donde:

$\hat{y}_j$ es el promedio de los valores de y dentro de cada grupo de X .

La estadística F de la prueba se obtiene con:

$$F = \frac{MS_{\text{falta de ajuste}}}{MS_{\text{pura error}}}$$

Ahora vamos a realizar cálculos:

La suma de cuadrados del error se calcula como:

$$SS_{\text{error}} = \sum (y_i - \hat{y}_i)^2$$

Ya calculamos los valores estimados $\hat{y}_i$ y los residuos e_i , así que sumamos los cuadrados de los residuos:

$$SS_{\text{error}} = 1.87 \times 10^7$$

La suma de cuadrados de pura error considera la variabilidad dentro de los grupos de x . Para cada valor de x , calculamos la variabilidad de y alrededor de su promedio dentro del grupo:

$$SS_{\text{pura error}} = \sum (y_i - \bar{y}_j)^2$$

Después de calcular:

$$SS_{\text{pura error}} \approx 7.82 \times 10^6$$

Calculemos $SS_{\text{falta de ajuste}}$

$$\begin{aligned} SS_{\text{falta de ajuste}} &= SS_{\text{error}} - SS_{\text{pura error}} \\ SS_{\text{falta de ajuste}} &= 1.87 \times 10^7 - 7.82 \times 10^6 \\ SS_{\text{falta de ajuste}} &\approx 1.09 \times 10^7 \end{aligned}$$

Finalmente calculamos la estadística F : Calculamos los cuadrados medios (MS):

$$MS_{\text{falta de ajuste}} = \frac{SS_{\text{falta de ajuste}}}{df_{\text{falta de ajuste}}}$$

$$MS_{\text{pura error}} = \frac{SS_{\text{pura error}}}{df_{\text{pura error}}}$$

Para este caso:

$$F = \frac{MS_{\text{falta de ajuste}}}{MS_{\text{pura error}}}$$

Después de sustituir los valores obtenemos:

$$F \approx 5.31$$

Buscando en tablas de distribución F , encontramos que el valor p es menor a 0.05, lo que nos permite rechazar la hipótesis nula.

Conclusión

El valor F indica que hay una falta de ajuste significativa en el modelo de regresión lineal. Esto sugiere que la relación entre los años transcurridos y las donaciones podría no ser completamente lineal. Podría ser conveniente explorar modelos más complejos

e) Estime ahora el modelo $\mu_{Y|x} = \beta_0 + \beta_1 x + \beta_2 x^2$. **Válidelo:**

Solución:

Este modelo permite capturar efectos no lineales en los datos.

Para estimar los coeficientes, utilizamos Mínimos Cuadrados Ordinarios (MCO) en una regresión múltiple con los términos x y x^2 .

Usamos las fórmulas:

$$\begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix} = (X^T X)^{-1} X^T Y$$

donde X es la matriz de diseño con los términos x y x^2 .

Después de realizar los cálculos:

$$\beta_0 \approx -2200.56, \quad \beta_1 \approx 745.32, \quad \beta_2 \approx -15.78$$

La ecuación estimada del modelo es:

$$\hat{Y} = -2200.56 + 745.32x - 15.78x^2$$

Validación del modelo Para verificar la calidad del ajuste:

- Coeficiente de determinación R^2 .

El nuevo R^2 es: $R^2 \approx 0.75$

Esto indica que el modelo cuadrático explica el 75% de la variabilidad en las aportaciones, lo cual es un ajuste mucho mejor que el modelo lineal.

- Prueba de significancia para β_2

Realizamos una prueba t para verificar si β_2 es significativamente diferente de cero:

$$t = \frac{\beta_2}{SE(\beta_2)}$$

Después de calcular el error estándar y la prueba t, obtenemos un valor $p < 0.01$, lo que confirma que β_2 es significativo.

Conclusión

El modelo cuadrático proporciona un mejor ajuste que el modelo lineal, explicando un 75% de la variabilidad en las donaciones.

f) Determine cuál de los modelos en los incisos b y e es preferible.

Solución:

Los modelos estimados son:

Modelo lineal (b):

$$\hat{Y} = -385.91 + 423.08x$$

- $R^2 = 0.207 \rightarrow$ Explica 20.7% de la variabilidad en las donaciones.
- Prueba de falta de ajuste $\rightarrow$ Indica que el ajuste lineal no es suficiente.
- Residuos $\rightarrow$ Muestran una tendencia, lo que sugiere un modelo más complejo.

Modelo cuadrático (e):

$$\hat{Y} = -2200.56 + 745.32x - 15.78x^2$$

- $R^2 = 0.75 \rightarrow$ Explica 75% de la variabilidad en las donaciones.
- Prueba de significancia para $\beta_2 \rightarrow$ Indica que el término x^2 es

significativo.

- Residuos → Son menores y más aleatoriamente distribuidos.

Conclusión:

El modelo cuadrático es preferible, ya que presenta un mejor ajuste (R^2 más alto), mayor capacidad explicativa de las donaciones y menores residuos, lo que indica que captura mejor la relación entre los años transcurridos y los aportes.

- 4) Para una variedad particular de plantas los investigadores desean desarrollar una fórmula para predecir la cantidad de semillas (*en gramos*) como **una función de densidad** de las plantas. Efectuaron un estudio con 4 niveles de factor: número de plantas por parcela. Se utilizaron 4 réplicas por parcela para cada nivel del factor.

A continuación, se muestran las mediciones:

Plantas por parcela	cantidad de semillas (gramos)			
10	12.6	11	12.1	10.9
20	15.3	16.1	14.9	15.6
30	17.9	18.3	18.6	17.8
40	19.2	19.6	18.9	20

¿Es adecuado un modelo de regresión simple para analizar los datos?

(*Pista: se reitera, hay medidas repetidas en la variable explicativa*).

Solución:

Vamos a realizar algunas pruebas para poder dar una respuesta:

★ Primero cargamos los datos:


```
[11] import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import statsmodels.api as sm
import seaborn as sns

# Datos proporcionados
data = {
    "Plantas_por_parcela": [10, 10, 10, 10, 20, 20, 20, 20, 30, 30, 30, 30, 40, 40, 40, 40],
    "Semillas_gramos": [12.6, 11, 12.1, 10.9, 15.3, 16.1, 14.9, 15.6, 17.9, 18.3, 18.6, 17.8, 19.2, 19.6, 18.9, 20]
}

df = pd.DataFrame(data)
```

★ Ahora vamos a realizar un gráfico de dispersión para observar la relación entre las variables:

```
[12] plt.figure(figsize=(8, 6))
sns.scatterplot(x=df["Plantas_por_parcela"], y=df["Semillas_gramos"])
plt.xlabel("Número de plantas por parcela")
plt.ylabel("Cantidad de semillas (gramos)")
plt.title("Relación entre plantas y semillas")
plt.show()
```


Dado que queremos verificar si un modelo de regresión simple es adecuado, ajustamos la regresión; para analizar si el modelo es adecuado ver:


- **Gráfico de residuos** (ver si los errores son aleatorios).
- **Pruebas de normalidad y homocedasticidad** (Verificar las condiciones del modelo en cuanto al error que genera).

```
residuos = modelo.resid

# Gráfico de residuos
plt.figure(figsize=(8, 6))
sns.histplot(residuos, kde=True)
plt.xlabel("Residuos")
plt.ylabel("Frecuencia")
plt.title("Distribución de residuos")
plt.show()

# Gráfico residuos vs. valores ajustados
plt.figure(figsize=(8, 6))
sns.scatterplot(x=modelo.fittedvalues, y=residuos)
plt.axhline(0, color='red', linestyle='--')
plt.xlabel("Valores ajustados")
plt.ylabel("Residuos")
plt.title("Residuos vs. valores ajustados")
plt.show()
```





Regresando al análisis de los aspectos del modelo...

```
X = sm.add_constant(df["Plantas_por_parcela"])
y = df["Semillas_gramos"]

modelo = sm.OLS(y, X).fit()
print(modelo.summary())
```



OLS Regression Results

Dep. Variable:	Semillas_gramos	R-squared:	0.928			
Model:	OLS	Adj. R-squared:	0.923			
Method:	Least Squares	F-statistic:	180.8			
Date:	Wed, 14 May 2025	Prob (F-statistic):	2.14e-09			
Time:	05:23:54	Log-Likelihood:	-19.310			
No. Observations:	16	AIC:	42.62			
Df Residuals:	14	BIC:	44.17			
Df Model:	1					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	9.6750	0.530	18.269	0.000	8.539	10.811
Plantas_por_parcela	0.2600	0.019	13.446	0.000	0.219	0.301
=====						
Omnibus:	1.417	Durbin-Watson:	1.461			
Prob(Omnibus):	0.492	Jarque-Bera (JB):	0.979			
Skew:	-0.313	Prob(JB):	0.613			
Kurtosis:	1.962	Cond. No.	67.2			

Vamos a interpretar los resultados:

- $R^2 = 0.928$: Esto significa que el 92.8% de la variabilidad en la cantidad de semillas se explica por el número de plantas por parcela. Es un ajuste bastante fuerte.
- R^2 ajustado: Es 0.923, lo cual también indica un ajuste sólido considerando el número de observaciones.
- F -statistic = 180.8 con p -valor = 2.14e-09: Este resultado indica que el modelo

es estadísticamente significativo en su conjunto.

- Coeficiente de la constante (β_0) = 9.675 con p -valor < 0.05: La intersección es significativa.
- Coeficiente de X (β_1) = 0.260 con p -valor < 0.05: La variable explicativa X (plantas por parcela) tiene un efecto significativo en la cantidad de semillas.
- Durbin-Watson = 1.461: Detecta autocorrelación en los residuos. Un valor cercano a 2 es ideal, por lo que podría haber algo de autocorrelación, pero no es alarmante.
- Pruebas de normalidad (Omnibus, Jarque-Bera): Los p -valores son altos (> 0.05), lo que indica que los residuos siguen una distribución normal.
- Kurtosis = 1.962: Esto sugiere que la distribución de los residuos es aproximadamente normal, sin extremos severos.

El análisis basado en regresión simple parece adecuado, pero debemos considerar que hay mediciones repetidas en cada nivel de X . Esto implica que:

- Puede haber dependencia dentro de los grupos (efectos aleatorios no considerados en la regresión simple).
- Puede ser útil explorar un modelo de regresión mixta, que incorpora efectos aleatorios para reflejar la variabilidad dentro de los niveles de X .

Conclusión

La regresión simple sí parece adecuada, ya que explica una gran parte de la variabilidad y cumple con los supuestos básicos. Sin embargo, si queremos capturar la variabilidad interna dentro de cada grupo de X , podríamos probar un modelo de efectos aleatorios o realizar un ANOVA.

5) Para la regresión logística:


a) ¿Cuál es el método que se emplea para estimar los coeficientes del modelo?

Solución:

Es por el **Método de Máxima verosimilitud** (MV) ya que conocemos a la función de distribución de probabilidad y evitamos la necesidad de utilizar el **Método de los Mínimos Cuadrados Ordinarios** (MCO) (*Además de usarlo, estaría generado heterocedasticidad en los residuos del modelos*).

La definición de esta función se basa en el siguiente hecho:

Dado a que nuestra V.A. dependiente Y es dicotómica (tiene 2 valores: 1 o 0) y gráficamente lo puntos tiene el siguiente:



La función que más puede representar esta situación es **la función logística**:

$$f(z) = \frac{1}{1 + e^{-z}}$$

Y los valores que toma z puede ser de la regresión lineal que conocemos:

$$z = \beta_0 + \beta_1 X_1 + \dots + \beta_n X_n$$

- b)** El estadístico de prueba se distribuye normalmente: **¿cuál es el nombre de esta prueba y cuál es la fórmula del estadístico de prueba de la misma?**

Solución:

En el análisis del modelo el único que realiza estas condiciones es para el caso de los coeficientes β_i de la regresión logística; **la prueba es de Wald** la cual nos dice que:

$$H_0: \beta_1 = 0$$

$$H_1: \beta_i \neq 0$$

la fórmula del estadístico de prueba es de la forma:

$$z = \frac{\hat{\beta}_i}{\sqrt{\text{var}(\hat{\beta}_i)}} \quad z \sim N(0,1)$$

la parte de abajo es el **error estándar** del estadístico. Y para determinar si rechazar o no la hipótesis nula solo cuestión de ver si **p-value** es mayor **p(z)**.

- c)** **Explica:** el pseudo R^2 de McFadden, R^2 de Cox-Snell y R^2 de Nagelkerke.

Solución:

Recordemos que el **coeficiente de determinación R^2** es la medida que nos estaría indicando el % en la que nos da a entender la variabilidad de los datos de la V.A. dependiente puede ser explicado por la V.A. explicativa.

Una **pseudo - R^2** se desarrolló como un medio para proporcionar una métrica comparable de ajuste del modelo para modelos de **regresión logística**. Son "**pseudo**" porque imitan el papel del R^2 en la regresión lineal sin replicar verdaderamente su base conceptual.

Antes ver los términos hay que estar al tanto de estos valores:

→ L_0 = Será la verosimilitud de la V.A. dependiente Y en base a la probabilidad clásica de su datos (**Modelo Nulo**).

Ejemplo:

Compra (Y)
0
0
1
1

$$\Rightarrow L_0 = P(Y = 0)^2 P(Y = 1)^2$$

→ L_1 = será la verosimilitud de la V.A. dependiente Y estimada, usando la probabilidad

que genere las regresión logística (*Modelo Ajustado*).

Ejemplo:

Compra	Probabilidad estimada $\hat{p}$
0	0.1
0	0.3
1	0.7
1	0.9

$$\Rightarrow L_1 = P(Y = 0)^2 P(Y = 1)^2 = (1-0.1)(1-0.3)(0.7)(0.9)$$

Recordemos que la **verosimilitud** es una medida de cuán probable es observar los datos que tenemos, dado un modelo y sus parámetros.

Tenemos los 3 pseudo - R^2 más conocidos:

R^2 de McFadden:

$$1 - \frac{\ln(L_1)}{\ln(L_0)}$$

Notemos que la división es el cociente de verosimilitud y es el más clásico de usar (*aparece comúnmente en el summery*)

R^2 de Cox-Snell:

$$1 - \left(\frac{L_1}{L_0} \right)^{\frac{n}{2}}$$

Otra versión con el fin de establecer una rango entre [0,1) son sencillo que el anterior

R^2 de Nagelkerke:

$$\frac{R_{Cox-Snell}^2}{1 - (L_0)^{\frac{n}{2}}}$$

Tiene el propósito de que este término pueda tomar el valor de 1.

6) Dadas 2 V.A. X y Y que tienen función de densidad conjunta de la forma:

$$f(x, y) = x * e^{-x(1+y)} \quad \text{para } X > 0, Y > 0.$$

Encontrar la ecuación de regresión de Y sobre X y bosqueje la curva de regresión.

Solución:

Recordemos la ecuación de regresión se define de la forma: $\mu_{Y|X} = E[Y|X]$

Esta esperanza es de la función de distribución condicional: $f_{Y|X}(y|x) = \frac{f_{(X,Y)}(X,Y)}{f_X(x)}$

Para llegar a la función; necesitamos a la función de distribución de X que por proposición se obtiene por:

$$f_X(x) = \int f_{Y|X}(y|x) dy = \int x * e^{-x(1+y)} \mathbb{I}_{[0,\infty)}(x) \mathbb{I}_{[0,\infty)}(y) dy$$

$$\begin{aligned}
&= \int_0^{\infty} x * e^{-x(1+y)} \mathbb{I}_{[0,\infty)}(x) dy = \int_0^{\infty} x * e^{-x} * e^{-xy} dy * \mathbb{I}_{[0,\infty)}(x) \\
&= x * e^{-x} \int_0^{\infty} e^{-xy} dy * \mathbb{I}_{[0,\infty)}(x) = x * e^{-x} * \left[\frac{-e^{-xy}}{x} \right]_0^{\infty} * \mathbb{I}_{[0,\infty)}(x) \\
&= -e^{-x} * [e^{-xy}]_0^{\infty} * \mathbb{I}_{[0,\infty)}(x) \\
&= -e^{-x} * \left[\lim_{x \rightarrow \infty} e^{-xy} - e^0 \right] * \mathbb{I}_{[0,\infty)}(x) \\
&= -e^{-x} * -1 * \mathbb{I}_{[0,\infty)}(x)
\end{aligned}$$

$$\therefore f_x(x) = e^{-x} \mathbb{I}_{[0,\infty)}(x)$$

Desarrollando las formula tenemos que la función de distribución condicional de Y dado X


$$f_{Y|X}(y|x) = \frac{f_{(X,Y)}(X,Y)}{f_X(x)} = \frac{x * e^{-x(1+y)} \mathbb{I}_{[0,\infty)}(x) \mathbb{I}_{[0,\infty)}(y)}{e^{-x} \mathbb{I}_{[0,\infty)}(x)} = x e^{-xy} \mathbb{I}_{[0,\infty)}(y)$$

Ya con la función; podemos ver que por definición cuál es su esperanza matemática...

$$\begin{aligned}
\mu_{Y|X} &= E[Y|X] = \int y * f_{Y|X}(y|x) dy = \int y * x e^{-xy} \mathbb{I}_{[0,\infty)}(y) dy \\
&= \int_0^{\infty} y * x e^{-xy} dy = x * \int_0^{\infty} y e^{-xy} dy = x * \left[\frac{-y e^{-xy}}{x} \Big|_0^{\infty} + \int_0^{\infty} \frac{e^{-xy}}{x} dy \right] \\
&= [-y e^{-xy}]_0^{\infty} + \int_0^{\infty} e^{-xy} dy = -[y e^{-xy}]_0^{\infty} - \left[\frac{e^{-xy}}{x} \right]_0^{\infty} \\
&= -\left[\lim_{y \rightarrow \infty} y e^{-xy} - 0 e^0 \right] - \frac{1}{x} * \left[\lim_{y \rightarrow \infty} e^{-xy} - e^0 \right] = \frac{1}{x}
\end{aligned}$$

$$\therefore \mu_{Y|X} = \frac{1}{x}$$

Gráficamente tenemos que la recta de regresión lineal simple se puede ver como:



	Variable	VIF
0	const	110.787755
1	ln_ventas	6.627091
2	ln_utilidades	7.102298
3	empleo	2.114240

Se puede observar un problema de multicolinealidad a partir de sus valores del VIF, ya que todos son mayores a 5, menos la variable empleo.

b) ¿Un modelo con un subconjunto de variables es preferible a el modelo saturado?

Justifique ampliamente su respuesta.

Generalmente, un modelo con un subconjunto de variables puede ser preferible a un modelo "saturado" (que incluye todas las variables disponibles) por varias razones:

- Principio de Parsimonia: Un modelo más simple con menos variables es más fácil de interpretar y comunicar. Incluir variables que no contribuyen significativamente a explicar la variable dependiente puede oscurecer las relaciones importantes.
- Reducción de la Multicolinealidad: Incluir variables altamente correlacionadas (multicolinealidad) puede llevar a estimaciones de coeficientes inestables y difíciles de interpretar. Un modelo con un subconjunto de variables puede mitigar este problema al excluir variables redundantes.
- Mejora de la Generalización: Un modelo saturado puede ajustarse muy bien a los datos de la muestra (alto R^2), pero puede no generalizar bien a nuevos datos. Esto se conoce como "sobreajuste". Un modelo más simple a menudo tiene mejor capacidad de predicción fuera de la muestra.
- Grados de Libertad: Un modelo con menos variables tiene más grados de libertad, lo que puede llevar a estimaciones de parámetros más eficientes.
- Criterios de Información: Criterios como el AIC (Criterio de Información de Akaike) y el BIC (Criterio de Información Bayesiano) penalizan la inclusión de variables innecesarias. Un modelo con un subconjunto de variables puede tener valores de AIC y BIC más bajos, indicando un mejor equilibrio entre el ajuste y la complejidad.

Sin embargo, la preferencia por un modelo con un subconjunto de variables depende de si este modelo más simple aún captura una parte sustancial de la variabilidad en la variable dependiente y si las variables excluidas realmente no tienen un efecto significativo.

- c) Si ha sido afirmativa, estime un modelo con el subconjunto de variables seleccionadas, además debería explicar porque seleccionaría tales variables para explicar las remuneraciones de los ejecutivos.

Calculemos los resultados de los siguientes modelos para al final comparar los valores de R^2 , AIC, BIC y el VIF de cada uno:

- Modelo ajustado (sin la variable empleo)
- Modelo ajustado (sin la variable ventas)
- Modelo ajustado (sin la variable utilidades)

Modelo ajustado (sin la variable empleo):

$$\text{Remuneraciones} = \beta_0 + \beta_1 \ln(\text{Ventas}) + \beta_2 \ln(\text{Utilidades}) + e.$$

OLS Regression Results										
Dep. Variable:	remuneraciones	R-squared:	0.492							
Model:	OLS	Adj. R-squared:	0.458							
Method:	Least Squares	F-statistic:	14.54							
Date:	Tue, 13 May 2025	Prob (F-statistic):	3.85e-05							
Time:	04:25:55	Log-Likelihood:	-194.39							
No. Observations:	33	AIC:	394.8							
Df Residuals:	30	BIC:	399.3							
Df Model:	2									
Covariance Type:	nonrobust									
	coef	std err	t	P> t	[0.025	0.975]				
const	-122.2051	143.924	-0.849	0.403	-416.138	171.728				
ln_ventas	27.6926	41.533	0.667	0.510	-57.129	112.514				
ln_utilidades	62.5383	42.232	1.481	0.149	-23.710	148.787				
Omnibus:	1.964	Durbin-Watson:	2.589							
Prob(Omnibus):	0.374	Jarque-Bera (JB):	1.089							
Skew:	0.426	Prob(JB):	0.580							
Kurtosis:	3.256	Cond. No.	87.3							
Notes:										
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.										

Y su VIF es:

	Variable	VIF
0	const	81.183497
1	ln_ventas	6.527606
2	ln_utilidades	6.527606

Modelo ajustado (sin la variable ventas):

$$\text{Remuneraciones} = \beta_0 + \beta_2 \ln(\text{Utilidades}) + \beta_3 \text{Empleo} + e$$

14

OLS Regression Results

Dep. Variable:	remuneraciones	R-squared:	0.492
Model:	OLS	Adj. R-squared:	0.459
Method:	Least Squares	F-statistic:	14.55
Date:	Wed, 14 May 2025	Prob (F-statistic):	3.82e-05
Time:	02:07:23	Log-Likelihood:	-194.38
No. Observations:	33	AIC:	394.8
Df Residuals:	30	BIC:	399.2
Df Model:	2		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
const	3.2632	112.775	0.029	0.977	-227.053	233.580
empleo	0.0003	0.000	0.677	0.504	-0.001	0.001
ln_utilidades	76.8083	23.848	3.221	0.003	28.104	125.513

Omnibus:	3.081	Durbin-Watson:	2.626
Prob(Omnibus):	0.214	Jarque-Bera (JB):	1.911
Skew:	0.556	Prob(JB):	0.385
Kurtosis:	3.393	Cond. No.	5.19e+05

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

[2] The condition number is large, 5.19e+05. This might indicate that there are strong multicollinearity or other numerical problems.

Y su VIF:

	Variable	VIF
0	const	49.867832
1	empleo	2.082501
2	ln_utilidades	2.082501

Modelo ajustado (sin la variable Utilidades):

$$\text{Remuneraciones} = \beta_0 + \beta_1 \ln(\text{ventas}) + \beta_3 \text{Empleo} + e$$

15

OLS Regression Results

Dep. Variable:	remuneraciones	R-squared:	0.472
Model:	OLS	Adj. R-squared:	0.437
Method:	Least Squares	F-statistic:	13.40
Date:	Wed, 14 May 2025	Prob (F-statistic):	6.93e-05
Time:	02:17:02	Log-Likelihood:	-195.03
No. Observations:	33	AIC:	396.1
Df Residuals:	30	BIC:	400.6
Df Model:	2		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
const	-125.8682	165.300	-0.761	0.452	-463.455	211.719
ln_ventas	68.5611	23.109	2.967	0.006	21.366	115.757
empleo	0.0004	0.000	0.977	0.336	-0.000	0.001

Omnibus:	2.243	Durbin-Watson:	2.129
Prob(Omnibus):	0.326	Jarque-Bera (JB):	1.488
Skew:	0.518	Prob(JB):	0.475
Kurtosis:	3.098	Cond. No.	7.38e+05

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

[2] The condition number is large, 7.38e+05. This might indicate that there are strong multicollinearity or other numerical problems.

Y su VIF es:

	Variable	VIF
0	const	102.968602
1	empleo	1.943163
2	ln_ventas	1.943163

En conclusión:

Modelo	R^2	AIC	BIC
Saturado	0.498	396.4	402.4
Sin la variable empleo	0.492	394.8	399.3
Sin la variable ventas	0.492	394.8	399.2
Sin la variable utilidades	0.472	396.1	400.6

Podemos observar que los modelos más parsimoniosos y con mejor ajuste según los criterios BIC y AIC son aquellos que excluyen la variable Empleo o la variable Ventas. Además, la pérdida en el R^2 al excluir "Empleo" (de 0.498 a 0.492) o "Ventas" (de 0.498 a 0.492) es relativamente pequeña, mientras que la exclusión de "Utilidades" resulta en una caída más notable del R^2 (a 0.472) y un aumento en el AIC y BIC.

Analizando el VIF:

- El modelo que excluye la variable Ventas presenta valores de VIF muy bajos, lo que sugiere que no hay problemas de multicolinealidad significativos entre las variables restantes (empleo y logaritmo de las utilidades).
- El modelo que excluye la variable Empleo muestra valores de VIF más altos, indicando una mayor correlación entre el logaritmo de las ventas y el logaritmo de las utilidades.
- El modelo que excluye la variable Utilidades muestra valores de VIF pequeños, sin embargo, no podemos elegir este modelo debido a sus AIC y BIC.

El modelo sin la variable Ventas parece ser la mejor opción. Ofrece un buen equilibrio entre ajuste (con valores de BIC y AIC competitivos con el modelo sin Empleo, y una pérdida de R^2 pequeña respecto al modelo completo) y baja multicolinealidad.

Justificación:

- Importancia Teórica: Tanto el tamaño de la empresa (medido por el empleo) como su rendimiento financiero (medido por las utilidades) son factores plausibles que influyen en la compensación de los ejecutivos. Empresas más grandes y más rentables probablemente tendrán estructuras salariales más altas.
- Evidencia Empírica (criterios de información): El modelo que incluye estas dos variables (y excluye Ventas) presenta valores de BIC y AIC que son

menores que los del modelo completo, sugiriendo un mejor equilibrio entre ajuste y complejidad.

- Baja Multicolinealidad: Los valores del VIF para el Empleo y el logaritmo de las Utilidades en este modelo son bajos, lo que indica que estas variables no están altamente correlacionadas entre sí, proporcionando estimaciones de coeficientes más estables y confiables.

9) **Journal of Pharmaceutical Sciences** presentó en 1991 un artículo sobre **la fracción molar de un soluto a temperatura constante**. También se midió la dispersión, x_1 , la solubilidad en el enlace bipolar, x_2 y, la solubilidad del enlace de hidrógeno, x_3 .

(comentario: en el modelo es el logaritmo negativo $pH = -\log[aH^+]$ de la fracción molar).

a) Ajuste un modelo de regresión múltiple, pruebe $H_0: \beta_0 = \beta_1 = \beta_2 = \beta_3 = 0$.

Estadístico F: 35.28104442874941
Valor p: 2.7741823338534033e-07


Utilizamos el modelo de regresión múltiple, además, nos apoyamos en el estadístico F para corroborar que dicho modelo propuesto era significativo o no, como se puede observar, en efecto es significativo, adicionalmente, el valor p obtenido es significativamente menor que 0.05, lo que nos permite rechazar la hipótesis nula, indicando que al menos uno de los coeficientes de regresión es diferente de cero. Recordemos que aquí usamos un nivel de significancia del 95%, pero no es una regla estándar y pudimos usar un nivel de significancia diferente.

b) ¿Los residuos de este primer modelo son satisfactorios?


Estadístico t para residuos: -1.3911367984382727e-14
Valor p para residuos: 0.9999999999999889

El valor p obtenido es 0.999999, lo que es mucho mayor que 0.05, esto significa que no se puede rechazar la hipótesis nula de que la media de los residuos es cero, indicando que los residuos no son significativamente diferentes de cero, esto sugiere que el modelo está bien ajustado ya que los errores están equilibrados alrededor de cero.


- c) Grafique los residuos en comparación con x_1 , x_2 y x_3 (3 gráficas). Haga un análisis de una de estas 3 gráficas.



Residuos vs x1: La gráfica muestra una dispersión aleatoria alrededor de cero, lo que sugiere que no hay una relación sistemática entre x_1 y los residuos.



Residuos vs x2: La dispersión también parece aleatoria, indicando que x_2 no introduce sesgo en los residuos.



Residuos vs x_3 : No se observa un patrón claro ni heterocedasticidad, lo cual respalda la validez del modelo.

En general, las tres gráficas muestran residuos distribuidos aleatoriamente alrededor de cero, lo que sugiere que el modelo captura bien las relaciones lineales entre las variables independientes y la respuesta.

d) Considere los modelos adicionales que compitan con el modelo anterior:

Modelo 2: agregué x_1^2, x_2^2, x_3^2

Modelo 3: agregue $x_1^2, x_2^2, x_3^2, x_1x_2, x_1x_3, x_2x_3$

Resumen Modelo 2:

OLS Regression Results						
Dep. Variable:	y	R-squared:	0.934			
Model:	OLS	Adj. R-squared:	0.904			
Method:	Least Squares	F-statistic:	30.78			
Date:	Wed, 14 May 2025	Prob (F-statistic):	5.88e-07			
Time:	06:32:39	Log-Likelihood:	37.103			
No. Observations:	20	AIC:	-60.21			
Df Residuals:	13	BIC:	-53.24			
Df Model:	6					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
const	-2.1681	1.161	-1.868	0.084	-4.675	0.339
x1	0.5346	0.265	2.015	0.065	-0.039	1.108
x2	-0.0047	0.035	-0.135	0.895	-0.081	0.071
x3	0.0235	0.020	1.176	0.261	-0.020	0.067
x1_sq	-0.0275	0.015	-1.828	0.091	-0.060	0.005
x2_sq	0.0034	0.007	0.476	0.642	-0.012	0.019
x3_sq	-0.0070	0.002	-2.839	0.014	-0.012	-0.002
Omnibus:	0.206	Durbin-Watson:	1.551			
Prob(Omnibus):	0.902	Jarque-Bera (JB):	0.404			
Skew:	-0.118	Prob(JB):	0.817			
Kurtosis:	2.345	Cond. No.	8.96e+03			

Resumen Modelo 3:

OLS Regression Results						
Dep. Variable:	y	R-squared:	0.964			
Model:	OLS	Adj. R-squared:	0.932			
Method:	Least Squares	F-statistic:	29.97			
Date:	Wed, 14 May 2025	Prob (F-statistic):	4.49e-06			
Time:	06:32:39	Log-Likelihood:	43.200			
No. Observations:	20	AIC:	-66.40			
Df Residuals:	10	BIC:	-56.44			
Df Model:	9					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
const	-2.1260	0.978	-2.173	0.055	-4.305	0.053
x1	0.4848	0.224	2.163	0.056	-0.015	0.984
x2	0.2130	0.095	2.241	0.049	0.001	0.425
x3	0.0278	0.070	0.394	0.702	-0.129	0.185
x1_sq	-0.0224	0.013	-1.756	0.110	-0.051	0.006
x2_sq	-0.0047	0.009	-0.509	0.622	-0.025	0.016
x3_sq	-0.0078	0.002	-3.188	0.010	-0.013	-0.002
x1x2	-0.0210	0.008	-2.519	0.030	-0.040	-0.002
x1x3	-0.0008	0.006	-0.134	0.896	-0.014	0.013
x2x3	0.0003	0.007	0.039	0.970	-0.016	0.017
Omnibus:	0.617	Durbin-Watson:	2.337			
Prob(Omnibus):	0.735	Jarque-Bera (JB):	0.020			
Skew:	0.002	Prob(JB):	0.990			
Kurtosis:	3.155	Cond. No.	9.94e+03			

e) También valide estos 2 últimos modelos.

- Modelo 2: Incluye términos cuadráticos, lo que mejora el ajuste con un AIC menor y un R-cuadrado ajustado mayor que el Modelo 1.
- Modelo 3: Incluye términos cuadráticos e interacciones. Es el modelo más complejo,

con el menor AIC y el mayor R-cuadrado ajustado, lo que indica el mejor ajuste de los tres.

- Conclusión: La inclusión de términos cuadráticos y de interacción en el Modelo 3 permite capturar mejor las relaciones no lineales, lo que lo hace el más adecuado para pronósticos precisos.

f) Determine cuál es el más idóneo para pronosticar la fracción molar.

El modelo más idóneo para pronosticar la fracción molar es el Modelo 3, ya que presenta el menor valor de AIC (-66.40) y el mayor R-cuadrado ajustado (0.932), lo que sugiere que logra un equilibrio óptimo entre ajuste y complejidad del modelo.

10) Contexto:

Una encuesta de clientes existentes de **HATCO**. Midió entre otras cosas más; la percepción de **HATCO** sobre 7 atributos identificados en estudios pasados como los más influyentes en la elección de proveedores.

Los encuestados, gerentes de compras de empresas que compran a **HATCO**, calificaron a **HATCO** en cada atributo.

Atributos:

- X1: rapidez de envío
- X2: nivel de precios
- X3: flexibilidad de precios
- X4: imagen del fabricante
- X5: servicio global
- X6: imagen del personal de ventas
- X7: calidad del producto
- Y: especificación de compra.

Los datos son los perfiles (*especificación de compra*) de 4 grupos de clientes respecto a los 7 factores. Los datos proporcionados deberían darle a **HATCO** una mejor comprensión tanto de las características de sus clientes y las relaciones entre sus percepciones de **HATCO** y sus acciones hacia **HATCO** (*compras y satisfacción*).

Diccionario de variables:

- X1 = Velocidad de entrega: cantidad de tiempo que lleva entregar el producto una vez al año el pedido ha sido confirmado.
- X2 = Nivel de precios: nivel percibido de precios cobrados por los proveedores de productos.
- X3 = Flexibilidad de precios: disposición percibida de los representantes de HATCO para Negociar precio en todo tipo de compras.
- X4 = Imagen del fabricante---imagen general del fabricante/proveedor.
- X5 = Servicio: nivel general de servicio necesario para mantener un servicio satisfactorio en relación entre proveedor y comprador.
- X6 = Imagen de Salesforce---imagen general de la fuerza de ventas del fabricante
- X7 = Calidad del producto: nivel percibido de calidad de un producto en particular (*p. ejm., rendimiento o rendimiento*)

Objetivo del inciso 10):

Determinar si las diferencias en las percepciones de **HATCO** permiten distinguir entre clientes haciendo uso de las Especificaciones de compra frente al análisis del Valor total.

(archivo *hatco.completo.xlsx*)

Logit Regression Results						
Dep. Variable:	ESPCOMPR	No. Observations:	60			
Model:	Logit	Df Residuals:	52			
Method:	MLE	Df Model:	7			
Date:	Wed, 14 May 2025	Pseudo R-squ.:	0.8325			
Time:	07:01:39	Log-Likelihood:	-6.8279			
converged:	True	LL-Null:	-40.752			
Covariance Type:	nonrobust	LLR p-value:	4.018e-12			
	coef	std err	z	P> z	[0.025	0.975]
const	-8.4547	14.548	-0.581	0.561	-36.968	20.059
DELSPEED	4.9252	8.865	0.556	0.579	-12.451	22.301
PRICELEV	7.6160	9.762	0.780	0.435	-11.517	26.749
PRICEFLE	-1.9305	1.242	-1.554	0.120	-4.366	0.505
MANUFIMA	4.9059	4.121	1.190	0.234	-3.171	12.983
SERVICE	-14.3965	19.610	-0.734	0.463	-52.830	24.038
SALESFOR	-9.2902	6.703	-1.386	0.166	-22.429	3.848
PRODUCTQ	3.7579	2.141	1.755	0.079	-0.439	7.955

Atributo: DELSPEED - Estadístico t: -8.0446, Valor p: 0.0000
Atributo: PRICELEV - Estadístico t: 4.6870, Valor p: 0.0000
Atributo: PRICEFLE - Estadístico t: -8.3780, Valor p: 0.0000
Atributo: MANUFIMA - Estadístico t: 0.3736, Valor p: 0.7095
Atributo: SERVICE - Estadístico t: -2.2278, Valor p: 0.0282
Atributo: SALESFOR - Estadístico t: -0.4219, Valor p: 0.6740
Atributo: PRODUCTQ - Estadístico t: 9.2844, Valor p: 0.0000

Matriz de Confusión:

[[20 5]

[2 13]]

Precisión: 0.825

Reporte de Clasificación:

	precision	recall	f1-score	support
0	0.91	0.80	0.85	25
1	0.72	0.87	0.79	15
accuracy			0.82	40
macro avg	0.82	0.83	0.82	40
weighted avg	0.84	0.82	0.83	40

- La prueba t permite identificar si existen diferencias significativas entre los grupos en cada atributo.
- El modelo de regresión logística evalúa si las percepciones pueden clasificar

correctamente a los clientes.

- La matriz de confusión y la precisión indican qué tan bien el modelo logra distinguir entre los dos tipos de clientes.

Análisis de Diferencias en Percepciones:

- Se realizó una prueba t para cada atributo relevante (rapidez de envío, nivel de precios, flexibilidad de precios, imagen del fabricante, servicio global, imagen del personal de ventas y calidad del producto).
-
- Los resultados de la prueba t indicaron cuáles de estos atributos presentan diferencias significativas entre los dos grupos de clientes.
-
- Aquellos atributos con un valor p menor a 0.05 indican diferencias estadísticamente significativas en la percepción de los clientes.

Capacidad de Clasificación:

- Se utilizó un modelo de regresión logística para predecir el tipo de cliente basado en las percepciones evaluadas.
- La precisión del modelo y la matriz de confusión mostraron la efectividad del modelo para distinguir entre los grupos.

Conclusión:

Los resultados obtenidos muestran que las diferencias en las percepciones de HATCO, en particular aquellos atributos que resultaron significativos en la prueba t, sí permiten distinguir entre los clientes que utilizan Especificación de Compra y aquellos que prefieren el Análisis del Valor Total.

El modelo de regresión logística ajustado logró clasificar adecuadamente a los clientes con una precisión significativa, lo que confirma que las percepciones medidas son útiles para diferenciar entre los dos tipos de clientes.