

FES ACATLÁN, UNAM

Proyecto I: Regresión simple, múltiple y no lineal

(Modulo: Regresión y series de tiempo)



Requisitos de entrega:

- Se entregará conforme a las agrupaciones de trabajo generadas dentro el primer modulo del diplomado.
- Se entregará un único documento (tipo de archivo '.pdf') por equipo, donde estarán cada una de las respuestas de las actividades mencionados aquí abajo y, exclusivamente a partir del inciso número siete, deberá presentarse en formato de Informe Gerencial. Además, si se ha utilizado algún modulo especifico, distinto a los vistos en clase, también incluir el código completo de python en los Anexos.
- La fecha de entrega será a más tardar a medio día del próximo miércoles 14 de mayo. Enviarlo al correo institucional.

Rubricas:

- Respuestas de investigación y/o desarrollo matemático claras y concisas (incisos 2, 5 y 6)
- Interpretación de resultados generados en lenguaje Python (análisis de la información debidamente contextualizada) del resto de incisos.
- Todo el documento debe estar unificado, es decir, con el mismo Estilo

Proyecto-examen

- 1) A continuación, se muestran las capturas de tres muestras de peces: Casta Rica, Tilapia y Paleta realizadas en el cuerpo de agua: Presa Presidente Miguel Alemán. Obteniéndose las siguientes mediciones: longitud (en centímetros), W_calculado: Peso en gramos y Biomasa (peso total de los organismos vivos o el peso total de una población de peces o un recurso pesquero).

CASTA RICA

Longitud	Frecuencia	W calculado	Biomasa
19	1	163.523062	163.523062
20	1	185.801858	185.801858
22.5	1	249.130159	249.130159

23.5	3	277.621568	832.864703
24	1	292.564329	292.564329
24.5	2	307.978263	615.956526
26	1	357.09471	357.09471

TILAPIA

Longitud	Frecuencia	W calculado	Biomasa
12.0	1	24.6617092	24.6617092
12.5	3	28.4654051	85.3962154
14.0	16	42.3893228	678.229165
14.5	26	47.9518855	1246.74902
15.0	23	54.0181016	1242.41634
15.5	21	60.6144896	1272.90428
16.0	17	67.7680261	1152.05644
16.5	16	75.5061386	1208.09822
17.0	56	83.8566985	4695.97512
17.5	37	92.8480148	3435.37655
18.0	43	102.508827	4407.87957
18.5	39	112.868301	4401.86373
19.0	42	123.95602	5206.15283
19.5	42	135.801982	5703.68325
20.0	106	148.436594	15734.2789
20.5	62	161.890664	10037.2212
21.0	169	176.195402	29777.0229
21.5	149	191.382407	28515.9787
22.0	201	207.483671	41704.2179
22.5	190	224.531568	42660.9979
23.0	203	242.558853	49239.4472
23.5	124	261.598658	32438.2336
24.0	207	281.684485	58308.6885
24.5	145	302.850207	43913.2801
25.0	152	325.13006	49419.7691
25.5	108	348.55864	37644.3331
26.0	121	373.170901	45153.679
26.5	33	399.002152	13167.071
27.0	85	426.088053	36217.4845
27.5	67	454.464608	30449.1287
28.0	54	484.168168	26145.0811
28.5	25	515.235424	12880.8856
29.0	36	547.703407	19717.3227

29.5	39	581.609482	22682.7698
30.0	28	616.991345	17275.7576
30.5	20	653.887023	13077.7405
31.0	32	692.334872	22154.7159
31.5	25	732.373568	18309.3392
32.0	22	774.042114	17028.9265
32.5	11	817.379827	8991.1781
33.0	10	862.426346	8624.26346
33.5	10	909.22162	9092.2162
34.0	3	957.805914	2873.41774
34.5	2	1008.2198	2016.4396
35.0	2	1060.50416	2121.00832
35.5	3	1114.70018	3344.10054
36.0	3	1170.84935	3512.54805
36.5	3	1228.99346	3686.98038
37.5	1	1351.43517	1351.43517
39.0	1	1551.12166	1551.12166

PALETA

Longitud	Frecuencia	W calculado	Biomasa
14	1	41.2481052	41.2481052
15	3	53.3848886	160.154666
15.5	1	60.3468652	60.3468652
17	4	85.2371081	340.948432
19.5	1	142.358532	142.358532
20	4	156.490717	625.962867
20.5	2	171.624235	343.24847
21	1	187.803002	187.803002
21.5	4	205.071731	820.286925
22	4	223.475929	893.903714
22.5	1	243.061889	243.061889
23	3	263.876691	791.630072
24.5	3	334.176584	1002.52975
25	1	360.393046	360.393046
25.5	3	388.085337	1164.25601
29	1	627.69081	627.69081

- Establezca (si la hay) una relación entre Peso, Biomasa y longitud. Justifique con precisión su respuesta

- Si su respuesta ha sido afirmativa, modele tal relación.

- 2) En ocasiones es adecuado aplicar transformaciones a los datos, investigue y comente: ¿cuántas, cuáles y la utilidad de cada una de ellas?.
- 3) Modele la cantidad de miles de dólares de lo aportado a la asociación de exalumnos Alabama Tech por la generación de 1960 como una función del numero de años transcurrido desde la graduación:

año	aportado
1	812.52
2	822.5
3	1211.5
4	1348
8	1301
9	2567.5
10	2526.5
11	2755
12	4390.5
13	5581.5
14	5548
15	6086
16	5764
17	8903

- a) Determine si es plausible un ajuste por MCO, justifique numéricamente y/o gráficamente
 - b) Si ha sido afirmativa su respuesta, estime el modelo $\mu_{Y|x} = \beta_0 + \beta_1 x$
 - c) Valide el modelo anterior
 - d) Realice una prueba de falta de ajuste
 - e) Estime ahora el modelo $\mu_{Y|x} = \beta_0 + \beta_1 x + \beta_2 x^2$, válidelo
 - f) Determine cuál de los modelos en los incisos b y e es preferible.
- 4) Para una variedad particular de planta los investigadores desean desarrollar una fórmula para predecir la cantidad de semillas (en gramos) como una función de densidad de las plantas. Efectuaron un estudio con cuatro niveles de factor: número de plantas por parcela. Se utilizaron cuatro réplicas por parcela para cada nivel del factor. A continuación, se muestran las mediciones:

Plantas por parcela	cantidad de semillas (gramos)			
10	12.6	11	12.1	10.9
20	15.3	16.1	14.9	15.6
30	17.9	18.3	18.6	17.8
40	19.2	19.6	18.9	20

¿es adecuado un modelo de regresión simple para analizar los datos? (Pista: se reitera, hay medidas repetidas en la variable explicativa).

- 5) Para la regresión logística:
 - a) ¿cuál es el método que se emplea para estimar los coeficientes del modelo?,
 - b) El estadístico de prueba se distribuye Normal, ¿cuál es el nombre de esta prueba y cuál es la fórmula del estadístico de prueba de la misma?,
 - c) explica: el pseudo R^2 de McFadden, R^2 de Cox-Snell y R^2 de Nagelkerke.
- 6) Dadas dos variables aleatorias X y Y que tienen función de densidad conjunta $f(x, y) = xe^{-x(1+y)}$ para $x > 0, y > 0$. Encontrar la ecuación de regresión de Y sobre X y bosqueje la curva de regresión.

El archivo de excel BASES.xlsx contine diversas bases de datos que se emplearán a los siguientes contextos (7-9).

- 7) Se efectuó un estudio para determinar si el género del titular de la tarjeta de crédito es un factor en la generación de utilidades para cierta empresa de tarjetas de crédito. Las variables consideradas fueron: ingreso, número de miembros de la familia y genero del titular de la tarjeta de crédito. Los datos se encenctran en la Hoja 1 de BASES.xlsx
 - a) Ajuste un modelo de regresión lineal. Con base en este, ¿la empresa preferiría clientes del género femenino o masculino?
 - b) ¿el ingreso es un factor importante para explicar la variabilidad de la utilidad?
- 8) En un esfuerzo por modelar las remuneraciones de los ejecutivos en el año de 2009 se seleccionaron 33 empresas y se recabaron datos acerca de las

remuneraciones, las ventas, las utilidades y el empleo. Se reunieron los siguientes datos (Hoja 2)

- c) Considere el modelo $y = \beta_0 + \beta_1 \ln x_1 + \beta_2 \ln x_2 + \beta_3 x_3 + e$, ajuste el modelo.
 - d) ¿un modelo con un subconjunto de variables es preferible a el modelo saturado? Justifique ampliamente su respuesta
 - e) Si ha sido afirmativa, estime un modelo con el subconjunto de variables seleccionas, además debería explicar porque seleccionaría tales variables para explicar las remuneraciones de los ejecutivos
- 9) Journal of Pharmaceutical Sciences presentó en 1991 un artículo sobre la fracción molar de un soluto a temperatura constante. También se midió la dispersión, x_1 , la solubilidad en el enlace bipolar, x_2 y, la solubilidad del enlace de hidrogeno, x_3 . (comentario: en el modelo y es el logaritmo negativo $pH = -\log[aH^+]$ de la fracción molar).
- f) Ajuste un modelo de regresión múltiple, pruebe $H_0: \beta_0 = \beta_1 = \beta_2 = \beta_3 = 0$.
 - g) ¿Los residuos de este primer modelo son satisfactorios?
 - h) Gráfique los residuales en comparación con x_1, x_2 y x_3 (tres gráficas) Haga análisis de una de estas tres graficas.
 - i) Considere los modelos adicionales que compitan con el modelo anterior:
Modelo 2: agregué x_1^2, x_2^2, x_3^2
Modelo 3: agregue $x_1^2, x_2^2, x_3^2, x_1x_2, x_1x_3, x_2x_3$
 - j) También valide estos dos últimos modelos
 - k) Determine cual es el más idóneo para pronosticar la fracción molar
- 10) ** Contexto: Una encuesta de clientes existentes de HATCO. Midió entre otras cosas más, la percepción de HATCO sobre siete atributos identificados en estudios pasados como los más influyentes en la elección de proveedores. Los encuestados, gerentes de compras de empresas que compran a HATCO, calificaron a HATCO en cada atributo.
- Atributos:
- X1: rapidez de envío
 - X2: nivel de precios
 - X3: flexibilidad de precios
 - X4: imagen del fabricante
 - X5: servicio global
 - X6: imagen del personal de ventas

X7: calidad del producto

Y: especificación de compra.

Los datos son los perfiles (especificación de compra) de cuatro grupos de clientes respecto a los siete factores. Los datos proporcionados deberían darle a HATCO una mejor comprensión tanto de las características de sus clientes y las relaciones entre sus percepciones de HATCO y sus acciones hacia HATCO (compras y satisfacción).

Diccionario de variables:

X1 Velocidad de entrega: cantidad de tiempo que lleva entregar el producto una vez al año el pedido ha sido confirmado.

X2 Nivel de precios: nivel percibido de precios cobrados por los proveedores de productos.

X3 Flexibilidad de precios: disposición percibida de los representantes de HATCO para Negociar precio en todo tipo de compras.

X4 Imagen del fabricante---imagen general del fabricante/proveedor.

X5 Servicio: nivel general de servicio necesario para mantener un servicio satisfactorio relación entre proveedor y comprador.

X6 Imagen de Salesforce---imagen general de la fuerza de ventas del fabricante

X7 Calidad del producto: nivel percibido de calidad de un producto en particular (p. ejm., rendimiento o rendimiento)

Objetivo del inciso 10). Determinar si las diferencias en las percepciones de HATCO permiten distinguir entre clientes haciendo uso de las Especificaciones de compra frente al análisis del Valor total. (archivo **hatco.completo.xlsx**)

Sugerencia de procedimiento:

- 1) Dividir la muestra en dos grupos, el primero con 60 observaciones seleccionadas aleatoriamente (las 40 restantes, serán para validar el modelo de regresión logística)
- 2) Ajustar un modelo de regresión logit a la muestra de entrenamiento conforme a lo expuesto en el inciso 1).
- 3) Valide el modelo con la muestra de entrenamiento
- 4) Finalmente Mostrar la matriz de confusión y la precisión para la muestra de prueba.