

DIPLOMADO TÉCNICAS ESTADÍSTICAS Y MINERÍA DE DATOS

MÓDULO IV – MINERÍA DE DATOS

M. C. JAVIER ROSAS HERNÁNDEZ

805226@pcpuma.acatlan.unam.mx
jrosashe@gmail.com



MÓDULO IV - TEMARIO

- **4.1 Introducción a la Minería de Datos**
 - 4.1.1 El proceso de descubrimiento de conocimiento y la minería de datos
 - 4.1.2 Fuentes de datos
 - 4.1.3 DWH (OLTP y OLAP)
 - 4.1.4 Relación de la minería de datos con otras disciplinas
 - 4.1.5 Aplicaciones de minería de datos
 - 4.1.6 Qué es y qué no es minería de datos
 - 4.1.7 Introducción a las técnicas de minería de datos
 - 4.1.8 Clasificación de las técnicas de minería de datos
- **4.2 Pre-procesamiento de datos**
 - 4.2.1 Clasificación de los atributos
 - 4.2.2 Integración y limpieza de los datos
 - 4.2.3 Transformación
- **4.3 Técnicas de minería de datos**
 - 4.3.1 Asociaciones y correlaciones
 - 4.3.2 Clasificación y predicción
 - 4.3.3 Árboles de decisión
 - 4.3.4 Clasificación utilizando probabilidades de Bayes
 - 4.3.5 Clasificación basada en reglas
 - 4.3.6 Redes Neuronales
 - 4.3.7 Análisis de centroides
- **4.4 Evaluación de los resultados obtenidos y presentación de datos**
 - 4.4.1 Medidas de eficiencia
 - 4.4.2 Curva de ROC
- **4.5 Herramientas para minería de datos**
 - 4.5.1 La necesidad de herramientas computacionales para el proceso de extracción de conocimiento
 - 4.5.2 Algoritmos para las técnicas de minería de datos
 - 4.5.3 Software de minería de datos
 - 4.5.3.1 Enterprise Miner
 - 4.5.3.2 Rapid Miner

LOGÍSTICA


- Poner foto en CETED - [Educación Continua FES Acatlán: Iniciar sesión en el sitio](#)
- Link Microsoft Teams - <https://bit.ly/4kcQHK7>
- Descargar App o desde web
- Pueden o no poner el video
- Intermedio – Recreo - Break
- Dudas
 - Levantar la mano
 - Escribir en el chat (CETED, Teams), Escribir en el Foro
 - Enviar correo (PCPuma, Gmail)
 - **NO whatsapp**
- Tiempo respuesta 1-2 días
- Sin actividad en la plataforma serán dados de baja
- Sesiones Miércoles 6 pm – 9 pm y Sábados 8 am – 1 pm -
- 24, 28, 31 de mayo, 4, 7, 11, 14, 18, 21 y 25 de junio de 2025

Software
Altair RapidMiner Studio

<https://altair.com/altair-rapidminer-free-trials>

“AI won’t take your job, but someone using AI will.”

The person hired to replace you using AI:



La IA en los
Demos de venta

//

La IA cuando
comienzas a usarla



PRESENTACIÓN



- **¿Quién soy? Carrera y otros**
- **¿Qué hago relacionado a datos?**
- **¿Para qué este Diplomado?**
- **NO TITULARME**
- **Opcional: Poner video**

EVALUACIÓN

50%

5-7 prácticas

I Exposición (del proyecto)



50%

Proyecto Aplicable

Trabajo escrito

Fecha de Entrega

Último día o una semana después





2021 GARTNER MAGIC QUADRANT FOR DATA SCIENCE AND MACHINE LEARNING PLATFORMS

Figure 1: Magic Quadrant for Analytics and Business Intelligence Platforms



Source: Gartner (February 2021)

2021 GARTNER MAGIC QUADRANT FOR ANALYTICS AND BUSINESS INTELLIGENCE PLATFORMS

Figure 1: Magic Quadrant for Analytics and Business Intelligence Platforms



Source: Gartner (March 2022)

2022 GARTNER MAGIC QUADRANT FOR ANALYTICS AND BUSINESS INTELLIGENCE PLATFORMS



2023 GARTNER MAGIC QUADRANT FOR ANALYTICS AND BUSINESS INTELLIGENCE PLATFORMS

Figure 1: Magic Quadrant for Data Science and Machine Learning Platforms



2024 MAGIC QUADRANT
FOR DATA SCIENCE AND
MACHINE LEARNING
PLATFORMS

Figure 1: Magic Quadrant for Analytics and Business Intelligence Platforms



2024 GARTNER MAGIC
QUADRANT FOR
ANALYTICS AND
BUSINESS INTELLIGENCE
PLATFORMS

MINERÍA DE DATOS

- La Minería de Datos es una ***disciplina*** reciente y prometedora.
- La Minería de Datos puede verse como el resultado natural de la evolución de la Tecnología de Información y muy especialmente de las bases de datos.

EVOLUCION

60's

- Sistemas de procesamiento de archivos

70's

- Sistemas de bases de datos jerárquicas
- Sistemas de bases de datos de red
- Sistemas de bases de datos relacionales
- Herramientas de modelado de datos
- Métodos de acceso e indexación
- Lenguajes de consulta
- Administración de transacciones
- OLTP

EVOLUCION

80's

- Se adopta la tecnología relacional
- Modelo Entidad/Relación extendido
- Modelo Orientado a Objetos
- Modelo Objetos/Relacional
- Modelos deductivos
- Sistemas de bases de datos orientados a aplicaciones
- Sistemas de bases de datos heterogéneos
- Sistemas de Información global basados en Internet

EVOLUCIÓN


ruta de evolución

desde un punto de vista funcional

- Recolección de datos y creación de bases de datos ->
- Desarrollo de mecanismos efectivos de almacenamiento y recuperación de los datos, consultas y procesamiento de transacciones ->
- Análisis avanzado de los datos: data warehouse (almacén de datos) y minería de datos.

Cada etapa es un pre-requisito de la siguiente y esta a su vez es una consecuencia de la anterior.

DATA WAREHOUSE VS DATA MINING



EVOLUCIÓN

■ Enriquecimiento de datos pero información pobre

- El uso de los Sistemas de bases de datos ha dejado grandes volúmenes de datos.
 - Se ha excedido la capacidad humana de análisis y comprensión de los datos.
 - Las decisiones son tomadas con base en la experiencia e intuición y no con la información almacenada en los repositorios.
 - Necesidad de herramientas de análisis poderosas.
- 
- Con las técnicas de Minería de Datos podemos ver los grandes repositorios (anteriormente inútiles) de datos como grandes minas.
 - Utilizando dichas técnicas podemos convertir los datos en información útil.


EVOLUCIÓN – KDD – KNOWLEDGE DISCOVERY IN DATABASES

- **Data cleaning:** eliminar ruido e inconsistencias.
- **Data integration:** combinación de múltiples fuentes de datos.
- **Data selección:** selección de datos relevantes para el análisis.
- **Data transformation:** aplicación de operaciones de transformación o consolidación de los datos para su análisis.
- **Data mining:** aplicación de métodos inteligentes para extraer patrones de interés.
- **Pattern evaluation:** identificación de los patrones encontrados que representación información.
- **Presentación del conocimiento:** herramientas visuales presentación el conocimiento encontrado.


DATA WAREHOUSE

- Repositorio de múltiples fuentes de datos heterogéneas organizados bajo un esquema unificado en un solo sitio, orientados a facilitar la toma de decisiones.
 - Limpieza e integración de datos
 - OLAP (Técnicas de análisis): sumarización, consolidación y agregación.
 - Soporta herramientas de Análisis multi-dimensional y para la toma de decisiones.


DWH VS DM





KNOWLEDGE



OLTP









ACTIVIDAD – DISEÑO ER

Se desea mantener la información correspondiente a las películas estrenadas en los cines mexicanos en los últimos años. Sobre cada película interesa conocer información acerca del director, actores y productores que participan en la misma, así como los premios recibidos por las películas, directores, actores y productores en diversos festivales. También se desea considerar el número de espectadores y la recaudación de cada película en cada cine donde ha sido estrenada. Las restricciones al problema son:


- a) El título de una película no es único. Sobre el mismo guion pueden realizarse distintas versiones y éstas pueden tener el mismo título o distinto. De igual manera dos películas diferentes pueden tener el mismo título. Aunque dos películas tengan el mismo título no pueden haberse realizado en el mismo año, ni tienen a los mismos actores, ni director, etc.
- b) No interesa conocer a los directores, productores ni actores a no ser que participen en alguna película sobre las que se desea almacenar la información.
- c) Cada actor tiene asignado un nivel de importancia: actor principal, de reparto, etcétera.
- d) Los festivales de cine en los que se presentan las películas organizan certámenes anuales para premiar los trabajos cinematográficos del año. Los premios son característicos de cada festival y pueden ser otorgados o no, es decir puede haber premios desierto. También suelen otorgar premios a la trayectoria artística de los concursantes.
- e) Las películas se proyectan más de una vez en el mismo cine durante cierto periodo de días.




KIMBALL DATA LIFE CYCLE



INMON DATA WAREHOUSE




DATA VAULT ARCHITECTURE




CUBO OLAP (DWH)

CUBOS





ARQUITECTURA ESTRELLA

Es el diseño de DW más simple. La principal característica de un esquema de estrella es una tabla central, llamada tabla de hechos (fact table) y tablas de dimensiones (dimension tables) que permite explorar categorías específicas, sumarizados, listados y criterios particulares.



Fact Table





PRÁCTICA I - PBI

Realizar el siguiente laboratorio de PowerBI

Tutorial: From dimensional model to stunning report in Power BI Desktop - Power BI | Microsoft Docs
(<https://docs.microsoft.com/en-us/power-bi/create-reports/desktop-dimensional-model-report>)


Realizar 3 cambios personalizados al reporte

- Agregar un gráfico
- Indicar dónde se encuentran y cuáles son los procesos de ETL
- Agregar un indicador, métrica o cambio de datos
- Indicar cuáles son las tablas de hechos y dimensiones
- Subir la pantalla con su resultado, agregando tu nombre en el reporte (o el archivo .pbix)
- No ejecutar el último paso (publicación del reporte)


PROCESO DE MINERÍA DE DATOS

Pasos involucrados


- Integración de Datos
- Selección de Datos
- Limpieza de Datos
- Transformación de Datos
- Minería de Datos
- Evaluación de patrones
- Presentación del conocimiento




PROCESO KDD





PROCESO MINERÍA DE DATOS






Data Science: The Who and How



Data Science: Machine Learning Overview



E2E ML Life Cycle



Data Preparation

Multiple Data Sources
Multiple Formats
Cleansing
Transformation



Model Building

Choice of algorithms
Choice of language
Choice of development tools
Local Testing



Model Training

Code first, No Code, Low Code
Distributed Training
Hyperdrive



Model Registration and Management

Containerization
Versioning
Model Repository
Track Experiments



Model Deployment


Deploying your model
Real time Inferencing
Batch Inferencing
Monitoring



CRISP - DM


CROSS INDUSTRY STANDARD PROCESS
FOR DATA MINING

IBM




KNOWLEDGE DISCOVERY IN DATABASES SAS

Data Science Lifecycle



THE MICROSOFT TEAM DATA SCIENCE PROCESS (TDSP)

CICLO DE VIDA DE LA IA ACTUAL



BREVE HISTORIA DE LA IA

Artificial Intelligence

Machine Learning

Deep Learning

Generative AI

1956

Artificial Intelligence

El campo de las ciencias de la computación que busca crear máquinas inteligentes que puedan replicar o superar la inteligencia humana

1997

Machine Learning

subconjunto de IA que permite a las máquinas aprender de los datos existentes y mejorarlos para tomar decisiones o predicciones

2017

Deep Learning

Una técnica de aprendizaje automático en la que se utilizan capas de redes neuronales para procesar datos y tomar decisiones

2021

Generative AI

Cree nuevos contenidos escritos, visuales y auditivos a partir de indicaciones o datos existentes.

CLASIFICACIÓN DE LAS TÉCNICAS ANALÍTICAS

DESCRIPTIVAS

DIAGNÓSTICAS

PREDICTIVAS

PRESCRIPTIVAS

Nivel de Madurez de la Organización



¿Qué ha pasado?

¿Por qué ha pasado?

¿Qué va a pasar?

¿Qué hacer para que pase?

Estadística descriptiva

Data Discovery

Estadística inferencial

Optimización

Reporting

Regresiones

Simulación de procesos

Visualización

Pronósticos

Simulación de Montecarlo

Segmentación y árboles de decisión

Minería de Datos

Minería de Texto

Redes Neuronales


Machine Learning


Big Data Analytics

ESTADÍSTICA DESCRIPTIVA

<i>Estadística Descriptiva Descargue</i>	
Media	4,1
Error típico	0,2
Mediana	3,9
Moda	4,7
Desviación estándar	2,0
Varianza de la muestra	4,0
Coficiente de variabilidad	0,5
Curtosis	10,5
Coeficiente de asimetría	2,4
Rango	14,0
Mínimo	1,1
Máximo	15,1
Suma	543,3
Cuenta	131,0
Nivel de confianza(95,0%)	0,3

<i>Análisis de datos</i>					
Cuartil 1	2,9	DI	2,3	Outliers por debajo	0,0
Cuartil 2	3,9	1,5DI	3,4	Outliers por encima	3,0
Cuartil 3	5,1	LI	-0,5	Total Outliers	3,0
Cuartil 4	15,1	LS	8,5	Muestra	102,0






Power BI Public Preview

How You Live & What You Do


for STEM workers by Industry Size and Mean Earnings




es. Highest and Lowest
EST




Unemployment Rate



Housing Prices 2007 vs 2010





Jobs Rate of Change by Sector 2002 - 2012, 2012 - 2022




DIAGNÓSTICAS

BI y Data Discovery

PREDICTIVAS – SERIES DE TIEMPO



junio
acerque dieran julio
brownie ejemolo harinera convenios hubiera
ademas com especiales horarios bonos frecuente comprandole daban
beneficios consumidor estudiar manejo canales creditos asi fomentar capacitaciones continuidadnfon
consumo navideñas meses capacidad cupo mantenga caja acuerdo fechas antigüedad realiza
recetas panadero compras depronto mejoraran cantidad lineas bono - experiencia rapida puesto
comun comunicacion empaque nreclamos competir navidad aplica invitaciones bajar comprando establecidos
podtia insumos oportuna degustqiones pedido **gestion** informacion compra impulso aplicaciones somos
dias programadas descargue visitas **mercadeo** **soporte** **cuidado** mantener hdv impulsadoras algun
quejas vendedor **poder** **comerciales** **descuento** **excelente** **completamente** vias mes
natura **satisfecho** **planta** **comercial** **mejorar** **precios** **almacenamiento** servicios
ventajas **curso** **descuentos** **precio** cliente ruta
sostenga **competitivo** relacion comprar
regalos
volumen
correo
procesos
tecnicas
esten
conoce
promociones
servicio **calidad** **capacitacion** **asesoria** sanidad
empresa **tecnica** **bajos** **propiedades** **tecnico** **ofertas** **acompañamiento** **credito** **anos** **rifas** **fumigacion** **entrega** **eventos** **visita** **asesorias** a
listos almanaques saber innovacion **desarrollo** **incentivos** **asesor** pro
antiguos seugidosnsinnimportar instalaciones **proyectos** mantenimier
mire tenernuna sentido manejar ayuda sistemas mantenervel ventas cual
genera motivo adecuado utiliza medidos concursos solucion conserve pag
harina orolemas capacitacion valle muestras condiciones necesite are



PREDICTIVAS

MINERÍA DE
TEXTO

SEGMENTACIÓN


PRESCRIPTIVA – MODELOS DE OPTIMIZACIÓN


Condiciones	Proyecto 1	Proyecto 2	Proyecto 3	Proyecto 4	Proyecto 5	Proyecto 6	Proyecto 7	Proyecto 8	Proyecto 9	Proyecto 10
Inversión (\$)	515	440	734	637	127	633	767	336	195	87
Impacto (Personas beneficiadas)	1691	1497	2058	1264	1881	1668	2278	2251	1514	1631
Cobertura (Regiones beneficiadas)	5	6	5	9	6	3	10	10	1	3

Restricciones	Valor	Unidad
Presupuesto disponible	3000	COP\$
Impacto mínimo	5000	Personas
Cobertura mínima	9	Regiones

Opciones:

- Maximizar impacto
- Maximizar cobertura
- Minimizar presupuesto





PRESCRIPTIVA – SIMULACIÓN DISCRETA