

DIPLOMADO TÉCNICAS ESTADÍSTICAS Y MINERÍA DE DATOS

MÓDULO IV – MINERÍA DE DATOS

M. C. JAVIER ROSAS HERNÁNDEZ


805226@pcpuma.acatlan.unam.mx
jrosashe@gmail.com



PREPROCESAMIENTO DE DATOS

El éxito de un proceso de Minería de Datos depende no solo de tener todos los datos necesarios (una buena recopilación) sino de que éstos estén íntegros, completos y consistentes (una buena limpieza e integración)

PROCESO DE CALIDAD DE DATOS



CALIDAD DE DATOS

Proceso de Calidad de Datos

- **Perfilado de datos:** Consisten en evaluar los datos en cuanto a sus estructuras, contenido.
 - Localizar, Medir, Monitorear, Reportar
- **Mejora de datos ó enriquecimiento:** Dentro de este proceso se considera la incorporación de datos en la base, permitiendo aumentar la completitud en los datos.
- **Matching:** Como su nombre lo indica, este proceso se encarga de encontrar datos con coincidencias y relaciones entre sí.

Dimensiones más comunes para la Calidad

- Completitud
- Conformidad
- Consistencia
- Precisión/exactitud
- Duplicación
- Integridad
- Oportuno/actual

CALIDAD DE DATOS

EL PROBLEMA

La calidad de los datos ha mejorado, se ha avanzado en la construcción de reglas de integridad.

No ha sido suficiente!!

Es una realidad.

- Los sistemas siguen creciendo.
- En las bases de datos existe mucha información incorrecta respecto al dominio de la realidad.
- Existen datos inconsistentes.
- Si los datos provienen de diferentes fuentes,
 - ...los datos erróneos se suman, pero las inconsistencias se multiplican, ...varias fuentes afirman cosas diferentes del mismo objeto.
 - ...normalmente hay disparidad de formatos, nombres y rangos.
 - ...podemos encontrar datos faltantes o duplicados.

Se dificulta el proceso de extracción de conocimiento!!

CALIDAD DE DATOS

Objetivos:

- Eliminar el mayor número posible de datos erróneos, inconsistentes e irrelevantes.
 - Presentar los datos de la manera más apropiada para el proceso y los algoritmos de minería de datos.
- INTEGRACIÓN
 - LIMPIEZA
 - SELECCIÓN
 - TRANSFORMACIÓN

PREPROCESAMIENTO DE DATOS

TÉCNICAS DE PREPROCESAMIENTO DE LOS DATOS

- Técnicas que nos ayudan a la integración y limpieza.
 - Cálculo de medias, varianzas y correlaciones
 - Histogramas
 - Gráficos de dispersión
 - Detección de valores anómalos
- Transformaciones.
 - Redefinición de atributos
 - Creación de nuevos atributos
 - Separación de atributos
 - Discretización
 - Numerización
 - Sumarización
 - Pivotación
 - Generalización
- Técnicas clásicas del análisis multivariante.
- Análisis factorial.
- Técnicas de selección.

PREPROCESAMIENTO DE DATOS

INTEGRACIÓN

EL PROBLEMA DEL
ESCLARECIMIENTO DE IDENTIDAD

Para la integración se deben identificar los objetos, es decir, necesitamos que : **datos sobre el mismo objeto se unifiquen y datos de diferentes objetos permanezcan separados.**

Durante la integración pueden ocurrir dos tipos de errores:

- Dos o más objetos diferentes se unifican.
- Dos o más fuentes del mismo objeto se dejan separadas.

Es muy problemático cuando se utilizan valores agregados como total de compras de una persona.

PREPROCESAMIENTO DE DATOS

<i>rfc</i>	<i>nombre</i>	<i>edo. civil</i>	<i>f.nac.</i>

<i>CURP</i>	<i>nombre</i>	<i>soltero</i>	<i>edad</i>



<i>rfc</i>	<i>nombre</i>	<i>edo. civil</i>	<i>f.nac.</i>	<i>CURP</i>	<i>nombre</i>	<i>soltero</i>	<i>edad</i>

PREPROCESAMIENTO DE DATOS

Generalmente se es conservador, si se tiene duda a la hora de unificar, se deja los objetos separados.

Se pueden encontrar problemas de unificación de formatos.

Se puede encontrar diferentes unidades de medición.

Si el dato está en una fuente, pero no en la otra, se generan datos faltantes.

Es común que aparezcan datos redundantes total o parcialmente como edad y fecha de nacimiento, ciudad y CP, etc.

A la hora de unificar, los datos inconsistentes, normalmente se convierten en faltantes, ya que ante la duda, se deja el campo faltante. (También se puede elegir la media o la moda o un valor por defecto.)

PREPROCESAMIENTO DE DATOS

Una vez integrados los datos...

Informe de estado: resumen de las características de los atributos. Se puede hacer por tabla o para toda la base de datos.

Las características a mostrar para cada atributo son:

- Nombre de la tabla
- Tipo de datos (nominal o numérico)
- Total de instancias
- Cantidad de nulos o faltantes
- Distancia entre los atributos
- Media
- Desviación estándar
- Moda
- Valor mínimo
- Valor máximo
- ...entre otros

PREPROCESAMIENTO DE DATOS

En una **tabla resumen** se puede visualizar fácilmente esta información, se puede construir fácilmente a partir de consultas SQL.

También se puede visualizar la información en un **histograma** que muestra la distribución para los diferentes valores de un atributo. Para el caso de los atributos numéricos se realiza por intervalos.

Un **diagrama de caja** muestra la información resumida de los histogramas.

Para visualizar dos variables se pueden construir **histogramas tridimensionales**, podemos ver la distribución de una variable o atributo respecto a otro.

Una **gráfica de dispersión** también nos muestra la información de dos variables y es muy útil en atributos numéricos. Se puede agregar otra dimensión marcando utilizando una marca diferente para cada valor del tercer atributo. Para cuatro variables se pueden obtener todas gráficas para las posibles combinaciones de atributos, generando una tabla de gráficas de dispersión.

PREPROCESAMIENTO DE DATOS

VALORES FALTANTES

Razones para remplazar un *missing value*

- Si el método de minería de datos que vamos a utilizar no le da un adecuado tratamiento a dichos valores.
 - Ignora los ejemplos con datos faltantes, podemos tener un sesgo importante en los datos.
 - Si tiene un método de remplazo no apropiado, pues desconoce el contexto de los datos.
- Para realizar agregaciones que nos permitan crear otras vistas minables de los datos.

PREPROCESAMIENTO DE DATOS

DETECCIÓN

Iniciamos revisando la tabla resumen.

A veces los campos faltantes no están representados como nulos

- Valores fuera de formato
- Valores fuera de rango
- Texto indicados como “no tiene”
- Números indicados como -1 o 99

Las restricciones de las aplicaciones o las restricciones de integridad referencial a veces ayudan a evitar los datos faltantes, pero a veces son las que causan los peores problemas. Si no tenemos un valor para un atributo y la aplicación lo permite, simplemente no lo ponemos, este faltante será fácil de detectar. Si la aplicación no permite dejar el campo vacío, entonces ocurren casos como el 3 y 4 que se conoce como nulos camuflados.

PREPROCESAMIENTO DE DATOS

QUE PUEDEN REPRESENTAR LOS VALORES FALTANTES:

Características relevantes: la falta de un celular puede representar una persona que no desea que se le contacte por ese medio.

Valores no existentes: a veces en verdad representan datos que no existen, por ejemplo un cliente nuevo que no ha realizado consumos.

Datos incompletos: pueden ser en realidad datos incompletos comúnmente generados en procesos de integración.

PREPROCESAMIENTO DE DATOS

TRATAMIENTO

- Ignorar.
- Eliminar: quitar el atributo para todos los ejemplos (la columna).
- Filtrar: quitar las filas.
- Remplazar: manual o automático. Se sugiere en casos donde no haya muchos. Normalmente la media para atributos numéricos o la moda para atributos nominales.
- Predecir: (Imputación de datos faltantes). Se puede intentar predecir el valor a partir de otros ejemplos. Ej. Predecir el sexo a partir del nombre.
- Segmentar: Separar las tuplas y generar modelos diferentes para las tuplas con datos faltantes.
- Esperar: que los datos faltantes estén disponibles.

PREPROCESAMIENTO DE DATOS

VALORES ERRONEOS

DETECCIÓN

Para atributos nominales

- Datos que no se ajustan al formato.
- Datos con valores no permitidos.
- Datos inconsistentes, que se ajustan al formato y que son permitidos pero que representan una situación que no se presenta o no está permitida en la realidad, ej. Matriculas nuevas para autos viejos.
- Para datos erróneos que se ajusten al formato será muy complicada o imposible su detección.

PREPROCESAMIENTO DE DATOS

Para atributos numéricos

Buscar datos anómalos, atípicos, extremos, aislados. Conocidos como **outliers**.

Un valor anómalo no representa siempre un valor erróneo.

Un valor dentro de la normalidad puede ser un dato erróneo.

Hay datos anómalos que no son erróneos y que no son convenientes para algunas técnicas de minería de datos.

PREPROCESAMIENTO DE DATOS

TRATAMIENTO

- Ignorar. (hay algoritmos robustos)
- Eliminar: quitar el atributo para todos los ejemplos (la columna).
- Filtrar: quitar las filas.
- Remplazar: por un valor nulo.
- Predecir: Se puede intentar predecir el dato correcto mediante una técnica de DM.
- Discretizar, así los valores anómalos caerán en los rangos extremos.

TRANSFORMACIÓN

EL TIPO DE UN ATRIBUTO
DETERMINA EN GRAN MEDIDA
COMO VA A SER TRATADO POR
LAS HERRAMIENTAS DE MINERÍA
DE DATOS

DISCRETIZACIÓN:

Convertir un atributo numérico a nominal ordenado.

NUMERIZACIÓN:

Convertir un atributo nominal a numérico.

PREPROCESAMIENTO DE DATOS

DISCRETIZACION (CUANTIZACIÓN)

- También llamado **binning**.
- Cada nuevo valor nominal representa un intervalo o **bin**.
- Se recomienda cuando:
 - Existen umbrales significativos. (calificaciones)
 - Interpretación no lineal de una medida.
 - Homogenizar el tipo de atributos.

NUMERIZACIÓN

- Se utiliza cuando el método de minería de datos no admite valores nominales.
- 1 a n
- 1 a n-1
- 1 - 1

PREPROCESAMIENTO DE DATOS

¿Por qué es importante el nivel de medición?

Conocer el nivel de medición ayuda a decidir cómo interpretar los datos de esa variable.

Ayuda a decidir qué análisis estadístico es apropiado en los valores que se asignaron. Si una medida es nominal, entonces nunca promediaría los valores de los datos o haría una prueba t en los datos.

Normalmente hay cuatro niveles de medición que se definen, conocido como NOIR:

- Nominal
- Ordinal
- Intervalo
- Ratio

PREPROCESAMIENTO DE DATOS

- En la medición **nominal**, los valores numéricos simplemente "nombran" el atributo de forma única. No se implica ningún orden de los casos.
 - Por ejemplo, los números de camisetas en el baloncesto son medidas a nivel nominal. Un jugador con el número 30 no es más de nada que un jugador con el número 15, y ciertamente no es el doble del número 14.
- En la medición **ordinal**, los atributos se pueden ordenar por rango. Aquí, las distancias entre atributos no tienen ningún significado.
 - Por ejemplo, en una encuesta podría codificar Logros Académicos como 0=menor que Prepa; 1=Prepa incompleta; 2=grado Prepa.; 3=universidad trunca; 4=título universitario; 5=post universidad. En esta medida, un mayor número significa más educación.
 - Pero, ¿es la distancia de 0 a 1 igual que la de 3 a 4? No. El intervalo entre valores no es interpretable en una medida ordinal.


PREPROCESAMIENTO DE DATOS

- En la medición de **interval**, la distancia entre atributos tiene significado. El intervalo entre valores es interpretable. Debido a esto, tiene sentido calcular un promedio de una variable de intervalo, donde no tiene sentido hacerlo para escalas ordinales.
 - Por ejemplo, cuando medimos la temperatura (en Fahrenheit), la distancia de 30-40 es la misma que la distancia de 70-80. Pero considerar que en las relaciones de medición de intervalos no tienen ningún sentido: 80 grados no es dos veces más caliente que 40 grados (aunque el valor del atributo es dos veces más grande).
- Finalmente, en la medición de **ratio** siempre hay un cero absoluto que es significativo. Esto significa que se puede construir una fracción significativa (o relación) con una variable de relación. El peso es una variable de relación.
 - En la investigación social aplicada la mayoría de las variables de "recuento" son la relación, por ejemplo, el número de clientes en los últimos seis meses. ¿por qué? Porque se puede tener cero clientes y porque tiene sentido decir que "... tuvimos el doble de clientes en los últimos seis meses que en los seis meses anteriores".

EJERCICIO 2 – CLASIFICACIÓN ATRIBUTOS

Classify the following attributes as discrete, or continuous. Also classify them as qualitative (nominal or ordinal) or quantitative (interval or ratio). Some cases may have more than one interpretation, so briefly indicate your reasoning if you think there may be some ambiguity.

- a) Number of telephones in your house
- b) Size of French Fries (Medium or Large or X-Large)
- c) Ownership of a cell phone
- d) Number of local phone calls you made in a month
- e) Length of longest phone call
- f) Length of your foot
- g) Price of your textbook
- h) Zip code
- i) Temperature in degrees Fahrenheit
- j) Temperature in degrees Celsius
- k) Temperature in Kelvin



E2 – CLASIFICACION DE ATRIBUTOS

				Qualitative		Quantitative		
	Binario	Discreto	Continuo	Nominal	Ordinal	Intervalo	Ratio	Comentarios
Tarifa uber			X		X		X	Si se considera cupón para viaje gratis es de Ratio

SIMILITUD O MEDIDA DE DISTANCIA

- La similitud es un número cercano a cero cuando las instancias son muy parecidas e incrementa entre más distintas son las instancias.

REQUERIMIENTO DE UNA FUNCIÓN DE DISTANCIA

$$\mathbf{X}_i = (x_{i1}, x_{i2}, x_{i3}, \dots, x_{in})$$

$$\mathbf{X}_j = (x_{j1}, x_{j2}, x_{j3}, \dots, x_{jn})$$

- $d(\mathbf{X}_i, \mathbf{X}_j) \geq 0$
- $d(\mathbf{X}_i, \mathbf{X}_i) = 0$
- $d(\mathbf{X}_i, \mathbf{X}_j) = d(\mathbf{X}_j, \mathbf{X}_i)$
- $d(\mathbf{X}_i, \mathbf{X}_j) \leq d(\mathbf{X}_i, \mathbf{X}_h) + d(\mathbf{X}_h, \mathbf{X}_j)$

MEDIDAS DE SIMILITUD

Distancia máxima:

$$d(\mathbf{X}_i, \mathbf{X}_j) = \max_p |x_{ip} - x_{jp}|$$

Distancia Manhattan:

$$d(\mathbf{X}_i, \mathbf{X}_j) = \sum_p |x_{ip} - x_{jp}|$$

Distancia Euclidiana:

$$d(\mathbf{X}_i, \mathbf{X}_j) = \sqrt{\sum_p (x_{ip} - x_{jp})^2}$$

Distancia Minkowski:

$$d(\mathbf{X}_i, \mathbf{X}_j) = \left(\sum_p |x_{ip} - x_{jp}|^n \right)^{\frac{1}{n}}$$

DISTANCIA EUCLIDIANA

Distancia Euclidiana:

$$d(\mathbf{X}_i, \mathbf{X}_j) = \sqrt{\sum_p (x_{ip} - x_{jp})^2}$$

Distancia Euclidiana (cuadrática):

$$d^2(\mathbf{X}_i, \mathbf{X}_j) = \sum_p (x_{ip} - x_{jp})^2$$

$$d^2(\mathbf{X}_i, \mathbf{X}_j) = \sum_p [(x_{ip} - x_{jp})(x_{ip} - x_{jp})]$$

DISTANCIA EUCLIDIANA

$$(\mathbf{X}_i - \mathbf{X}_j) = \begin{bmatrix} (x_{i1} - x_{j1}) \\ (x_{i2} - x_{j2}) \\ \dots \\ (x_{in} - x_{jn}) \end{bmatrix}$$

$$(\mathbf{X}_i - \mathbf{X}_j)^T = [(x_{i1} - x_{j1}), (x_{i2} - x_{j2}), \dots, (x_{in} - x_{jn})]$$

$$\begin{aligned} (\mathbf{X}_i - \mathbf{X}_j)^T (\mathbf{X}_i - \mathbf{X}_j) &= [(x_{i1} - x_{j1}), (x_{i2} - x_{j2}), \dots, (x_{in} - x_{jn})] \begin{bmatrix} (x_{i1} - x_{j1}) \\ (x_{i2} - x_{j2}) \\ \dots \\ (x_{in} - x_{jn}) \end{bmatrix} \\ &= \sum_p [(x_{ip} - x_{jp})(x_{ip} - x_{jp})] \end{aligned}$$

DISTANCIA EUCLIDIANA

Distancia Euclidiana:

$$d(\mathbf{X}_i, \mathbf{X}_j) = \sqrt{\sum_p (x_{ip} - x_{jp})^2}$$

$$d^2(\mathbf{X}_i, \mathbf{X}_j) = \sum_p (x_{ip} - x_{jp})^2$$

$$d^2(\mathbf{X}_i, \mathbf{X}_j) = \sum_p [(x_{ip} - x_{jp})(x_{ip} - x_{jp})]$$

$$d^2(\mathbf{X}_i, \mathbf{X}_j) = (\mathbf{X}_i - \mathbf{X}_j)^T (\mathbf{X}_i - \mathbf{X}_j)$$

Distancia Euclidiana:

$$d^2(\mathbf{X}_i, \mathbf{X}_j) = (\mathbf{X}_i - \mathbf{X}_j)^T (\mathbf{X}_i - \mathbf{X}_j)$$

Distancia Mahalanobis:

$$d^2(\mathbf{X}_i, \mathbf{X}_j) = (\mathbf{X}_i - \mathbf{X}_j)^T \Sigma (\mathbf{X}_i - \mathbf{X}_j)$$

Σ , es la matriz de varianza-covarianza, de $n \times n$.

Atributos Categóricos

- Si son iguales, la distancia es 0, si son diferentes la distancia es 1.

CÁLCULO DE DISTANCIA

ID	Concierto	Costo
1	Shakira	8500
3	Guns	6000
5	Bad Bunny	11000
8000	Peso Pluma	7500

$$d(x_i, x_j) = d(x_1, x_3) = \max_p |x_{1,p} - x_{3,p}|$$

$$d(x_1, x_3) = \max_p |x_{1,ID} - x_{3,ID}, x_{1,Concierto} - x_{3,Concierto}, x_{1,Costo} - x_{3,Costo}|$$

$$d(x_1, x_3) = \max_p |1-3, Shakira - Guns, 8500 - 6000|$$

$$d(x_1, x_3) = \max_p |-2, 1, 2500| = 2500$$

$$d(x_1, x_5) = \max_p = 2500$$

$$d(x_1, x_8) = \max_p = 7999$$

$$d(x_5, x_8) = \max_p = 3500$$

Distancia máxima:

$$d(X_i, X_j) = \max_p |x_{ip} - x_{jp}|$$

Distancia Manhattan:

$$d(X_i, X_j) = \sum_p |x_{ip} - x_{jp}|$$

Distancia Manhattan

$$d(x_1, x_3) = \sum |1, 1, 2500| = 2501$$

$$d(x_1, x_5) = \sum |1, 1, 1-3500| = 3501$$

$$d(x_1, x_8) = \sum |1, 1, 1000| = 1001$$

$$d(x_5, x_8) = \sum |1, 1, 3500| = 3501$$

CÁLCULO DE DISTANCIA

ID	Concierto	Costo	Duración
1	Shakira	8500	120.5
3	Guns	6000	130.3
5	Bad Bunny	11000	75.8
8000	Peso Pluma	7500	100.1

Distancia Euclidiana:

$$d^2(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i - \mathbf{x}_j)^T (\mathbf{x}_i - \mathbf{x}_j)$$

Distancia Mahalanobis:

$$d^2(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i - \mathbf{x}_j)^T \Sigma (\mathbf{x}_i - \mathbf{x}_j)$$

Σ , es la matriz de varianza-covarianza, de $n \times n$.

$$d^2(\mathbf{x}_i, \mathbf{x}_j) = \sum_p (x_{ip} - x_{jp})^2$$

Distancia Euclidiana cuadrática

$$\begin{aligned} d^2(\mathbf{x}_1, \mathbf{x}_3) &= \sum (1^2, 2500^2, -9.8^2) = 6250096.04 \\ d^2(\mathbf{x}_1, \mathbf{x}_5) &= \sum (1^2, -2500^2, 44.7^2) = 6251999.09 \\ d^2(\mathbf{x}_1, \mathbf{x}_8) &= \sum (1^2, 1000^2, 20.4^2) = 1000417.16 \end{aligned}$$

$$d^2(\mathbf{x}_3, \mathbf{x}_5) = 25,002971.25$$

Distancia Euclidiana

$$\begin{aligned} d(\mathbf{x}_1, \mathbf{x}_3) &= \sqrt{\sum (1^2, 2500^2, -9.8^2)} = 2500 \\ d(\mathbf{x}_1, \mathbf{x}_5) &= \sqrt{\sum (1^2, -2500^2, 44.7^2)} = 2500.39 \\ d(\mathbf{x}_1, \mathbf{x}_8) &= \sqrt{\sum (1^2, 1000^2, 20.4^2)} = 1000.20 \end{aligned}$$

$$d(\mathbf{x}_3, \mathbf{x}_5) = 5000.29$$

Distancia Euclidiana
(2 atributos)

$$\begin{aligned} d(\mathbf{x}_1, \mathbf{x}_3) &= 2500 \\ d(\mathbf{x}_1, \mathbf{x}_5) &= 2500 \\ d(\mathbf{x}_1, \mathbf{x}_8) &= 1000 \end{aligned}$$

$$d(\mathbf{x}_3, \mathbf{x}_5) = 5000$$

CÁLCULO DE DISTANCIA

ID	Concierto	Costo
1	Shakira	8500
3	Guns	6000
5	Bad Bunny	11000
8000	Peso Pluma	7500

Distancia Euclidiana:

$$d^2(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i - \mathbf{x}_j)^T (\mathbf{x}_i - \mathbf{x}_j)$$

Distancia Mahalanobis:

$$d^2(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i - \mathbf{x}_j)^T \Sigma (\mathbf{x}_i - \mathbf{x}_j)$$

Σ , es la matriz de varianza-covarianza, de $n \times n$.

$$\text{COV} (X , Y) = \Sigma (x - \text{avg}(x)) (y - \text{avg}(y)) / n$$

$$d^2(x_3, x_5) = (1, -5000) \begin{pmatrix} 1 & 1498187 \\ 1498187 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -5000 \end{pmatrix} = -7490935000, 1493186 \quad \begin{pmatrix} 1 \\ -5000 \end{pmatrix} = -1.4956 \times 10^{10}$$

NORMALIZACIÓN DE DATOS

- Para normalizar la columna correspondiente al atributo j.

$$col[A_j]' = \frac{col[A_j] - min_{A_j}}{max_{A_j} - min_{A_j}}$$

NORMALIZACIÓN

- Supóngase los siguientes valores de sueldos entre \$12,000 y \$98,000, ¿cuál sería el valor normalizado para un sueldo de \$73,600
- Sueldo normalizado = $(73600 - 12000) / (98000 - 12000) = 0.71$
- Atributo calificaciones, entre 5 y 10. Un alumno con calificación de 7.3
- Calificación normalizada = $(7.3 - 5) / (10 - 5) = 0.46$

- Para normalizar la columna correspondiente al atributo j.

$$col[A_j]' = \frac{col[A_j] - min_{A_j}}{max_{A_j} - min_{A_j}}$$

NORMALIZACIÓN

ID	Concierto	Costo	CostoNorm	Duración	DuraNorm
1	Shakira	8500	0.5	120.5	0.82
3	Guns	6000	0	130.3	1
5	Bad Bunny	11000	1	75.8	0
8	Peso Pluma	7500	0.3	100.1	0.44

$\text{Min}_{\text{Costo}} = 6000$

$\text{Máx}_{\text{Costo}} = 11000$

$$\text{CostoNorm}(1) = (8500 - 6000) / (11000 - 6000) = 0.5$$

$$\text{CostoNorm}(3) = (6000 - 6000) / (11000 - 6000) = 0$$

$$\text{CostoNorm}(5) = (11000 - 6000) / (11000 - 6000) = 1$$

$$\text{CostoNorm}(8) = (7500 - 6000) / (11000 - 6000) = 0.3$$

- Para normalizar la columna correspondiente al atributo j.

$$col[A_j]' = \frac{col[A_j] - min_{A_j}}{max_{A_j} - min_{A_j}}$$

NORMALIZACIÓN

ID	Concierto	Costo	CostoNorm	Duración	DuraNorm
1	Shakira	8500	0.5	120.5	0.64
3	Guns	6000	0	130.3	0.78
5	Bad Bunny	11000	1	75.8	0
8	Peso Pluma	7500	0.3	100.1	0.35
11	Fabulosos	7200	0.24	145	1

Nueva data

Min_{Costo} = 6000

Máx_{Costo} = 11000

$$\text{CostoNorm}(1) = (8500 - 6000) / (11000 - 6000) = 0.5$$

$$\text{CostoNorm}(3) = (6000 - 6000) / (11000 - 6000) = 0$$

$$\text{CostoNorm}(5) = (11000 - 6000) / (11000 - 6000) = 1$$

$$\text{CostoNorm}(8) = (7500 - 6000) / (11000 - 6000) = 0.3$$

- Para normalizar la columna correspondiente al atributo j.

$$col[A_j]' = \frac{col[A_j] - min_{A_j}}{max_{A_j} - min_{A_j}}$$