

DIPLOMADO TÉCNICAS ESTADÍSTICAS Y MINERÍA DE DATOS

MÓDULO IV – MINERÍA DE DATOS

M. C. JAVIER ROSAS HERNÁNDEZ

805226@pcpuma.acatlan.unam.mx
jrosashe@gmail.com



APRENDIZAJE

1

Unsupervised Learning

The data don't have any "true" classes or criteria; groups are shaped by similarity, not accuracy.

2

Supervised Learning

The data now have a true class or outcome variable; accuracy is now the guiding consideration.

MACHINE LEARNING

- El entrenamiento y la implementación de un modelo de aprendizaje automático eficaz implica mucho trabajo, gran parte de él consume mucho tiempo y recursos.
- Los mineros de datos y científicos de datos dedican mucho esfuerzo a explorar, preprocesar datos y probar varios tipos de algoritmos de entrenamiento de modelos para producir modelos más precisos
- El entrenamiento conlleva mucho tiempo y, a menudo, se hace un uso ineficiente del costoso hardware informático.
- Las herramientas para aprendizaje automático ayudan a simplificar algunas de las tareas y reducir el tiempo que se tarda en preparar datos, entrenar un modelo e implementar un servicio predictivo.

MACHINE LEARNING

- Las herramientas y lenguajes para Machine Learning permiten crear y operar soluciones de aprendizaje automático.
- Incluyen una amplia gama de características y capacidades que ayudan a los científicos de datos en:
 - Preparar datos
 - Entrenar modelos
 - Publicar servicios predictivos
 - Supervisar su uso.
 - Aumentar la eficiencia mediante la automatización de muchas de las tareas
 - Les permite usar recursos informáticos algunos basados en la nube que escalan de manera efectiva para manejar grandes volúmenes de datos
 - Ser más eficientes en los costos en la nube al consumir solo cuando se usan realmente

MINERÍA DE DATOS – TIPO DE ANÁLISIS



Clustering



Classification



Association
analysis



Anomaly
detection

TAREAS ESPECIALIZADAS

1

Sequence Mining

In time-ordered data, find events that typically precede or follow each other.

2

Text Mining

In unstructured text data, find words and phrases that define voices and distinguish texts.

PRINCIPALES ENFOQUES

1

Classical Statistics


Methods based on familiar statistics, typically transparent, possible to calculate by hand

2

Machine Learning

More complex methods, often opaque, require substantial computing power

Aprendizaje Supervisado y NO supervisado



ALGORITMOS MÁS COMUNES



Linear
regression



k-means
classification



Hidden
Markov models



Support vector
regression



k-Nearest
Neighbors



Hierarchical
clustering



Random forests



LASSO regression

LASSO - least absolute shrinkage and selection operator

¿TENER MUCHOS DATOS ES MEJOR?


- La reducción de datos ayuda a simplificar el conjunto de datos y a centrarse en variables o construcciones que tienen más probabilidades de transmitir un significado y menos probabilidades de generar ruido.

Restricciones

- Almacenamiento
- Memoria
- Tiempo

Razones estadísticas

- Evitar la multicolinealidad
- Obtener mayores grados de libertad
- Evitar el sobreajuste




TIPOS DE PRE-PROCESAMIENTO

Esta categorización no es mutuamente excluyente.


La eliminación de datos redundantes puede verse como una forma de limpieza de datos, así como la reducción de datos.

En resumen, los datos del mundo real tienden a ser sucios, incompletos e incoherentes

Data cleaning




Data integration



Data transformation

$-2, 32, 100, 59, 48 \longrightarrow -0.02, 0.32, 1.00, 0.59, 0.48$

Data reduction



ANÁLISIS DE COMPONENTES PRINCIPALES - PCA

Problema

- ¿Podemos describir la “información” contenida en estos datos mediante algún conjunto de variables menor que el de variables originales?

Idea:


- Si una variable es función de otras, contiene información redundante.
- Por tanto, si las p variables observadas están fuertemente correlacionadas, será posible sustituirlas por menos variables sin gran pérdida de “información”.

Esta reducción de la dimension va a permitir:

- Simplificar posteriores análisis, que se harán a partir de un menor número de variables que el original.
- Una representación gráfica de los individuos en dimensión reducida (generalmente, 1 o 2).
- Examinar e interpretar las relaciones entre las variables observadas.

ALGORITMOS PARA REDUCCIÓN DE DATOS

- **Análisis de Componentes Principales (PCA)**
 - Reduce el número de variables
 - Maximiza la variabilidad en un espacio de baja dimensionalidad



- **Reducción de la dimensionalidad**
 - Colectores no lineales
 - Usado en visión por computadora, etc.
 - Más complicadas y difíciles de interpretar
 - Kernel PCA
 - Isomap
 - Locally linear embedding
 - Maximum variance unfolding


REDUCCIÓN DIMENSIONALIDAD

- "¿Podemos reducir el volumen de datos eligiendo formas alternativas y 'más pequeñas' de representación de datos?"

Los siguientes datos son una lista de precios de artículos comúnmente vendidos (redondeado al dólar más cercano).

Los números ordenados son:

1, 1, 5, 5, 5, 5, 5, 8, 8,
10, 10, 10, 10, 12, 14, 14, 14,
15, 15, 15, 15, 15, 15, 18, 18, 18, 18, 18, 18, 18, 18,
20, 20, 20, 20, 20, 20, 20, 21, 21, 21, 21,
25, 25, 25, 25, 25, 28, 28, 30, 30, 30.




REDUCCIÓN DIMENSIONALIDAD

- Para reducir aún más los datos, es común que cada valor denote un rango continuo de valores para el atributo dado. Cada barra representa un rango diferente de \$10 para el precio.
- Un histograma de igual distancia para el precio, donde los valores se agregan para que cada barra tenga una distancia uniforme de \$10.


Reglas de partición comunes:

- Equi-distancia: en un histograma de igual ancho, el ancho de cada rango de la barra es uniforme




REDUCCIÓN DIMENSIONALIDAD

Histograma de Equi-frecuencia




- Equi-frecuencia (o equi-profundo): En un histograma de igual frecuencia, las barras se crean para que, aproximadamente, la frecuencia de cada barra sea constante.

Ejemplo gráfico de histograma V-óptimo (aproximado con cuantiles)




- V-Óptimo: Si consideramos todos los histogramas posibles para un número determinado de barras, el histograma V-Optimal es el que tiene la menor varianza con anchos variables.

Histograma MaxDiff




- MaxDiff: En un histograma MaxDiff, consideramos la diferencia entre cada par de valores adyacentes.

Chart Suggestions—A Thought-Starter



ANÁLISIS DE CLÚSTER O CLUSTERING

- Grupos de conveniencia
 - Encontrar grupos de casos que son similares a algún otro
 - La agrupación es pragmática
- Funcionamiento
 - ¿Qué casos pueden ser tratados de la misma manera?
 - Depende de propósitos específicos
- Ejemplos
 - Marketing – Poner el mismo anuncio a un grupo
 - Medicina – Identificar casos similares o medicamentos para los tratamientos parecidos
 - Ecología – Categorizar los ambientes donde viven las especies
 - Leyes – Analizar argumentos similares para a otros casos



CLUSTERING

- **Clustering** es una forma de aprendizaje automático que se usa para agrupar elementos similares en clústeres en función de sus características. Por ejemplo, un investigador podría tomar medidas de pingüinos y agruparlos en función de las similitudes en sus proporciones.
- **Clustering** es un ejemplo de aprendizaje automático no supervisado, en el que se entrena un modelo para separar elementos en clústeres o segmentos basándose únicamente en sus características o *features*. No hay ningún valor de clúster (o etiqueta o *label*) conocido previamente para entrenar el modelo.