



Universidad Nacional Autónoma de México
Facultad de Estudios Superiores Acatlán
Modulo IV



Proyecto: Adicción a las redes sociales.

Para: Rosas Hernández Javier.

Publicado por: Mendieta Lopez David.

Minería de Datos.

30 de junio del 2025.


Análisis de la situación:

Las **redes sociales** son plataformas digitales formadas por comunidades de individuos con intereses, ideas, actividades o relaciones en común que nos conecta e une de forma virtual (*hasta de forma física en algunos casos*).



En la actualidad, las redes sociales se han convertido en una extensión más de nuestra vida ya que nos facilitan el contactarnos con las personas y funciona como un medio de comunicación e intercambio de información. La importancia que tiene, que es posible conectarnos entre personas, solucionar problemas, etc.

Pero no todo es color de rosa; el uso y exceso constante de las redes sociales puede tener el efecto adverso a los que está ofreciendo, tales como:



- *Ser antisocial.*
- *Distorsión de la realidad.*
- *Poco enfoque en las cosas.*
- *Comparativas destructivas.*
- *Realidad algo alterada.*
- *Procrastinación, etc.*

Ayudando a contribuir a enfermedades mentales tales como **depresión, ansiedad, altas expectativas, etc.**

La responsabilidad de colocar límites al tiempo e dedicación al usar las redes sociales está en cada uno de nosotros; pero es algo que las demás personas podemos notar a detectar con facilidad de quienes lo padecen; pero:

¿Es posible cuantificarlos a las personas que son adictas a las redes sociales?

Esta pregunta la realizaron un grupo de personas que decidieron realizar una encuesta en línea abierta a todo el mundo para contestar una serie de preguntas con respecto al uso y tiempo que le dan las redes sociales (*donde los participantes son totalmente anónimos*). La información fue publicada en la plataforma de datos abiertos: **Kaggle**, justo en la siguiente liga:

<https://www.kaggle.com/datasets/adilshamim8/social-media-addiction-vs-relationships/data>



La información de la encuesta es resumida en un par de **V.A.s** que se centra la información centrándose en puntos clave como:

- La intensidad de uso.
- La dinámica de las relaciones.

Cada fila es calificada a cada uno de los registros por medio de una calificación; el detalle recaí en que no se especifica la forma, las reglas o parámetros para recibir dicha calificación, por lo que:

¿Habrá posibilidad de estimar y calificar a los usuarios que son adictos a las redes sociales y podemos quienes son más propenso a esta situación?


Por último, las calificaciones deberán de ser representativas e identificables para determinar el estado en el usuario puedan o no presentar una adicción a las redes sociales. Por lo que es más conveniente que tipo de clasificación es más conveniente para los registros, por lo que la siguiente pregunta es:

¿Se generarán algunos grupos que no se puedan ver a simple vista?

Por lo que podemos empezar con un análisis de los datos y que podemos ver qué información podemos rescatar e utilizar a nuestro favor...

Entendimiento de los Datos:

Los datos están almacenados en un archivo del tipo **.CSV** llamado: **“Students Social Media Addiction”**



Los datos esta distribuidos en una serie de columna que las podemos enlistas de la siguiente forma:

Variable	Descripción
Student_ID	Identificador único del encuestado
Age	Edad en años
Gender	El sexo que tiene el participante: Hombre/Mujer

Academic_Level	Ultimo nivel academico que ha tenido; donde las opciones son: Bachillerato / Pregrado / Posgrado
Country	País de residencia
Avg_Daily_Usage_Hours	Promedio de horas por día en las redes sociales
Most_Used_Platform	La plataforma mas usada por el participante
Affects_Academic_Performance	Autoevaluacion del participante sobre si las redes sociales a tenido efecto abversos a su rendimiento academico con: (Sí/No)
Sleep_Hours_Per_Night	Promedio de horas de sueño por noche
Mental_Health_Score	Salud mental autopercebida (1 = mala a 10 = excelente)
Relationship_Status	Que tipo de relacion tiene el participante: Soltero / En Relación / Complicado
Conflicts_Over_Social_Media	Número de conflictos de relación debido a las redes sociales
Addicted_Score	Puntuación de adicción a las redes sociales (1 = baja a 10 = alta)

La mayoría de las V.A.s tiene nombres que podemos interpretar con facilidad; por otra parte, algunas condiciones que estipularon a las horas de extraer la información:

- Para enfocarse en las adiciones a las redes sociales, la encuesta fue dirigida a los jóvenes que estén cursando alguno de los grados de estudios en su país.
- La encuesta fue dirigida por medio de los correos institucionales de los jóvenes estudiantes.
- Tuvo una previa limpieza en los datos, tales como:
 - Quitaron los registros duplicados.
 - Los datos son válidos (*en sus rangos*) y son campo que se tiene que responder obligatoriamente (*sin valores nulos*).

Extracción, Transformación e Limpieza de los datos: La base de datos esta formada originalmente por 705 Filas y 12 V.A.s de las cuales nos quedamos por 704 registros y 9 V.A.s. Dichas columnas sera la siguientes:


Variable	Tipo de dato	Valores	Descripción
Age	Discreto, Nominal e Ratio	16 - 25	Edad en años
Gender	Boleano, Nominal e Ratio	Hombre = 1 / Mujer = 0	El sexo que tiene el participante
Academic_Level	Discreto, Ordinal e Ratio	Bachillerato = 1 / Licenciatura = 2 / Graduado = 3	Ultimo nivel academico que ha tenido

Avg_Daily_Usage_Hours	Continua, Ordinal e Ratio	1 - 9	Promedio de horas por día en las redes sociales
Affects_Academic_Performance	Boleano, Ordinal e Ratio	Sí = 1 / No = 0	Autoevaluacion del participante sobre si las redes sociales a tenido efecto abversos a su rendimiento academico
Sleep_Hours_Per_Night	Continua, Ordinal e Ratio	3 - 10	Promedio de horas de sueño por noche
Mental_Health_Score	Discreto, Ordinal e Ratio	1 = mala - 10 = excelente	Salud mental autopercebida
Relationship_Status	Discreto, Nominal e Ratio	Soltero = 1 / En Relación = 2 / Complicado = 3	Que tipo de relacion tiene el participante
Conflicts_Over_Social_Media	Discreto, Nominal e Ratio	3 - 5	Número de conflictos de relación debido a las redes sociales
Addicted_Score	Discreto, Ordinal e Ratio	1 = baja - 10 = alta	Puntuación de adicción a las redes sociales

En cuanto a los valores nulos no está presente (*como lo habían indicado*); los registros duplicados no están prácticamente, con excepción de un caso (*el registro 274*).

Análisis de datos: Realicemos algunos términos estadísticos, visualizaciones, gráficas y la información para conocer mejor la base de datos que tenemos a nuestra disposición hay algunos resultados interesantes...


- En cuanto al numero de participantes de la encuesta; se priorizo que la proporción entre hombres y mujeres sean las misma...



Gender	
0	0
1	1

La moda que se genera en cuestión nos arroja los únicos 2 resultados y es conveniente que la forma en predecir; ya que el modelo estaría disponible para ambas partes. Caso contrario a la proporción de otras V.A.s que son muy diferentes y es hago diversifica la información de la base de datos y con ello podemos prevenir un caso “**información Redundantes**”.


Algunos ejemplos son:



Relationship_Status	
2	0.544034
3	0.410511
1	0.045455


Las relaciones sentimentales de los participantes son mas proactivas de lo que uno puede suponer a simple vista *(ya que vemos a los usuarios de las redes sociales como personas con poco contacto con las personas a sus alrededores)*.

Y más presencia de las personas que tiene problemas académicos por el uso de estas plataformas *(contribuyendo a objetivo que deseamos estimar)*



- Para el modelo de **Regresión Lineal Múltiple**; es necesario que las mayorías de las V.A.s tenga un comportamiento de **una distribución normal....**



Las variables categóricas tienen esas características; por ejemplo, para las edades tiene ese comportamiento donde la mayoría de los datos están en el centro:



Puede haber casos donde no tenga forma de una distribución normal como el número de conflictos que han tenido los encuestados...




Pero el detalle recaí en las V.A.s continuas y son las que debemos de comprobar dicho aspecto (las cuales son las columnas que indican el número de horas):




Podemos estar mas tranquilos por ese aspecto, pero si observamos las graficas anteriores podemos ver que hay presencia de outliers; **¿será conveniente eliminarlos?, ¿son demasiados en los datos para los modelos?**

Gráficamente, no es conveniente buscarlos por las V.A.s discretas, ya que agrupan la información por las categorías y deforman los datos (*pareciendo atípicos*). Solo las V.A.s continuas son las que nos brinda esa ayuda...



Recordemos que las gráficas Box son la perspectiva área de la función de distribución de una serie de datos. De las columnas de las horas de sueño y uso de redes en promedio podemos ver que son poco los datos que podemos considerar atípicos (*los cuales son 3 filas*) los cuales no son suficientes para descartarlos de la base de datos.

Por las graficas de dispersión, podemos ver con claridad la tendencia que tiene la información de la base de datos; pero surge algunos inconvenientes....



Hay ciertas irregulares en los datos de las cuales nos da indicios de que el resumen que genero esta base de datos está mal, podemos descartar estas filas; pero están representando mas del 60%, nos quedaría al menos 156 filas y dicha perdida de información no podemos permitirla.

Nos hemos desviado del tema principal, las preguntas anteriores pueden ser respondidas por 1 razón más...

- Al querer calificar a los jóvenes que son adictos a las redes sociales; estos datos atípicos son esenciales para poder evaluar a las personas que se cataloga como: **“casos extremos”**.

Estadística Descriptiva: Veamos cuales son las modas que tiene las V.A.s categóricas

	Gender	Academic_Level	Affects_Academic_Performance	Mental_Health_Score	Relationship_Status	Addicted_Score
0	0	3.0	1.0	6.0	2.0	7.0
1	1	NaN	NaN	NaN	NaN	NaN

Resumiendo, estos resultados nos dan han entender que la mayoría de las personas:

- Son graduadas.
- Las redes sociales han afectado su desempeño académico.
- Tiene una regular salud mental.
- Tiene una pareja sentimental.
- Son medianamente adictos a una red social.

Luego de las V.A.s continuas podemos que algunos términos más interesantes:

	Age	Avg_Daily_Usage_Hours	Sleep_Hours_Per_Night	Conflicts_Over_Social_Media
Promedio	20.662	4.921	6.867	2.852
Desviacion	1.399	1.257	1.126	0.956
Minimo	18.000	1.500	3.800	0.000
Maximo	24.000	8.500	9.600	5.000

Algunas observaciones de la imagen anterior son:


- Hay personas que han estado mas de 1 hora usando las plataformas sociales.
- Hay casos de personas que no llegan a cumplir las mínimas 5 horas de descanso.
- En promedio, cada participante tiene 3 conflictos sociales.
- La dispersión de los datos con respecto a su media no sobre pasa del 1.50.
- La edad promedio del participante es de 20 años.

Otra cosa he dejado por alto es por qué no hemos aplicado una normalización de los datos en la base; la razón está en la siguiente imagen:

	Age	Avg_Daily_Usage_Hours	Sleep_Hours_Per_Night	Conflicts_Over_Social_Media
Cuartil 25%	19.75	4.1	6.0	2.0
Mediana	21.00	4.8	6.9	3.0
Cuartil 75%	22.00	5.8	7.7	4.0

Los cuartiles de las V.A.s continuas tiene una distribución de los rangos de sus valores similares y es innecesario aplicar dicha transformación. Para las V.A.s Categóricas no recibe este tratamiento (*ya que estaríamos alterando la información que nos esta proporcionado*).

Quisiera en utilizar todas las columnas para el modelo, pero no es posible ya que el modelo de regresión lineal múltiple es un modelo que se estropea con facilidad (*Sobre ajuste, Multicolinealidad y heteroscedasticidad*) y para escoger las V.A.s mas importantes; un buen indicio será ver las relaciones que tiene entre ellas...



Utilizando las **Correlacion de Pearson**, construimos esta matriz de correlación de las que por el mapa de calor, vemos que hay algunas V.A.s se relación mejor que otras:

- “Affects_Academic_Performance”, “Avg_Daily_Usage_Hours” esta muy relacionada con “Conflicts_Over_Social_Media” y “Addicted_Score”, **positivamente**.
- Mientras que “Sleep_Hours_Per_Night”, “Mental_Health_Score” esta muy relacionada con “Conflicts_Over_Social_Media” y “Addicted_Score”, **negativamente**.
- Una observacion extras Podemos que ver es que “Sleep_Hours_Per_Night”, “Mental_Health_Score” esta muy relacionada con “Avg_Daily_Usage_Hours” y “Affects_Academic_Performance” **negativamente**.

Aunque de la relación que tiene las columnas con la calificación es muy diversa; ya que si las ordenamos tenemos lo siguiente:


	Addicted_Score
Addicted_Score	1.000000
Conflicts_Over_Social_Media	0.933225
Affects_Academic_Performance	0.865917
Avg_Daily_Usage_Hours	0.831670
Academic_Level	-0.033967
Gender	-0.052980
Relationship_Status	-0.075137
Age	-0.170790
Sleep_Hours_Per_Night	-0.764227
Mental_Health_Score	-0.944991

Todas tiene alguna relación con nuestra V.A. objetivo y hay razones para dePor último; veamos de donde viene la mayoría de los registros:

Country		Country		Country		Country		Country	
India	53	Maldives	19	Finland	8	Norway	1	Venezuela	1
USA	40	Sri Lanka	19	Austria	1	Chile	1	Ecuador	1
Canada	34	Nepal	19	Thailand	1	Argentina	1	Hungary	1
France	27	Pakistan	19	Philippines	1	Ghana	1	Czech Republic	1
Mexico	27	China	16	Taiwan	1	Kenya	1	Slovakia	1
Spain	27	Poland	16	Indonesia	1	Nigeria	1	Croatia	1
Turkey	27	Germany	14	Hong Kong	1	South Africa	1	Serbia	1
Ireland	27	Australia	14	Israel	1	Colombia	1	Slovenia	1
Denmark	27	South Korea	13	Egypt	1	Peru	1	Bulgaria	1
Switzerland	27	UAE	8	Morocco	1	Costa Rica	1	Estonia	1
UK	22	Singapore	8	Vietnam	1	Bolivia	1	Latvia	1
Japan	21	New Zealand	8	Belgium	1	Panama	1	Lithuania	1
Italy	21	Brazil	8	Greece	1	Jamaica	1	Ukraine	1
Russia	21	Malaysia	8	Portugal	1	Uruguay	1	Moldova	1
Bangladesh	20	Netherlands	8	Sweden	1	Paraguay	1	Bahamas	1

[illegible]

La verdad quisiéramos verlo por graficas de barras, solo que no se visualiza bien los nombres de cada país...



Pero podemos entender que la mayoría de los registros está en los principales centros urbanizados de todo el mundo, por lo que exigir más registros de los países con pocos accesos al wifi sería una proeza (*además de que si los descartamos sería una pérdida de información del 40%*).

Y las redes sociales que mas utilizan son las más populares que todos conocemos:

Most_Used_Platform	Instagram	TikTok	Facebook	WhatsApp	Twitter	LinkedIn	WeChat	Snapchat	Vkontakte	LINE	KakaoTalk	YouTube
count	249	154	123	54	30	21	15	13	12	12	12	10

Es curioso ver que LinkedIn que está dirigido a el desarrollo profesional de los trabajadores este inclinado en este ámbito y haya perdido su visión en el paso del tiempo y YouTube está en camino de la misma situación.

Modelo Analítico:


Para comenzar con esta parte; recapitulando todo lo que hemos analizado, revisados y transformado, para mi punto de vista lo que propuse en la presentación de la última clase de **Modelo IV** debe de ser corregido.



Pasando de un **Modelo Predictivo Cuantitativo** como lo es *la Regresion Lineal Multiple* a un **Modelo de Clasificación Cualitativo** como lo es *Random Forest*.

La razón de este cambio repentino de implementación de algún modelo es por 2 razones:

- ✓ Todas la V.A.s que tengo en la base de datos son categóricas y solo 2 son del tipo cuantitativa; lo que es poco para una modelo de regresión lineal.
- ✓ La grafica de las V.A.s objetivo que seamos predecir tiene un comportamiento siguiente:



Una pendiente predictiva está provocando muchos errores de los cuales no deseamos en nuestro modelo y por supuesto que la normalización de los datos no ayuda mucho para este aspecto.

Una vez dicho hecho; para este apartado lo veremos en 3 puntos esenciales:

❖ La partición de las filas para entrenamiento (*Train*) y prueba (*Test*):

Para esta parte; se tomó la decisión que el modelo debe de ser entrenado el 70% de la base de datos y el 30% será para las pruebas sobre las eficiencias que tiene el modelo.

```
[42] # ===== Partimos el database en train y test ===== #  
  
#importamos la sig, funcion:  
from sklearn.model_selection import train_test_split  
  
# Designamos que variable es quien:  
X = adicc_1.drop('Addicted_Score', axis = 1) # X sera las V.A.s independientes  
Y = adicc_1['Addicted_Score']               # Y sera las V.A. dependiente
```

La forma en como configuramos esta partición de la forma en la que establecemos el resto de las columnas como nuestra V.A.s descriptivas **X** y la V.A. dependiente que deseamos

estimar será catalogada como: **Y = "Addicted_Score"**, aunque luego lo podemos cambiar a otro V.A. Y (**Y = "Gerden"**)

```
# Vamos a entrenar el modelo con el 70% y con el 30% sera las parte del test
x_train, x_test, y_train, y_test = train_test_split(X, Y, train_size = .70, test_size = .30, random_state = 42)

# Vemos los tamaño que tenemos de las particiones
print(f"La particion del entrenamiento es X_train: {x_train.shape} y Y_train: {y_train.shape}")
print(f"La particion de prueba es de X_test: {x_test.shape} y Y_test: {y_test.shape}")
```

➡ La particion del entrenamiento es X_train: (492, 9) y Y_train: (492,)
La particion de prueba es de X_test: (212, 9) y Y_test: (212,)

De igual forma estamos formando 4 variables que almacena cada una de las particiones que hemos generado por el % establecido, donde podemos notar fácilmente cuales son las de entrenamiento y cuáles son las de pruebas.


Por último, podemos ver que establezco una semilla para que la **aleatoriedad** que hemos usado en las particiones sea replicable y los resultados cambien.

En general, esta partición dividió las 704 filas en 492 en información para entrenamiento y 212 filas en las pruebas de eficiencia de los modelos.

❖ Sobre los modelos y el ajuste del modelo:

Recordemos en que el modelo **Random Forest** consiste en la ejecución simultanea de varios modelos de clasificación llamados **Decision Tree**, donde cada uno de los registros pase por cada uno de ellos, y como la anatomía de un árbol; se va pasando la información y estimando por medio de términos y preguntas cuantitativas para que al final se coloque un resultado en base a dichas decisiones.

De los resultados de cada árbol se buscar al mejor resultado de todos por medio de la moda y/o media. Podemos entenderlo mejor con el diagrama siguiente:



Para responder a las 2 V.A. que deseamos clasificar e estimar; tenemos 2 caso:

✓ Addicted_Score

Una vez aplicado e ajustado el modelo con **37-Decision Tree** e **aleatoriedad** fija para replicar de nuevos los mismos resultados, podemos ver con el dialogo siguiente:


```
# ===== Ajustamos el modelo ===== #  
  
# importamos el modelo de random forest por la paqueteria sklearn  
from sklearn.ensemble import RandomForestClassifier  
  
# Ajustamos los parametros del modelo  
modelo = RandomForestClassifier(n_estimators = 37, random_state = 42)  
modelo.fit(x_train, y_train)
```

```
RandomForestClassifier  
RandomForestClassifier(n_estimators=37, random_state=42)
```


Y si vemos algunas comparativos de los valores **y_predic** calculados, se puede observar que algunas predicciones son las misma que resultados reales...

	Real	Prediccion	Buen resultado
Student_ID			
298	8	7	False
82	7	7	True
78	5	5	True
209	7	7	True
320	4	4	True
279	5	5	True
245	9	9	True
325	4	4	True
286	7	7	True
121	7	7	True

La V.A. **Addicted_Score** al tener un formato ordinal y de múltiples resultados; solo podemos ver la “Matriz de Confusión” y la “Precisión de Global” de la estimacion. Para la **Accuracy** podemos verlo con la gráfica de barras de la tabla anterior:



Calculando la proporción, tenemos que el 89.6% de las predicciones son acertadas a su valor real por lo cual es un modelo totalmente eficiente a la hora de clasificar la información que introduzcamos (*obvio que hay algunas restricciones que tenemos que hablar*). Por otra parte veamos como nos queda la Matriz de Confusión es que un mapa que nos visualiza las coincidencias y fallas que tuvo el modelo entre los valores reales y los predictivos.



Viendo la diagonal principal de la matriz y sus alrededores; es un buen indicio de que la mayoría de las predicciones son acertadas y muy pocos errores de estimación (*pero estos resultados puedan deberse a las limitaciones que se impusieron en base de datos, algo que platicaremos más tarde*).

✓ Gender

Aplicamos los mismos parámetros que el caso anterior, podemos ver si podemos estimar cual es el genero mas propensos a estas adicciones...

```
[215] # ===== Partimos el database en train y test ===== #

#importamos la sig. funcion:
from sklearn.model_selection import train_test_split

# Designamos que variable es quien:
X = adicc_1.drop('Gender', axis = 1) # X sera las V.A.s independientes
Y = adicc_1['Gender']               # Y sera las V.A. dependiente


# Vamos a entrenar el modelo con el 70% y con el 30% sera las parte del test
x_train_1, x_test_1, y_train_1, y_test_1 = train_test_split(X, Y, train_size = .70, test_size = .30, random_state = 42)
```

```
RandomForestClassifier
RandomForestClassifier(n_estimators=37, random_state=98)
```

Con nuestra V.A. **Y = "Gerden"** y con este caso podemos aspectos que el caso pasado no nos podía ayudar por la condición que tenía **Y** y lo podemos observar la parte siguiente.

❖ Aciertos Vs Errores y como cuantificarlo:


Una vez aplicado la parte de test con el modelo anterior; podemos desarrollar su Matriz de Confusión...



Es claro que; por mayoría, las estimaciones de las predicciones dan en el calvo con los valores reales y tiene pocas excepciones; pero que nos dice los términos de eficiencia:

- **Accuracy** es del 86.3% lo cual es eficiente nuestro modelo.
- **Presicion** es del 84.3%; es decir, que sabe clasificar excelente a los valores positivos.


Pasando a la curva ROC que lo interpretamos de la siguiente forma:



la línea azul son los puntos que conecta las tasa de verdadero positivos con los negativos y originalmente debe de ser una curva pronunciada y tenue que la tenemos presente (*este indicando que el modelo responde bien con los registros a clasificar y no lo hace al azar*).


Las rectas que forma la curva ROC son muy “recta”, indicando que las tasas constantes hasta cierto punto (sin importar el volumen de las filas) y si el AUC nos reafirma el hecho que nuestro modelo no lo esta haciendo aleatoriamente las decisiones, es claro que la información de la base de datos esta de nicho y manipulada...

Podemos aplicarlo con todos los datos; pero el resultado es el mismo (hasta sobre ajustada que la curva anterior) ...



❖ **Respondiendo la última pregunta:**

Si queremos ver “los grupos invisibles” que pueden generar la información; hay que realiza un **Dedrograma** que nos ayuda a determinar el numero de grupos mas adecuado para realizar un modelo de clústering; la idea es ver si es posible tratar estos datos para un modelo no supervisado (*que los modelos anteriores lo son*) ...



Por practica; si marcamos una recta horizontal en la rama principal; el número de líneas que cruce será el número de grupos que debemos utilizar para los modelos. En este caso 2 grupos son los adecuados.

Aplicando el modelo de “K-Means” con toda la base de datos con los 2 grupos y etiquetando las filas por el grupo tenemos algo curioso que notamos...

Affects_Academic_Performance	Cluster
1	1
0	0
1	1
0	0
1	1
1	1
0	0
1	1
0	0
0	0
1	1
1	1

La agrupación que hemos modelado coincide con las personas que tiene un desempeño académico malo por las redes social y no sirve este modelo para clasificar automáticamente si podemos hacerlo por esta categoría y por ende lo descartamos.

Conclusiones:

Este proyecto debe ser un ejemplo y está destinado a ser un material de apoyo para las personas que están interesadas en mejorar estos modelos de clasificación que he desarrollado.

Ya que el beneficio que puede ofrecer (hasta este punto) es el de clasificar a los estudiantes de forma cuantitativa el nivel de adicción que presenta y saber por datos el tipo de género que pertenece el participante.



Este proyecto está dirigido principalmente a **las instituciones educativas** que deben de implementar medidas más restrictivas en el uso de las redes sociales (*con solo fines educativos*) en sus locaciones; con el único fin de que sus estudiantes no sean afectados en:

- Concentración.
- Pensamiento Crítico.
- Rendimiento Académica.

Ya que estos ámbitos de ser afectados drásticamente; provocan **la deserción académica** que ha estado aumentados en estos últimos años. Por otro lado, los estudiantes maduran con las decisiones que toman y conocer estos datos como una forma de concientizar que esta adicción repercute en su vida académica.

A pesar de mis esfuerzos para que unos de los modelos que hemos desarrollado en este proyecto fuera funcional y practico, no fueron suficientes por algunas limitaciones que estuve observando y encontrado a lo largo de este desarrollo...

Generalizando los detalles que se fueron explicado en este proyecto; son que los siguientes:

- Las limitaciones que encuentro todos los modelos, es el hecho de que solo esta destinado a calificar a estudiantes que continúan con sus estudios después de la educación básica y si quisiéramos calificar a otro tipo de personas; no se llegaría a resultados lógicos e coherente con el panorama que frente la persona a evaluar.
- La limpieza que estaba preestablecida en los datos es otra limitante que tenemos ya que a pesar de decir que la base de datos es un resumen de una serie de preguntas realizadas en una encuesta; esta acción debe ser la causa principal que el modelo sea muy propenso a que se sobre ajuste y no pueda modelar otros datos.
- Los supuestos que se tomaron fueron los que se proporcionaron en la página web en donde se consiguió esta base de datos. Y la deficiencia que tiene es el que no explican como fueron los resultados de la encuesta.