

# Práctica 3.

## 1. Preprocesamiento

Supongamos que los valores de un conjunto determinado de datos se agrupan en intervalos. Los intervalos y las frecuencias correspondientes son los siguientes:

| Edad   | Frecuencia |
|--------|------------|
| 1-5    | 550        |
| 5-15   | 950        |
| 15-20  | 1950       |
| 20-50  | 750        |
| 50-80  | 600        |
| 80-110 | 180        |

Calcular un valor medio aproximado para los datos.

## 2. Estadísticas

Supongamos que los datos para el análisis incluyen el atributo de Edad. Los valores de la edad para las tuplas de datos son (en orden creciente) 12, 15, 15, 16, 19, 19, 20, 20, 20, 21, 22, 22, 25, 25, 25, 25, 30, 33, 33, 34, 35, 35, 35, 35, 36, 36, 36, 42, 44, 45, 46, 52, 71, 76, 78

- a) ¿Cuál es la media de los datos? ¿Cuál es la mediana?
- b) ¿Cuál es la moda de los datos?
- c) Utilice la normalización min-max para transformar el valor 50 de la antigüedad en el intervalo  $[0.0, 1.0]$ .
- d) Trazar un histograma de equi-distancia de longitud 8
- e) Determina visualmente si hay datos anómalos

### 3. Preprocesamiento

Supongamos que un hospital probó los datos de edad y grasa corporal para 18 adultos seleccionados al azar con el siguiente resultado

|         |     |      |     |      |      |      |      |      |      |
|---------|-----|------|-----|------|------|------|------|------|------|
| Edad    | 22  | 23   | 27  | 28   | 39   | 42   | 47   | 50   | 50   |
| % Grasa | 9.5 | 27.5 | 7.7 | 18.8 | 31.4 | 26.9 | 27.5 | 27.2 | 31.3 |

|         |      |      |      |      |      |      |      |      |      |
|---------|------|------|------|------|------|------|------|------|------|
| Edad    | 52   | 54   | 55   | 56   | 57   | 59   | 60   | 62   | 66   |
| % Grasa | 35.5 | 42.5 | 28.9 | 33.5 | 31.2 | 34.1 | 33.3 | 41.4 | 36.7 |

- Calcule la media, la mediana y la desviación estándar de la edad y % Grasa.
- Grafica el diagrama de dispersión
- Normaliza los datos de Edad y % Grasa
- Determina visualmente si hay datos atípicos
- Calcula y explica el coeficiente de correlación de Pearson

## 4. Distancias

Cálculo de distancias, atributos numéricos

Sean las tuplas:  $X1=(5,3)$  y  $X2=(6,10)$

Encuentre la distancia utilizando:

- a) Distancia máxima
- b) Distancia de Manhattan
- c) Distancia Euclidiana

Expresar gráficamente los resultados

# 5. Distancias

Cálculo de distancias, atributos categóricos

Sea la siguiente tabla de datos

| ID | Color_ojos | Sexo | Edad |
|----|------------|------|------|
| 1  | Café       | M    | 24   |
| 2  | Negro      | M    | 23   |
| 3  | Azul       | F    | 31   |
| 4  | Negro      | F    | 27   |
| 5  | Negro      | F    | 24   |
| 6  | Verde      | M    | 28   |
| 7  | Café       | M    | 25   |

- a) Agrega tus datos y realiza lo siguiente
- b) Utilizando distancia Euclidiana, encuentre la distancia entre las tuplas 1 y 5
- c) Utilizando distancia Euclidiana, encuentre la distancia entre las tuplas 4 y 8
- d) Realiza lo mismo con la distancia de Manhattan y Mahalanobis
- e) Normaliza la edad

## 6. Definición de Modelos

Con los datos anteriores

- a) Calcula/genera la matriz de correlación de datos. Concluye tus resultados.
- b) Elaborar un modelo de regresión lineal, expresión lineal. Concluye tus resultados.