

Práctica 5

Detección de anomalías

Archivo AnomalyData.csv

Attribute Information

Búsqueda de información en internet por estado con variables de búsquedas en Google y variables de Psicología.

En Rapid Miner, crear el siguiente proceso documentando los resultados

1. Agregar los datos al proceso.
 1. Formato de columnas. Cambiar la variable “state_code” a tipo Polinomial. También las variables “PsychRegion”, “region” y “division” también tienen que ser polinomial.
 2. Guardar en la carpeta de Datos del Repositorio Local.
2. Agregar el operador “Retrieve” y configurar el archivo guardado previamente.
3. Agregar el operador “Attributes” y filtrar los atributos por un “subset”. Seleccionar los atributos y agregar el “state_code”
4. Agregar el operador “Set Role” y configurar “state_code” como el nombre del atributo y target role como “ID”
5. Agregar el operador “Detect outliers (Distances)” y configurar el número de vecinos y anomalías igual a 4. Mantener la distancia euclidiana. Conectar el operador a los resultados.
6. Ejecutar el proceso “Play”. Explica 2 resultados del ExampleSet. Un outlier verdadero y uno falso, ¿por qué el modelo los clasifica así o qué los hace clasificarse así?
7. Revisa las estadísticas de los outliers. Comenta las estadísticas.
8. En las gráficas, analiza las gráficas, con la opción de “color column” se pueden identificar los outliers en rojo (u otro color). Explica ¿por qué al comparar algunas variables hay outliers en el centro?
9. Compara el análisis con otro método de outliers como “Detect Outliers (Densities)”. ¿cuál recomendarías y por qué?

Regresión

Archivo winequality-red.csv

Attribute Information: Datos sobre características para evaluar la calidad de vinos tintos.

En Rapid Miner, crear el siguiente proceso documentando los resultados

1. Agregar los datos al proceso.
 1. Formato de Datos mantener el Header y Star Row en 1.
 2. Formato de columnas. Las mediciones químicas de la calidad del vino rojo están bien. Pero se tiene que identificar la variable de salida, esta será la variable "Quality", cambiar el rol a Label.
 3. Guardar en la carpeta de Datos del Repositorio Local.
2. Agregar el operador "Retrive" y configurar el archivo guardado previamente.
3. Agregar el operador "Linear Regression", mantener los parámetros por default.
4. A través del operador "Apply Model" y conectar al model del paso previo.
5. Evaluar el modelo a través del mecanismo de "Performance (Regression)". Conectar los resultados etiquetados del modelo aplicado y configurar el criterio principal como "RMSE" -root mean square error-, y seleccionar las métricas de "Correlation", "Square Correlation".
6. Conectar las dos salidas de Performance a los resultados del proceso.
7. Ejecutar el proceso "Play". Revisa los valores originales vs valores de predicción, ¿cuál es la principal diferencia? Si hay diferencia, ¿por qué existe la misma?
8. En las estadísticas, explica la diferencia entre el histograma de la variable "Quality" y los valores de predicción. ¿Por qué existe esta diferencia? Justifica si esta diferencia afectaría o no las conclusiones del modelo.
9. A través de las gráficas, determina la relación de las variables con la variable de salida "Quality". ¿Cuáles consideras que son las 3 variables que están más relacionadas a la calidad y por qué?
10. Si la variable "Quality" está en el eje Y ¿Por qué las gráficas de dispersión (scatter) muestra los puntos como líneas horizontales? ¿Qué indica la diferencia entre la variable "Quality" con los valores de predicción? Concluye si se continua con el modelo o si se tiene que cambiar de modelo.

11. En la pestaña de resultados de Performance, ¿cómo se interpreta el valor del RMSE del modelo? ¿cómo se interpreta el valor de correlación obtenido de acuerdo con el número de variables?
12. ¿Es el valor obtenido de la correlación al cuadrado la explicación de la varianza? ¿Cómo se interpreta este resultado?
13. Agrega los pesos (weights) a los resultados del proceso y explica ¿a qué se refieren estos datos?
14. ¿Cuál sería el modelo de regresión, expresión lineal, para el modelo?