



Facultad de Estudios Superiores

Acatlán

Diplomado: Técnicas Estadísticas y

Minería de Datos.

Modulo IV: Minería de Datos.

Practica v

Profesor: Javier Rosas Hernández.

Alumno: David Mendieta Lopez.

24/06/2025


PARTE # 1: **Detección de anomalías** (*Archivo AnomalyData.csv*)

Titula de la investigación: “*Attribute Information*”

Consiste en la búsqueda de información en internet por estado con variables de búsquedas en Google y variables de Psicología.

Desde la Plataforma RapidMiner; crear el siguiente proceso documentando los resultados....

- 1) Agregar los datos al proceso.



- a) **Formato de columnas:** Cambiar la variable “state_code”, “PsychRegion”, “region” y “division” a tipo Polinomial.

state_code <i>polynominal</i>	PsychRegi... <i>polynominal</i>	region <i>polynominal</i>	division <i>polynominal</i>
AL	1	3	6
AZ	2	4	8
AR	1	3	7
CA	2	4	9
CO	1	4	8
CT	3	1	1
DE	3	3	5
FL	1	3	5
GA	1	3	5
HI	3	3	6
ID	2	4	8

b) Guardar en la carpeta de Datos del Repositorio Local.

Where to store the data?

Local Repository (Local)

Name: Anomaly_Data

Location: //Local Repository/Anomaly_Data

Previous Finish Cancel

2) Agregar el operador “Retrive” y configurar el archivo guardado previamente.

Repository

Import Data

Samples

Community Samples (connected)

Local Repository (Local)

Connections

data

processes

Anomaly_Data (6/24/25 10:07 PM - 24)

DB (Legacy)

Operators

Retrive

Data Access (2)

Retrieve

Retrieve from File

Process

Process

inp

Retrieve Anomaly_Data

out

- 3) Agregar el operador “Atributos” y filtrar los atributos por un “subset”. Seleccionar los atributos y agregar el “state_code”


The screenshot shows a workflow with two operators: 'Retrieve Anomaly_D...' and 'Select Attributes'. The 'Select Attributes' operator is highlighted with a red box. Below the workflow, the 'Select Attributes: select subset' dialog box is open. It shows a list of attributes on the left and a 'Selected Attributes' list on the right. The attribute 'state_code' is selected in the 'Selected Attributes' list. The 'Apply' button is highlighted with a red box. To the right of the dialog, the 'Parameters' panel for the 'Select Attributes' operator is visible, showing the 'type' set to 'include attributes' and the 'attribute filter type' set to 'a subset'. The 'select subset' button is also highlighted with a red box.

- 4) Agregar el operador “Set Role” y configurar “state_code” como el nombre del atributo y target role como “ID”

The screenshot shows a workflow with three operators: 'Retrieve Anomaly_D...', 'Select Attributes', and 'Set Role'. The 'Set Role' operator is highlighted with a red box. Below the workflow, the 'Edit Parameter List: set roles' dialog box is open. It shows a table with two columns: 'attribute name' and 'target role'. The 'attribute name' is 'state_code' and the 'target role' is 'id'. The 'Apply' button is highlighted with a red box.

attribute name	target role
state_code	id

- 5) Agregar el operador “Detect outliers (Distances)” y configurar el número de vecinos y anomalías igual a 4. (*Mantener la distancia euclidiana*) Conectar el operador a los resultados.



- 6) Ejecutar el proceso “Play”. Explica 2 resultados del ExampleSet. Un outlier verdadero y uno falso, ¿por qué el modelo los clasifica así o qué los hace clasificarse así?

Result History			Ex
Open in Turbo Prep Auto Model Interactive Analysis			
Row No.	state_code	outlier	
1	AL	true	
2	AZ	true	
3	AR	true	
4	CA	true	
5	CO	false	
6	CT	false	
7	DE	false	
8	FL	false	
9	GA	false	
10	HI	false	
11	ID	false	
12	IL	false	
13	IN	false	
14	IA	false	

ExampleSet (49 examples, 2 special attributes, 0 regular attributes)

Recapitulemos que hemos realizado hasta el momento; Una vez de carga los datos, escogimos solo un atributo (*state_code*) y le cambiamos el rol de sus valores al tipo de **ID**. Por solo estamos contemplando una V.A. y con el “Detect outliers (Distances)” (*como su nombre lo indica*) estaríamos buscando los datos atípicos en base a los parámetros siguientes....

Detect Outlier (Distances)

- number of neighbors: 4
- number of outliers: 4
- distance function: euclidian distance

se utiliza a los 4 puntos más cercanos en cada valor


En este modelo se busca en concluir con 4 datos atípicos

Se usa la distancia euclidiana para los puntos-vecinos si es o no un outliers (por promedio)

Por lo que en los resultados; si indica que es falso, en dato no es atípico y si es verdadero, el dato es atípico...


7) Revisa las estadísticas de los outliers. Comenta las estadísticas.


Checando las gráficas e estadísticas tenemos que:



Si lo vemos en 2 partes:

- **state_code:** la gráfica de state_code son nos dice el número de veces en la que un valor se repiten....






Index	Nominal value	Absolute count	Fraction
1	AL	1	0.020
2	AR	1	0.020
3	AZ	1	0.020
4	CA	1	0.020
5	CO	1	0.020
6	CT	1	0.020
7	DE	1	0.020
8	FL	1	0.020




El detalle recaí en que solo se reporta una repetición por cada valor distinto y si es así; todos los valores que tiene la V.A. tienen solo valores únicos.

- **Outliers:** Para este caso, los ver la proporción que tiene los datos atípicos en comparación de los demás..




- 8) En las gráficas, analiza las gráficas, con la opción de “color column” se pueden identificar los outliers en rojo (u otro color). Explica ¿por qué al comparar algunas variables hay outliers en el centro?

Observemos algunos ejemplos de graficas que indique los supuestos “outliers”....



Podemos corroborar que hay datos atípicos en medio de las gráficas (*por lo general, deberían de estar por los extremos*). Esta problemática se debe al hecho de que se aplicó **el filtro de atributos e rol** antes del **modelo de outliers**; ya que lo pasa es que dicho filtro solo establece una V.A. que solo tiene valores únicos polinomiales (que solo contemplan un valor numérico similar entre ellos) y por ende las distancias son las mismas. Causando dicho modelo no sirve y solo está escogiendo datos al azar como si fuera datos atípicos.


Y si quitamos estos segmentos, podemos resolver este problema. Y por ejemplo tenemos la siguiente grafica....



9) Compara el análisis con otro método de outliers como “Detect Outliers (Densities)”. ¿cuál recomendarías y por qué?

Checando ambos modelos para detectar datos atípicos podemos sacar algunas conclusiones:

- Ambos modelos presentan el mismo problema de que se presenta en esta sección.
- El “Detect Outliers (Densities)” consiste en calcular las distancias disponibles de un punto y se determinan si un punto es atípico o no si la distancia radio es similar a la estipulada y los puntos que cumpla esto, se les calcula la proporción correspondiente a sus registros; si está por debajo por nuestra indicación, será considerado outliers.



- La diferencia crucial entre ambos modelos es el hecho de que esta es más precisa ya que puede detectar los datos atípicos de forma grupal (*mientras la anterior sirve para los datos más alejados de los demás*).

Aunque ambas son buenas en lo que hace, yo recomiendo más “Detect Outliers (Densities)” ya que es mas eficiente en lo que hace...


PARTE # 2: Regresion (winequality-red.csv)

Titula de la investigación: “Attribute Information”


Datos sobre características para evaluar la calidad de vinos tintos.

En RapidMiner, crear el siguiente proceso documentando los resultados


- 1) Agregar los datos al proceso.




- a) **Formato de Datos:** mantener el Header y Star Row en 1.




- b) **Formato de columnas:** Las mediciones químicas de la calidad del vino rojo están bien. Pero se tiene que identificar la variable de salida, esta será la variable “Quality”, cambiar el rol a Label.



c) Guardar en la carpeta de Datos del Repositorio Local.



2) Agregar el operador “Retrive” y configurar el archivo guardado previamente.



3) Agregar el operador “Linear Regression”, mantener los parámetros por default.

Process

Process

Retrieve winequality...

Linear Regression

Parameters

Linear Regression

feature selection M5 prime

☒ eliminate colinear features

min tolerance 0.05

☒ use bias

ridge 1.0E-8

Hide advanced parameters

Help

Linear Regression

AI Studio Core

Linear Regression.training set (training set)

Meta data: Data Table

- Source: /Local Repository/winequality-red

Number of examples = 1706

12 attributes:


Generated by: Retrieve winequality-red.output [0.120 - 1.590]

Expects: Data Table


Number of examples ≥ 0

Role	Name	Type	Range	Missings
	total sulfur ...	## integer	=[6 - 289]	= 0
	density	## real	=[0.984 - 1.0]	= 0
	pH	## real	=[2.740 - 4.0]	= 0
	sulphates	## real	=[0.330 - 2.0]	= 0
	alcohol	## real	=[8.400 - 1.0]	= 0
label	quality	## integer	=[3 - 8]	= 0


4) A través del operador “Apply Model” y conectar al model del paso previo.



- 5) Evaluar el modelo a través del mecanismo de “Performance (Regression)”. Conectar los resultados etiquetados del modelo aplicado y configurar el criterio principal como “RMSE” -root mean square error-, y seleccionar las métricas de “Correlation”, “Squared Correlation”.



- 6) Conectar las dos salidas de Performance a los resultados del proceso.



- 7) Ejecutar el proceso “Play”. Revisa los valores originales vs valores de predicción, ¿cuál es la principal diferencia? Si hay diferencia, ¿por qué existe la misma?

Una vez ejecutado nuestro diagrama tenemos 2 columnas una donde se califica todos los aspectos de un vino y un valor predictivo.

Result History

ExampleSet (Apply Model) x

Open in Turbo Prep Auto Model

Row No.	quality	predictio... ↓	fixed
1675	8	7.745	12.5
1669	7	7.321	4.90
1620	4	7.252	14.3
654	5	7.125	15.9
1674	6	7.100	7.30
1640	3	7.090	7.20
469	6	6.831	8.80
494	7	6.816	8.90
1136	7	6.793	7.40
371	7	6.748	9.40
379	7	6.748	9.40
143	6	6.746	5.20
145	6	6.746	5.20
590	8	6.720	5


ExampleSet (1,706 examples, 2 special attributes, 11 regular attributes)

La diferencia radical entre ambas columnas es el tipo de dato; mientras que la “Quality” contempla valores discretos entre 1 – 8, los valores predictivos contemplan en el mismo rango, pero son de valores continuos.


Esto se debe a que un modelo de regresión lineal produce resultados numéricos continuos, ya que busca estimar con precisión una cantidad. En contraste, la variable dependiente Y, en este caso "Quality", es de tipo multiordinal (*ordinal con múltiples categorías*), lo cual implica que toma valores enteros y ordenados, pero no necesariamente equidistantes entre sí. Por ello, es poco probable que el modelo prediga exactamente un número entero, ya que interpreta la variable como numérica continua, y no como una categoría discreta.

- 8) En las estadísticas, explica la diferencia entre el histograma de la variable “Quality” y los valores de predicción. ¿Por qué existe esta diferencia? Justifica si esta diferencia afectase o no las conclusiones del modelo.

Observemos en las estadísticas que:



Podemos corroborar los comentarios de la pregunta pasada tanto en su tipo de valor y el rango de esta. Pero si observamos los histogramas que nos ofrece ambas columnas que son muy distintas:



Aparte de los comentado anteriormente; la diferencia se debe a algo conocido como el residuo (*error*) de la regresión lineal. Ya que matemáticamente se establece como:

$$e_i = y_i - \hat{y}_i$$

Y forma parte de la recta de regresión, es algo que siempre de la forma:


$$y = \beta_0 + \beta_1 x + e$$

Este residuo es algo que puede afectar al modelo en general (*por el hecho de que los residuos sean muy grandes y no de predicciones poco fiables*); pero para eso, hay ciertos criterios que debemos de probar y con ello decir que es ruido blanco.

- Los residuos deben comportarse como una normal estándar con esperanza 0 y una varianza constante.
- Prueba de Jarque-Bera
- La Curtosis e Asimetría perteneciente a una distribución normal
- El evitar la multicolinealidad de las V.A.s

9) A través de las gráficas, determina la relación de las variables con la variable de salida “Quality”. ¿Cuáles consideras que son las 3 variables que están más relacionadas a la calidad y por qué?


A pesar de que la mayoría de las graficas que se relaciona con la V.A. Y formen rectas perpendiculares de las cuales solo se distribuyen por la cantidad de ellas y no tanto por el resultado que tenga. Por ejemplo:



Por lo tanto; por medio de las gráficas me he Imposible determinar que son las 3 V.A. mas relacionada o representativas para “quality” y es necesario ver otro métodos para encontrarlas.

10) Si la variable “Quality” está en el eje Y ¿Por qué las gráficas de dispersión (scatter) muestra los puntos como líneas horizontales? ¿Qué indica la diferencia entre la variable “Quality” con los valores de predicción? Concluye si se continua con el modelo o si se tiene que cambiar de modelo.

Realizando la grafica que nos pide nos quedaría de la siguiente forma:




Lo primero que podemos observar es el hecho hay unos saltos de línea que hay una marcara diferencian entre los valores que toma “quality” que son discretos y por ende toman 8 líneas y la generación de puntos sobre dichas líneas son las que marca lo valores que está tomando “quality predictive” que toma valores de forma continua. Este suceso ocurre dado a la diferencia entre los tipos de datos.

Aunque esta grafica no nos dice mucho sobre si utilizar este modelo predictivo sobre estos datos, nos da una pista de no usarla por **la recta de regresión** que colocamos. Ya que no esta esta representando la tendencia de los datos en su totalidad; será debería de ocupar un modelo predictivo que de resultados clasificadorio (como un **modelo de regresión logística múltiple**)


- 11) En la pestaña de resultados de Performance, ¿cómo se interpreta el valor del RMSE del modelo? ¿cómo se interpreta el valor de correlación obtenido de acuerdo con el número de variables?

Veamos como se interpreta esta información de los siguientes términos:



Este se valor se le conoce como **La Raíz del Error Cuadrático Medio** que nos indica el promedio de los errores generados por el modelo predictivo. La razón de porque esta al cuadrado es el hecho de que son tan pequeños que el elevarlo lo podemos visualizar y penalizar este detalle.

Para este caso podemos ver que es casi aproximado a 0, por ende; el error es muy bajo que este afectando el modelo de regresión lineal múltiple.



Este término, también conocido como **La Correlación Cuadrada** será la correlación que tiene las V.A. Y con respecto a su V.A. Y predictiva, pero al cuadrado (*para visualizar mejor valor*).

- 12) ¿Es el valor obtenido de la correlación al cuadrado la explicación de la varianza? ¿Cómo se interpreta este resultado?


El ultimo termino visto no tiene que ver nada con la explicación de la varianza (*eso la explica perfectamente el ANOVA*). La interpretación de este valor lo podemos verlo como:

“la relación proporcional que tiene los datos entre ambas variables”.

Este caso, como es de 0.254 nos quiere decir que conforme crece un valor de Y, entonces crece a 0.254 un valor de Y Predictivo.

- 13) Agrega los pesos (*weights*) a los resultados del proceso y explica ¿a qué se refieren estos datos?

Conectando estos datos de pesos con la visualización...



Y si vemos los pesos, estarán enlistados con una V.A. que lo acompañe:

Estos pesos lo podemos interpretar como:

Los Coeficiente de la Recta de la Regresión Lineal (β_i)

14) ¿Cuál sería el modelo de regresión, expresión lineal, para el modelo?

Los coeficientes de la recta será los términos que acompañe a la variable que representa al atributo en cuestión, ya que es el peso que tiene el atributo en la recta y su representación que toma es la siguiente:

	attribute	weight	
x_1	fixed aci...	0	β_1
x_2	volatile a...	-0.851	β_2
x_3	citric acid	0.238	β_3
x_4	residual ...	0.004	β_4
x_5	chlorides	-1.163	β_5
x_6	free sulf...	-0.003	β_6
x_7	total sulf...	-0.001	β_7
x_8	density	0	β_8
x_9	pH	0	β_9
x_{10}	sulphates	0.755	β_{10}
x_{11}	alcohol	0.256	β_{11}

$$E[Y|x] = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \beta_5 x_5 + \beta_6 x_6 + \beta_7 x_7 + \beta_8 x_8 + \beta_9 x_9 + \beta_{10} x_{10} + \beta_{11} x_{11}$$

Aunque hay más análisis que determinar si estos pesos son significativos o no en el modelo de predicción; pero a simple vista podemos indicar que estos pesos no tienen mucha repercusión (y eso que falta el intercepto en la tabla de pesos)....