

Práctica 6 – Clasificación

I. Archivo ccdefault.csv

Attribute Information

This research employed a binary variable, default payment (Yes = 1, No = 0), as the response variable. This study reviewed the literature and used the following 23 variables as explanatory variables:

X1: Amount of the given credit (NT dollar): it includes both the individual consumer credit and his/her family (supplementary) credit.

X2: Gender (1 = male; 2 = female).

X3: Education (1 = graduate school; 2 = university; 3 = high school; 4 = others).

X4: Marital status (1 = married; 2 = single; 3 = others).

X5: Age (year).

X6 - X11: History of past payment. We tracked the past monthly payment records (from April to September, 2005) as follows: X6 = the repayment status in September, 2005; X7 = the repayment status in August, 2005; . . .; X11 = the repayment status in April, 2005. The measurement scale for the repayment status is: -1 = pay duly; 1 = payment delay for one month; 2 = payment delay for two months; . . .; 8 = payment delay for eight months; 9 = payment delay for nine months and above.

X12-X17: Amount of bill statement (NT dollar). X12 = amount of bill statement in September, 2005; X13 = amount of bill statement in August, 2005; . . .; X17 = amount of bill statement in April, 2005.

X18-X23: Amount of previous payment (NT dollar). X18 = amount paid in September, 2005; X19 = amount paid in August, 2005; . . .; X23 = amount paid in April, 2005.

En Rapid Miner, crear el siguiente proceso documentando los resultados

1. Agregar los datos al proceso.

1. Formato de Datos mantener el Header y Star Row en 1.

2. Formato de columnas. Para la variable "Default", que quiere decir si la persona incumplió en sus pagos o no, se debe cambiar el tipo a "binomial" y rol ajustarlo a "label" que quiere decir la variable de salida o lo que se quiere predecir.
 3. Guardar en la carpeta de Datos del Repositorio Local.
2. Agregar el operador "Retrive" y configurar el archivo guardado previamente.
 3. Agregar el operador "Set Role" y configurar "Default" como el nombre del atributo y target role como "Label"
 4. Agregar el operador "Split Data" y configurar las particiones, agregando las entradas 80% (training) y 20% (testing) equivalentes en decimal.
 5. Agregar el algoritmo "Naive Bayes" ligando al primer conjunto de datos (training). Validar que esté configurada la corrección de Laplace.
 6. A través del operador "Apply Model" y conectar al model del paso previo. También conectar el conjunto de testing a los datos no etiquetados.
 7. Evaluar el model a través del mecanismo de "Performance (Binomial)". Conectar los resultados etiquetados del model aplicado y configurar el criterio principal com "first", y las métricas de "Accuracy", "Classification Error".
 8. Conectar el modelo a los resultados. Las dos salidas de Performance y los resultados del modelo.
 9. Ejecutar el proceso "Play". Explica los resultados de la Distribución Simple.
 10. Explica 2 resultados del ExampleSet (Split Data). Predicción correcta y predicción incorrecta, ¿por qué se clasifican así o qué es lo que determina la clasificación?
 11. Observa los resultados del Vector de Performance, indica el valor de Accuracy, ¿cómo se interpreta? ¿cómo fue la predicción overall, valores verdaderos vs las predicciones? ¿qué me indica el error de clasificación?
 12. En las gráficas, de la distribución simple, explica dos gráficas de variables, además ¿cuáles serían las Top 4 variables que tienen las más grandes diferencias? ¿por qué son esas diferencias?
 13. Ejecuta el mismo proceso distribuyendo el conjunto de entrenamiento 70% y 30% para pruebas. ¿Cómo cambian los resultados?
 14. Comparar los resultados, pero ahora utilizando el algoritmo "k-Nearest Neighbors". ¿Cuál es el mejor algoritmo? ¿por qué?
 15. Comparar con otros algoritmos (2 o más) con la finalidad de mejorar los resultados. ¿Mejoraron los resultados? ¿cuál algoritmo recomendarías y por qué?

II.

Para los siguientes datos:

ID	Clase	Predicción
1	1	1
2	1	0
3	1	1
4	1	0
5	1	1
6	1	0
7	1	1
8	1	0
9	1	1
10	1	1
11	1	1
12	0	0
13	0	1
14	0	0
15	0	1
16	0	0
17	0	1
18	0	0
19	0	1
20	0	1
21	0	0
22	0	1

- a) Encontrar la matriz de confusión.
- b) Encontrar la precisión (precisión de la clase positive), sensitivity, specificity y accuracy (precisión global).
- c) Encontrar la TPR y FPR.
- d) Ubicar el clasificador en un espacio de ROC.

Concluir y justificar si es un modelo adecuado o no.

¿Qué acciones recomendarías realizar para mejorar el modelo?