



Facultad de Estudios Superiores

Acatlán

Diplomado: Técnicas Estadísticas y

Minería de Datos.

Modulo IV: Minería de Datos.

Practica VI

Profesor: Javier Rosas Hernández.

Alumno: David Mendieta Lopez.

28/06/2025

PARTE # 1: Clasificacion (Archivo ccdefault.csv)

Attribute Information: This research employed a binary variable, default payment (Yes = 1, No = 0), as the response variable. This study reviewed the literature and used the following 23 variables as explanatory variables:

X_1	Amount of the given credit (NT dollar): it includes both the individual consumer credit and his/her family (supplementary) credit.
X_2	Gender (1 = male; 2 = female)
X_3	Education (1 = graduate school; 2 = university; 3 = high school; 4 = others).
X_4	Marital status (1 = married; 2 = single; 3 = others).
X_5	Age (year).
$X_6 - X_{11}$	History of past payment. We tracked the past monthly payment records (from April to September, 2005) as follows: X_6 = the repayment status in September, 2005; X_7 = the repayment status in August, 2005; . . .; X_{11} = the repayment status in April, 2005. The measurement scale for the repayment status is: -1 = pay duly; 1 = payment delay for one month; 2 = payment delay for two months; . . .; 8 = payment delay for eight months; 9 = payment delay for nine months and above.
$X_{12} - X_{17}$	Amount of bill statement (NT dollar). X_{12} = amount of bill statement in September, 2005; X_{13} = amount of bill statement in August, 2005; . . .; X_{17} = amount of bill statement in April, 2005.
$X_{18} - X_{23}$	Amount of previous payment (NT dollar). X_{18} = amount paid in September, 2005, and X_{19} = amount paid in August, 2005; . . .; X_{23} = amount paid in April, 2005.
X_{19}	?

En RapidMiner, crear el siguiente proceso documentando los resultados...

1) Agregar los datos al proceso.

a. **Formato de Datos:** Cambiar el Header y Star Row en 2.

Import Data - Specify your data format

Specify your data format

☒ Header Row
 Start Row
 Column Separator

File Encoding
 Escape Character
 Decimal Character

☒ Use Quotes
☒ Skip Comments
☐ Trim Lines ☐ Multiline Text

		X1	X2	X3	X4	X5	X6	X7	X8	X9
1										
2	ID	LIMIT_B...	SEX	EDUCATL...	MARRIA...	AGE	PAY_0	PAY_2	PAY_3	PAY_4
3	1	20000	2	2	1	24	2	2	-1	-1
4	2	120000	2	2	2	26	-1	2	0	0
5	3	90000	2	2	2	34	0	0	0	0
6	4	50000	2	2	1	37	0	0	0	0
7	5	50000	1	2	1	57	-1	0	-1	0
8	6	50000	1	1	2	37	0	0	0	0
9	7	500000	1	1	2	29	0	0	0	0
10	8	100000	2	2	2	23	0	-1	-1	0

no problems.

- b. **Formato de columnas:** Para la variable “Default”, que quiere decir si la persona incumplió en sus pagos o no, se debe cambiar el tipo a “binomial” y rol ajustarlo a “label” que quiere decir la variable de salida o lo que se quiere predecir.

Import Data - Format your columns.


Format your columns.

Date format
☐ Replace errors with missing values ⓘ


	PAY_AMT2 <i>integer</i>	PAY_AMT3 <i>integer</i>	PAY_AMT4 <i>integer</i>	PAY_AMT5 <i>integer</i>	PAY_AMT6 <i>integer</i>	default pay... <i>binominal label</i>
1	689	0	0	0	0	1
2	1000	1000	1000	0	2000	1
3	1500	1000	1000	1000	5000	0
4	2019	1200	1100	1069	1000	0
5	36681	10000	9000	689	679	0
6	1815	657	1000	1000	800	0
7	40000	38000	20239	13750	13770	0
8	601	0	581	1687	1542	0
9	0	432	1000	1000	1000	0
10	0	0	13007	1122	0	0
11	12	50	300	3738	66	0

no problems.

c. Guardar en la carpeta de Datos del Repositorio Local.




2) Agregar el operador “Retrive” y configurar el archivo guardado previamente.




3) Agregar el operador “Set Role” y configurar “Default” como el nombre del atributo y target role como “Label”

Ignoramos esta parte ya que habíamos estipulado la V.A. Y como la default y del tipo “label” en la carga de los datos.

4) Agregar el operador “Split Data” y configurar las particiones, agregando las entradas 80% (training) y 20% (testing) equivalentes en decimal.







Y si vemos la cantidad de registros en las particiones tenemos que:

Split Data.partition 1 (partition 1)					Split Data.partition 2 (partition 2)				
Meta data: Data Table					Meta data: Data Table				
● Source: //Local Repository/ccdefault					● Source: //Local Repository/ccdefault				
Number of examples = 24002					Number of examples = 6001				
25 attributes:					25 attributes:				
Note: Some of the nominal values in this set were discarded due to performance reasons. You can change this behaviour in the preferences (rapidminer.general.md_nominal_values_limit).					Note: Some of the nominal values in this set were discarded due to performance reasons. You can change this behaviour in the preferences (rapidminer.general.md_nominal_values_limit).				
Generated by: Split Data.partition 1 - Retrieve ccdefault.output					Generated by: Split Data.partition 2 - Retrieve ccdefault.output				
Role	Name	Type	Range	Missings	Role	Name	Type	Range	Missings
	att1	nominal	unknown	= 0		att1	nominal	unknown	= 0
	X1	nominal	≤[10000, 1...	= 0		X1	nominal	≤[10000, 1...	= 0
	X2	nominal	≤[1, 2, SEX]	= 0		X2	nominal	≤[1, 2, SEX]	= 0
	X3	nominal	≤[0, 1, 2, 3,...]	= 0		X3	nominal	≤[0, 1, 2, 3,...]	= 0
	X4	nominal	≤[0, 1, 2, 3,...]	= 0		X4	nominal	≤[0, 1, 2, 3,...]	= 0
	X5	nominal	≤[21, 22, 2...	= 0		X5	nominal	≤[21, 22, 2...	= 0


- 5) Agregar el algoritmo “Naive Bayes” ligando al primer conjunto de datos (training). Validar que esté configurada la corrección de Laplace.




- 6) A través del operador “Apply Model” y conectar al model del paso previo. También conectar el conjunto de testing a los datos no etiquetados.



- 7) Evaluar el modelo a través del mecanismo de “Performance (Binomial)”. Conectar los resultados etiquetados del modelo aplicado y configurar el criterio principal como “first”, y las métricas de “Accuracy”, “Classification Error”.




- 8) Conectar el modelo a los resultados. Las dos salidas de Performance y los resultados del modelo.



- 9) Ejecutar el proceso “Play”. Explica los resultados de la Distribución Simple.

Ejecutando el modelo que hemos desarrollado hasta ahora tenemos un par de resultados:



La función: **Naive Bayes** es un modelo probabilístico que se encarga de ver (*en general*) la probabilidad de que un registro este clasificado en alguno de los grupos que presenta nuestra V.A. Y. Para este caso tenemos 2 grupos:

- Los que pagaran el siguiente mes (*la 1º clase y está indicando una probabilidad del 22.1 % de que un registro sea de alguien que pague*).
- Los que no pagaran el siguiente mes (*la 0º clase y está indicando una probabilidad del 77.9% de que un registros no pagara*).

“Las 24 distribuciones” solo son el # de V.A. que es contemplaron para el análisis de la probabilidad.

10) Explica 2 resultados del ExampleSet (*Split Data*). Predicción correcta y predicción incorrecta, ¿por qué se clasifican así o qué es lo que determina la clasificación?

Checando algunos resultados del modelo tenemos 2 ejemplos donde le atino y donde no:

Row No.	default pay...	prediction(d...	confidence(1)	confidence(0)	ID	LIMIT_BAL	SEX	EDUCATION	MAR
1	0	0	0.479	0.521	19	360000	2	1	1
2	1	0	0.166	0.834	22	120000	2	2	1
3	1	1	0.900	0.100	32	50000	1	2	2
4	0	0	0.364	0.636	33	100000	1	1	2

Esta clasificación se debe al modelo y tanto la forma en como crea el intervalo de confianza que es representada como por columnas en amarillo; si tiene o se aproxima a cero o a uno es decisivo a la hora de predecir si el registro es 1 o 0.

11) Observa los resultados del Vector de Performance, indica el valor de Accuracy, ¿cómo se interpreta? ¿cómo fue la predicción overall, valores verdaderos vs las predicciones? ¿qué me indica el error de clasificación?


Observando **La Matriz de Confusión** de la ejecución...

	true 1	true 0	class precision
pred. 1	826	1057	43.87%
pred. 0	502	3615	87.81%
class recall	62.20%	77.38%	

Hay una variedad de términos que nos ayuda a entender un poco de los datos predictivos y los datos verdaderos. Pero podemos concluir que el overall tiene buena cantidad de coincidencia entre los datos originales con los predictivos.

Para esta ocasión veremos 3 términos:

- **Accuracy:** Indica el % en el modelo da con presión el mismo resultado de su dato predictivo con el dato real. Una 74.02% es una buena precisión que el modelo puede ofrecer.
- **Classification_error:** Sera la parte complementaria del término anterior; mientras menor sea el termino, mejor y con 25.98% es algo considerable.
- **Curva ROC:** Podemos ver que tiene la clásica curva que los caracteriza como un modelo bueno a la ahora de clasificar.



12) En las gráficas de la distribución simple, explica 2 gráficas de variables, además ¿cuáles serían las Top 4 variables que tienen las más grandes diferencias? ¿por qué son esas diferencias?

Checando cada una de las graficas que nos genera la parte de la distribución simple, detecto que hay graficas que tiene una diferencia grande.

La graficas son las representaciones de **la distribución de probabilidad acumulada (Normal) de los montos aportados en el mes en cuestión:**


- (1) Azul de los registros que pagaran
- (2) Rojo de los que no lo realizaran el próximo.

Una de las razones por la cual esta la diferencia, es más el hecho cualitativo del monto que se aportaron en dicho mes.


Por lo que a pesar de que realizaron el pago (con posible más cantidad de lo normal), el modelo estaría clasificando si la persona pagara o no el próximo mes independientemente de lo anterior. Hay V.A. en donde la diferencia esta **Pro o en Contra** de realizar los pagos.

4 ejemplos que podemos notar esta diferencia serian:


- PAY_ATM6




- PAY_6



- PAY_0




- PAY_ATM_2




- 13) Ejecuta el mismo proceso distribuyendo el conjunto de entrenamiento 70% y 30% para pruebas. ¿Cómo cambian los resultados?

Aplicando La partición de los datos que indica el problema:




Revisando cada aspecto que hemos hecho en este practica; es decir, que no hay mucha diferencia con los resultados anteriores. Solo un leve aumento **Accuracy** del 75.48% y **Curva ROC** esta más definida que la anterior (porque es posible que el modelo pueda aprender mejor a clasificar los registro; pero con más posibilidades de un “sobreajuste” del modelo)



- 14) Comparar los resultados, pero ahora utilizando el algoritmo “k-Nearest Neighbors”. ¿Cuál es el mejor algoritmo? ¿por qué?

Siguiendo las indicaciones que cambiar el modelo de aprendizaje a **k-Nearest Neighbors** (utilizando los 5 puntos más cercanos y la distancia euclidiana), el diagrama nos quedaría de la siguiente forma:



Y contemplado la última partición que hemos utilizado podemos observar algunos términos...

- Los intervalos de confianza son distintos a lo que hemos realizado:

Row No.	default pay...	prediction(d...	confidence(1)	confidence(0)	ID	LIMIT_BAL	SEX	EDUCATION	MAR
12	0	0	0.413	0.587	43	10000	1	2	2
13	0	0	0.225	0.775	44	140000	2	2	1
14	0	0	0.209	0.791	45	40000	2	1	2
15	1	0	0.391	0.609	47	20000	2	1	2
16	1	1	0.593	0.407	48	150000	2	5	2
17	1	1	0.587	0.413	51	70000	1	3	2

- K-NN no ha tenido problema al detectar los 2 grupos de clasificación:

KNNClassification

Weighted 5-Nearest Neighbour model for classification.

The model contains 21002 examples with 24 dimensions of the following classes:

1
0

- Tiene casi la misma precisión que no el modelo anterior. De igual forma con la matriz de confusión:

accuracy: 75.08%

	true 1	true 0	class precision
pred. 1	366	617	37.23%
pred. 0	1626	6391	79.72%
class recall	18.37%	91.20%	

Por lo que la verdad a mi punto de vista; los 2 modelos son competentes al clasificar los registros y no están opacando al otro...

15) Comparar con otros algoritmos (2 o más) con la finalidad de mejorar los resultados. ¿Mejoraron los resultados? ¿cuál algoritmo recomendarías y por qué?

Realizando otros modelos como: “Regresión Lineal” e “Random Tree” podemos concluir que si hay una mejoría al clasificar. Este sería con **Random Tree** ya que en todo el aspecto supera con los demás modelos y con respecto a su precisión lo podemos ver con la siguiente imagen.

accuracy: 81.97%

	true 1	true 0	class precision
pred. 1	648	279	69.90%
pred. 0	1344	6729	83.35%
class recall	32.53%	96.02%	

PARTE # 2: Resultados Vs Predicciones (*Aparte Teórica*)

Para los siguientes datos:

ID	Clase	Predicción
1	1	1
2	1	0
3	1	1
4	1	0
5	1	1
6	1	0
7	1	1
8	1	0
9	1	1
10	1	1
11	1	1
12	0	0
13	0	1
14	0	0
15	0	1
16	0	0
17	0	1
18	0	0
19	0	1
20	0	1
21	0	0
22	0	1

Realizado por medio de Excel, realizamos a la selección de las 4 situación y tenemos que:

ID	Clase	Prediccion
1	1	1
2	1	0
3	1	1
4	1	0
5	1	1
6	1	0
7	1	1
8	1	0
9	1	1
10	1	1
11	1	1
12	0	0
13	0	1
14	0	0
15	0	1
16	0	0
17	0	1
18	0	0
19	0	1
20	0	1
21	0	0
22	0	1

a) Encontrar la matriz de confusión.

	True	False	
Clase 1 (positivo)	7	4	11
Clase 0 (negativo)	6	5	11
	12	10	22

b) Encontrar los siguientes términos:

I. Presicion: Sera la proporción de instancias relevantes entre las instancias recurente.

$$PT \setminus PT + PF = \frac{7}{7 + 4} = 63.63\%$$

II. Accuracy: Sera la proporción de predicciones que el modelo clasificó correctamente.

$$PT + PF \setminus TOTAL = \frac{7 + 6}{22} = 59.09\%$$

c) Encontrar la TPR (Sensitivity) y FPR (Specificity).

Para la **TPR** (*la tasa de positivos reales*) será la proporción de la cantidad total de instancias pertinentes que se recuperaron realmente.

$$PT \setminus PT + NF = \frac{7}{7 + 5} = 58.33\%$$

Para la **FPR** (*la tasa de negativos reales*) sera lo opuesto a la sensibilidad.

$$PT \setminus TN + FP = \frac{6}{6 + 4} = 60\%$$

d) Ubicar el clasificador en un espacio de ROC.

