

## ¿Qué son los componentes principales?

El análisis de componentes principales es un procedimiento matemático que transforma un conjunto de variables posiblemente correlacionadas en un conjunto menor de variables no correlacionadas.

La 1a componente principal explica la mayor variabilidad posible de los datos y cada componente subsecuente explica la mayor variabilidad posible restante no explicada por las componentes anteriores.

Los componentes principales tienen como objetivo reducir la dimensionalidad de un conjunto de datos e interpretarlos.

Se consideran una serie de variables  $x_i$  donde  $i \in (1, \dots, p)$  sobre un grupo de objetos o individuos y se trata de calcular, a partir de ellas, un nuevo conjunto de variables  $y_1, y_2, \dots, y_p$  incorrelacionadas entre sí, cuyas varianzas vayan decreciendo progresivamente.

Donde cada  $y_j$  ( $j = 1, 2, \dots, p$ ) es una combinación lineal de las  $x_i$  's originales, es decir,

$$y_j = a_{j1}x_1 + a_{j2}x_2 + \dots + a_{jp}x_p \\ = a_j' X$$

siendo  $a_j' = (a_{1j}, a_{2j}, \dots, a_{pj})$  un vector de constantes, y

$$X = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix}$$

Como lo que queremos es la variabilidad de los datos buscamos maximizar la varianza, una forma simple podría ser aumentar los coeficientes  $a_{1j}$ . Por ello, para **mantener la ortogonalidad** de la transformación se impone que el módulo del vector  $a'_j = (a_{1j}, a_{2j}, \dots, a_{pj})$  sea 1. Es decir

$$a_j^t a_j = \sum_{k=1}^p a_{kj}^2 = 1$$

Y

$$a_i^t a_j = 0$$

El primer componente se calcula eligiendo  $a_1$  de modo que  $y_1$  tenga la mayor varianza posible, sujeta a la restricción de que  $a_j^t a_j = 1$ . El segundo componente principal se calcula obteniendo  $a_2$  de modo que la variable  $y_2$  obtenida, esté incorrelada con  $y_1$ , del mismo modo se eligen  $y_3, y_4, \dots, y_p$ , incorrelaciondas entre sí, de manera que las variables aleatorias obtenidas vayan teniendo cada vez menor varianza.