




FACULTAD DE ESTUDIOS SUPERIORES ACATLÁN

TECNICAS ESTADISTICAS Y MINERIA DE DATOS
PROYECTO FINAL

Entre Colonias y Metros Cuadrados: Explorando el Mercado Inmobiliario de la CDMX



Elaborado por el equipo 4

10 de septiembre de 2025

Índice general

Objetivo	2
Introducción	3
1. Análisis descriptivo	5
1.1. Estructura de los datos	6
1.2. Características del conjunto de datos	7
1.3. Análisis descriptivo de las variables.	8
2. Técnicas estadísticas utilizadas	10
2.1. Matriz de correlación	11
2.2. Análisis de Componentes Principales (PCA)	12
2.3. Clustering con K-means	13
Conclusión	16
Anexo	17
Bibliografía	44
Colaboradores	45

Objetivo

El presente proyecto, titulado *“Entre Colonias y Metros Cuadrados: Explorando el Mercado Inmobiliario de la CDMX”*, tiene como objetivo principal analizar de forma integral el mercado de vivienda en la Ciudad de México, con especial énfasis en cómo la ubicación —a nivel de colonias— y las características físicas de los inmuebles —como el tamaño, número de habitaciones, antigüedad y tipo de propiedad— influyen en la conformación de los precios. A través de esta exploración, se busca identificar patrones espaciales y estructurales que permitan entender las dinámicas de valorización del suelo urbano y del parque habitacional, aportando una base analítica que contribuya tanto al estudio académico del fenómeno urbano como a la toma de decisiones en el ámbito inmobiliario, urbanístico y de políticas públicas.

Objetivos específicos

- Explorar y describir las características principales del mercado inmobiliario residencial de la Ciudad de México, a partir del análisis de variables como tipo de propiedad, ubicación, superficie y precio, en el contexto económico determinado por el tipo de cambio del peso mexicano frente al dólar.
- Aplicar técnicas de Análisis de Componentes Principales (PCA) con el fin de reducir la dimensionalidad del conjunto de datos, eliminando redundancias y permitiendo una interpretación más clara de las relaciones entre las variables de superficie y precio.
- Implementar algoritmos de segmentación (clustering) sobre los componentes principales o variables normalizadas, con el objetivo de identificar grupos homogéneos de propiedades según sus características físicas y de ubicación.
- Interpretar y caracterizar los clústeres resultantes, para construir una tipología de inmuebles dentro del mercado de la CDMX que permita entender las dinámicas de valorización inmobiliaria en diferentes zonas y tipos de vivienda.
- Generar visualizaciones e *insights* relevantes que comuniquen de forma clara los hallazgos, facilitando así su aplicación tanto en contextos académicos como en escenarios de toma de decisiones dentro del sector inmobiliario.

Introducción

La Ciudad de México (CDMX) representa uno de los mercados inmobiliarios más complejos y dinámicos de América Latina. Como capital del país y núcleo económico, político y cultural, su tejido urbano se caracteriza por una amplia diversidad de zonas residenciales que varían significativamente en términos de infraestructura, accesibilidad, servicios y niveles socioeconómicos. Esta heterogeneidad se refleja directamente en el valor de las propiedades, el cual está influenciado no solo por la ubicación geográfica, sino también por factores estructurales como el tipo de inmueble, la superficie construida, el terreno disponible y las condiciones del mercado en momentos específicos.

En este contexto, el análisis del mercado inmobiliario de la CDMX se convierte en una herramienta clave para comprender las dinámicas urbanas, identificar patrones de valorización del suelo y ofrecer información útil para la planificación urbana, la inversión y el diseño de políticas públicas. El presente proyecto se basa en un conjunto de datos que captura una muestra representativa de propiedades residenciales disponibles en la ciudad durante un periodo determinado, con un tipo de cambio aproximado de 18.80 pesos mexicanos por dólar estadounidense.

Los datos incluyen variables clave como el tipo de propiedad, la localidad específica dentro de la ciudad, detalles de precios y la superficie. Esta combinación permite un análisis enfocado de cómo estas características principales influyen en el valor de las propiedades en una metrópolis latinoamericana importante bajo condiciones económicas específicas.

Problemática

La Ciudad de México, como una de las metrópolis más grandes y pobladas de América Latina, enfrenta profundas desigualdades en el acceso a la vivienda. A lo largo de su territorio coexisten zonas de alta plusvalía con otras marcadas por la precariedad urbana, lo que genera un mercado inmobiliario fragmentado y de difícil interpretación. En este contexto, el precio de una propiedad no solo depende de su tamaño o tipo, sino de múltiples factores que interactúan entre sí, siendo la ubicación uno de los más determinantes.

Sin embargo, la toma de decisiones dentro del sector inmobiliario —tanto para compradores individuales como para desarrolladores, inversionistas y autoridades públicas— se ve limitada por la falta de análisis sistemáticos y actualizados que integren las diversas dimensiones que influyen en el valor de las propiedades. La abundancia de datos disponibles en plataformas digitales no siempre se traduce en conocimiento claro y útil para evaluar de manera objetiva el comportamiento del mercado.

A esta complejidad se suma la necesidad de herramientas que permitan identificar patrones ocultos en los datos y segmentar el mercado de forma eficiente, considerando tanto las características físicas de los inmuebles como su localización geográfica. En ausencia de este tipo de análisis, el mercado opera bajo condiciones de asimetría de información, dificultando una planificación urbana equitativa y un acceso justo a la vivienda.

Por tanto, surge la necesidad de desarrollar un estudio que, mediante métodos estadísticos y técnicas de ciencia de datos, permite explorar cómo variables como el tipo de propiedad, superficie y ubicación inciden en el precio de los inmuebles, y cómo estas relaciones pueden simplificarse y agruparse para generar una visión estructurada del mercado residencial de la Ciudad de México.

Capítulo 1

Análisis descriptivo

Este conjunto de datos proporciona una vista de los precios de la vivienda en la Ciudad de México (CDMX), recopilada durante un período en el que el peso mexicano se cotizaba aproximadamente a 18.80 frente al dólar estadounidense. Ofrece una visión clara del mercado inmobiliario residencial en la CDMX, un centro urbano dinámico e influyente.

Los datos incluyen variables clave como el tipo de propiedad, la ubicación específica dentro de la ciudad, detalles de precios y superficie. Esta combinación permite un análisis preciso de cómo estas características fundamentales influyen en el valor de las propiedades en una importante metrópolis latinoamericana bajo condiciones económicas específicas.

1.1. Estructura de los datos

El conjunto de datos consta de 18,234 registros y 11 atributos principales. A continuación se describen las variables disponibles:

- **property_type**: Tipo de propiedad (por ejemplo: casa, departamento, terreno, etc.).
Permite diferenciar entre los distintos usos residenciales del inmueble.
- **places**: Localidad o zona específica dentro de la CDMX (como colonia o delegación).
Importante para analizar variaciones geográficas en precios y superficie.
- **lat-lon**: Coordenadas geográficas (latitud y longitud) del inmueble.
Útil para análisis espacial o visualización geográfica.
- **price**: Precio total publicado del inmueble (en la moneda original).
Es la variable objetivo principal para análisis de valor.
- **currency**: Moneda en la que está expresado el precio (por ejemplo, MXN o USD).
Ayuda a interpretar correctamente el valor antes de convertirlo.
- **price_aprox_local_currency**: Precio aproximado convertido a moneda local (MXN).
Estándar común para comparar precios sin importar la moneda original.
- **price_aprox_usd**: Precio aproximado en dólares estadounidenses (USD).
Útil para análisis desde una perspectiva internacional o estandarizada.
- **surface_total_in_m2**: Superficie total del terreno del inmueble en metros cuadrados.
Refleja el tamaño completo, incluyendo áreas no construidas.
- **surface_covered_in_m2**: Superficie construida del inmueble en metros cuadrados.
Importante para estimar el valor real habitable o útil.
- **price_usd_per_m2**: Precio por metro cuadrado en USD.
Permite comparar inmuebles independientemente de su tamaño total.
- **price_per_m2**: Precio por metro cuadrado en la moneda local (MXN).
Métrica clave para evaluar valor relativo por superficie en el mercado local.

1.2. Características del conjunto de datos

- Número total de registros: 18,234
- Número total de atributos/variables: 11
- Registros faltantes: 0
- Distribución de variables objetivo: price, price_per_m2




Figura 1.1: Distribución de la variable `price_mxn`.




Figura 1.2: Distribución de la variable `price_per_m2_mxn`.

1.3. Análisis descriptivo de las variables.

Estadísticos descriptivos de variables numéricas:			
	count	mean	std \
price	18234.0	3.603177e+06	5.481585e+06
price_aprox_local_currency	18234.0	5.085788e+06	9.618485e+06
price_aprox_usd	18234.0	2.703984e+05	5.113903e+05
surface_total_in_m2	18234.0	4.062464e+03	4.872699e+05
surface_covered_in_m2	18234.0	4.039938e+03	4.872686e+05
price_usd_per_m2	18234.0	1.503674e+03	2.123173e+03
price_per_m2	18234.0	2.480409e+04	4.047341e+04

	min	25%	50% \
price	7000.000000	1.055008e+06	2.000000e+06
price_aprox_local_currency	109030.610000	1.111025e+06	2.269284e+06
price_aprox_usd	5796.880000	5.907037e+04	1.206520e+05
surface_total_in_m2	1.000000	6.700000e+01	9.500000e+01
surface_covered_in_m2	1.000000	6.700000e+01	9.500000e+01
price_usd_per_m2	0.000600	6.773976e+02	1.108178e+03
price_per_m2	0.011377	1.157143e+04	1.882843e+04

	75%	max
price	4.000000e+06	2.337267e+08
price_aprox_local_currency	4.711236e+06	3.364841e+08
price_aprox_usd	2.504844e+05	1.789000e+07
surface_total_in_m2	1.950000e+02	6.574800e+07
surface_covered_in_m2	2.000000e+02	6.574800e+07
price_usd_per_m2	1.897980e+03	1.759177e+05
price_per_m2	3.273260e+04	3.338953e+06

Figura 1.3: Estadísticos descriptivos de las variables numéricas.

1. **Variables Económicas:** Las variables relacionadas con precios: price, price_aprox_local_currency y price_aprox_usd reflejan una amplia dispersión en el mercado:
 - El precio promedio de las propiedades se sitúa alrededor de 3.6 millones de pesos mexicanos, con una desviación estándar cercana a los 5.5 millones, lo que evidencia una considerable variabilidad en los valores observados.
 - En términos de dólares, el precio promedio es de aproximadamente 270,000 USD, con una desviación estándar de más de 500,000 USD, reafirmando la heterogeneidad del mercado.
 - Los precios mínimos y máximos, que oscilan entre los 7,000 pesos y más de 233 millones de pesos, sugieren la inclusión de propiedades de muy distintas características, desde unidades accesibles hasta desarrollos de alta gama o propiedades comerciales.
2. **Superficie de las Propiedades:** Las variables surface_total_in_m2 y surface_covered_in_m2 representan, respectivamente, la superficie total y la superficie construida de las propiedades:
 - La superficie total promedio es de aproximadamente 406 m^2 , mientras que la superficie cubierta promedio es de 94 m^2 . Esta diferencia sugiere que una parte importante del área corresponde a espacios no construidos, como patios, jardines o áreas comunes.
 - Ambas variables presentan valores extremos amplios (hasta más de 57,000 m^2), lo que puede reflejar la presencia de terrenos, desarrollos verticales u otras tipologías fuera del segmento residencial típico.

3. **Precios por Metro Cuadrado:** Las variables price_per_m^2 (en pesos) y price_usd_per_m^2 (en dólares) proporcionan una medida relativa del valor de las propiedades:

- El precio promedio por metro cuadrado es de aproximadamente 24,800 pesos o 1,500 dólares, valores coherentes con los rangos observados en zonas urbanas consolidadas de la Ciudad de México.
- No obstante, las desviaciones estándar son elevadas, lo que indica diferencias sustanciales entre distintas zonas geográficas o tipos de propiedades.

El análisis estadístico descriptivo evidencia la complejidad y diversidad del mercado inmobiliario residencial en la Ciudad de México. Las amplias variaciones en precios y superficies reflejan un ecosistema inmobiliario compuesto por múltiples segmentos, desde vivienda social hasta propiedades de lujo

Capítulo 2

Técnicas estadísticas utilizadas

El presente proyecto se apoyó en dos técnicas estadísticas principales para analizar el mercado inmobiliario de la Ciudad de México: el Análisis de Componentes Principales (PCA) y los métodos de agrupamiento basados en el algoritmo *K-means*. A continuación se describe el fundamento teórico de cada técnica, así como su pertinencia dentro del estudio.

2.1. Matriz de correlación

Con el fin de identificar relaciones lineales entre las variables numéricas, se utilizó la correlación de Pearson. Este coeficiente mide el grado de asociación lineal entre dos variables x y y , y se define como:

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

donde r_{xy} toma valores en el intervalo $[-1, 1]$. Valores cercanos a 1 indican una relación lineal positiva fuerte, valores cercanos a -1 una relación lineal negativa fuerte, y valores próximos a 0 sugieren ausencia de relación lineal.

En este proyecto se calculó la matriz de correlación para las variables numéricas del conjunto de datos inmobiliarios. La Figura 2.1 muestra el mapa de calor de dichas correlaciones, donde se observan asociaciones significativas entre las variables relacionadas con los precios ($price$, $price_aprox_local_currency$, $price_aprox_usd$) y entre las superficies ($surface_total_in_m2$, $surface_covered_in_m2$).




Figura 2.1: Matriz de correlación de variables numéricas.

2.2. Análisis de Componentes Principales (PCA)

El Análisis de Componentes Principales (PCA) es una técnica estadística que transforma un conjunto de variables posiblemente correlacionadas en un conjunto de componentes principales no correlacionados. El objetivo es reducir la dimensionalidad de los datos manteniendo la mayor parte de la información original.

Dado un conjunto de observaciones $X \in \mathbb{R}^{n \times p}$, se define la matriz de covarianzas:

$$S = \frac{1}{n-1}(X - \bar{X})(X - \bar{X})^T$$

A partir de S se resuelve el problema de autovalores y autovectores:

$$Sv_i = \lambda_i v_i$$

donde λ_i son los autovalores que representan la varianza explicada por cada componente, y v_i son los autovectores asociados.

El Análisis de Componentes Principales (PCA) transforma un conjunto de variables posiblemente correlacionadas en un nuevo conjunto de variables no correlacionadas:

$$Z_1, Z_2, \dots, Z_p,$$

ordenadas de modo que

$$\text{Var}(Z_1) \geq \text{Var}(Z_2) \geq \dots \geq \text{Var}(Z_p).$$

Cada componente es una combinación lineal de las variables originales:

$$Z_j = v_{j1}X_1 + v_{j2}X_2 + \dots + v_{jp}X_p = v_j'X,$$

con $v_j'v_j = 1$ y $v_j'v_k = 0$ si $j \neq k$.

Cálculo de los Componentes

El primer componente se obtiene resolviendo:

$$\max_{a_1} a_1' S a_1 \quad \text{s.a.} \quad a_1' a_1 = 1.$$

Usando multiplicadores de Lagrange:

$$\mathcal{L}(v_1, \lambda) = v_1' S v_1 - \lambda(v_1' v_1 - 1).$$

Derivando:

$$\frac{\partial \mathcal{L}}{\partial v_1} = 2Sv_1 - 2\lambda v_1 = 0,$$

lo que lleva a

$$Sv_1 = \lambda v_1.$$

Por lo tanto, v_1 es un vector propio y λ su valor propio asociado. El primer componente corresponde al mayor valor propio.

El segundo componente se calcula maximizando $v_2' S v_2$ con restricciones:

$$v_2' v_2 = 1, \quad v_2' v_1 = 0.$$

Esto da lugar al segundo mayor valor propio y su vector propio asociado, y así sucesivamente.

Propiedades de los Componentes

1. Conservan la variabilidad inicial:

$$\sum_{j=1}^p \text{Var}(Z_j) = \sum_{j=1}^p \lambda_j = \text{tr}(\Sigma).$$

2. Proporción de variabilidad explicada: Cada componente j explica

$$\frac{\lambda_j}{\sum_{k=1}^p \lambda_k}.$$

3. Predicción lineal óptima: Tomar los primeros $m < p$ componentes da la mejor aproximación lineal (en mínimos cuadrados) con m variables.

La proporción de varianza explicada por los k primeros componentes se calcula como:

$$\text{Varianza explicada acumulada} = \frac{\sum_{i=1}^k \lambda_i}{\sum_{j=1}^p \lambda_j}$$

En la Figura 2.2 se presenta la *gráfica de codo*, la cual muestra la varianza explicada acumulada en función del número de componentes principales. Se observa que con los tres primeros componentes se logra explicar más del 85 % de la varianza total, lo cual justifica su selección para el análisis posterior.

2.3. Clustering con K-means

Una vez transformados los datos con PCA, se aplicó el algoritmo de *K-means*, el cual segmenta las observaciones en k grupos homogéneos de acuerdo con sus características. La función objetivo que se minimiza es:

$$J = \sum_{i=1}^k \sum_{x_j \in C_i} \|x_j - \mu_i\|^2$$

donde x_j es un punto de datos, C_i el clúster i , y μ_i el centroide del clúster correspondiente. El algoritmo sigue dos pasos iterativos:




Figura 2.2: Gráfica de codo del PCA: varianza explicada acumulada por número de componentes.

1. **Asignación:** cada observación se asigna al centroide más cercano.
2. **Actualización:** los centroides se recalculan como la media de los puntos asignados a cada clúster.

Este proceso se repite hasta alcanzar la convergencia. Para determinar el número óptimo de clústeres se utilizaron dos criterios:

- **Método del codo:** basado en la inercia total, definida como la suma de las distancias cuadráticas entre cada observación y el centroide de su clúster.

En la Figura 2.3 se observa un “codo” alrededor de $k = 3-4$; en este estudio se tomó $k = 3$ por ofrecer una partición parsimoniosa y coherente con la interpretación sustantiva de los grupos.

- **Coeficiente de silhouette:** métrica que evalúa la coherencia de la asignación de cada observación.

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

donde $a(i)$ es la distancia media entre el punto i y los demás puntos de su mismo clúster, y $b(i)$ es la mínima distancia media entre i y los puntos de otro clúster.




Figura 2.3: Método del codo para K-means (inercia vs. número de clústeres).




Figura 2.4: Evaluación del número de clústeres mediante el coeficiente silhouette.

En la Figura 2.4 se observa que los valores más altos del coeficiente se alcanzan en $k = 2$ y $k = 3$. Al combinar este resultado con el método del codo, se seleccionó $k = 3$ como el número de clústeres más adecuado, ya que ofrece un balance entre simplicidad y calidad en la segmentación de los datos.

La combinación de ambos métodos indicó que el número adecuado de clústeres para este conjunto de datos era $k = 3$. Esta segmentación permitió identificar tipologías de inmuebles en la CDMX con patrones diferenciados en superficie y precio, contribuyendo al objetivo general del proyecto.

Conclusión

El análisis realizado permitió comprender de manera más clara las dinámicas que rigen el mercado inmobiliario de la Ciudad de México. A partir del estudio descriptivo se evidenció la enorme heterogeneidad en los precios de las propiedades, con valores que van desde montos accesibles hasta cifras que corresponden a desarrollos de alta gama. Esta dispersión se explica no solo por las características físicas de los inmuebles, como la superficie total y construida, sino principalmente por la ubicación, que se confirmó como uno de los factores más determinantes en la valorización.

La aplicación del Análisis de Componentes Principales (PCA) permitió reducir la complejidad de las variables sin perder información sustantiva, mostrando que tres componentes principales explican más del 85 % de la varianza del conjunto de datos. Esto facilitó la interpretación de las relaciones entre superficie, precio y ubicación, eliminando redundancias y resaltando las variables de mayor impacto en la dinámica inmobiliaria.

Posteriormente, el uso de técnicas de *clustering* con el algoritmo K-means permitió segmentar el mercado en tres grupos principales de propiedades. Cada clúster reflejó patrones diferenciados en términos de tamaño y valor, lo cual ofrece una tipología de viviendas que puede servir como insumo tanto para inversionistas como para la planeación urbana y la formulación de políticas públicas orientadas al acceso equitativo a la vivienda.

En conjunto, este proyecto demuestra el potencial de combinar técnicas estadísticas y de minería de datos para transformar información cruda en conocimiento útil y aplicable. Los resultados no solo enriquecen la comprensión académica del fenómeno urbano en la CDMX, sino que también ofrecen una base práctica para la toma de decisiones en un mercado tan complejo y competitivo como el inmobiliario.

Anexo

El fragmento de código mostrado en la Figura 2.5 corresponde a la configuración base del entorno de análisis. En él se importan librerías para manejo de datos (`pandas`, `numpy`), visualización (`matplotlib`, `seaborn`) y modelado estadístico (`StandardScaler` y `PCA` de `scikit-learn`). Además, se define un estilo visual uniforme para las gráficas y se carga el archivo `housing_data_CDMX.csv` en un `DataFrame`, que constituye la base del análisis posterior.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

# Configuración estética
sns.set(style="whitegrid", palette="muted")
plt.rcParams["figure.figsize"] = (8,5)

df = pd.read_csv("housing_data_CDMX.csv")
```

Figura 2.5: Configuración inicial en Python: importación de librerías, definición de estilo para las gráficas y carga del dataset `housing_data_CDMX.csv`.

La Figura 2.6 presenta la exploración inicial del conjunto de datos. Se identificaron un total de 18,234 registros y 11 variables, sin presencia de valores faltantes. La visualización de las primeras filas permitió verificar la correcta carga del archivo, mientras que el resumen de columnas (`info()`) confirmó los tipos de dato y la integridad del dataset. Este paso es esencial para garantizar que los análisis estadísticos y de minería de datos posteriores se realicen sobre una base confiable.

```

# =====
# 3. Vista general del dataset
# =====
print("Dimensiones del dataset:", df.shape)
print("\nPrimeras filas:")
print(df.head())

print("\nInformación de columnas:")
print(df.info())

print("\nValores faltantes por columna:")
print(df.isnull().sum())

```

Dimensiones del dataset: (18234, 11)

Primeras filas:

	property_type	places	lat-lon	price	currency
0	apartment	MiguelHidalgo	23.634501,-102.552788	5500000.0	MXN
1	house	Iztapalapa	19.31033,-99.068557	1512000.0	MXN
2	apartment	Tlalpan	19.279771,-99.234597	926667.0	MXN
3	apartment	MiguelHidalgo	23.634501,-102.552788	6410000.0	MXN
4	apartment	MiguelHidalgo	19.432657,-99.177444	4416000.0	MXN

	price_aprox_local_currency	price_aprox_usd	surface_total_in_m2
0	5450245.50	289775.66	54.0
1	1498321.97	79661.96	80.0
2	918284.00	48822.82	100.0
3	6352013.39	337720.36	135.0
4	4376051.62	232663.51	87.0

	surface_covered_in_m2	price_usd_per_m2	price_per_m2
0	54.0	5366.215926	101851.85190
1	80.0	995.774500	18900.00000
2	100.0	488.228200	9266.67000
3	135.0	2501.632296	47481.48148
4	87.0	2674.293218	50758.62069

Información de columnas:

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 18234 entries, 0 to 18233
Data columns (total 11 columns):
#   Column                                Non-Null Count  Dtype
---  ---                                -
0   property_type                        18234 non-null  object
1   places                              18234 non-null  object
2   lat-lon                             18234 non-null  object
3   price                               18234 non-null  float64
4   currency                            18234 non-null  object
5   price_aprox_local_currency          18234 non-null  float64
6   price_aprox_usd                     18234 non-null  float64
7   surface_total_in_m2                 18234 non-null  float64
8   surface_covered_in_m2               18234 non-null  float64
9   price_usd_per_m2                    18234 non-null  float64
10  price_per_m2                        18234 non-null  float64
dtypes: float64(7), object(4)
memory usage: 1.5+ MB
None

```

Valores faltantes por columna:

```

property_type      0
places             0
lat-lon            0
price              0
currency           0
price_aprox_local_currency  0
price_aprox_usd    0
surface_total_in_m2  0
surface_covered_in_m2  0
price_usd_per_m2   0
price_per_m2       0
dtype: int64

```

Figura 2.6: Vista general del dataset en Python: dimensiones, primeras filas, tipos de datos y verificación de valores faltantes.

La Figura 2.7 presenta los principales estadísticos descriptivos de las variables numéricas del conjunto de datos. Los resultados muestran una marcada heterogeneidad en precios, con valores que van desde los 7,000 hasta más de 233 millones de pesos. En cuanto a las superficies, el promedio total es de 406 m², mientras que el área cubierta es de aproximadamente 94 m², indicando la presencia de terrenos con extensiones amplias. Estas características confirman la complejidad del mercado inmobiliario en la Ciudad de México y justifican la necesidad de aplicar técnicas de reducción de dimensionalidad y segmentación para su análisis.




Figura 2.7: Estadísticos descriptivos de las variables numéricas del dataset. Se muestran medidas de tendencia central, dispersión y percentiles clave.

La Figura 2.8 muestra el procedimiento empleado para identificar las 10 colonias con mayor precio promedio por metro cuadrado en la CDMX. Primero, se agrupan los registros por lugar y se calcula la media de la variable `price_per_m2`. Luego, se ordenan los resultados en orden descendente y se seleccionan las 10 zonas más caras. Finalmente, los datos se representan en una gráfica de barras que facilita la comparación visual de los precios relativos entre las distintas colonias.

```

# Top lugares más caros por m²
top_places = (
    df.groupby("places")["price_per_m2"]
    .mean()
    .sort_values(ascending=False)
    .head(10)
)

print("\nTop 10 lugares más caros (precio promedio por m²):")
print(top_places)

# --- Gráfica ---
plt.figure(figsize=(10,6))
top_places.plot(kind="bar", color="crimson", edgecolor="black")

plt.title("Top 10 lugares con mayor precio promedio por m²", fontsize=14)
plt.ylabel("Precio promedio por m² (MXN)")
plt.xlabel("Lugar")
plt.xticks(rotation=45, ha="right")
plt.grid(axis="y", linestyle="--", alpha=0.7)
plt.tight_layout()
plt.show()

```

Figura 2.8: Código en Python para calcular y graficar el Top 10 de lugares con mayor precio promedio por metro cuadrado en la Ciudad de México.

La Figura 2.9 presenta el resultado del análisis de precios promedio por metro cuadrado. Se evidencia que la ubicación constituye un factor determinante en el valor de la vivienda, ya que las colonias con mayor conectividad y servicios urbanos concentran los precios más elevados, mientras que otras zonas, aunque aparecen en el ranking, mantienen costos relativamente menores. Este hallazgo refuerza la importancia de considerar la dimensión espacial en la valoración inmobiliaria.




Figura 2.9: Top 10 lugares con mayor precio promedio por metro cuadrado en la Ciudad de México.

Se observan diferencias marcadas entre zonas de alta plusvalía como Benito Juárez, Cuajimalpa y Miguel Hidalgo frente a otras alcaldías que, aunque forman parte del ranking, presentan valores más bajos.

La Figura 2.10 muestra una asociación positiva entre superficie y precio, con evidencias de rendimientos decrecientes (pendiente más plana en escala logarítmica). Los departamentos se concentran en superficies menores y precios relativamente acotados, mientras que las casas exhiben mayor variabilidad tanto en tamaño como en valor, lo que refleja la heterogeneidad del mercado.



Figura 2.10: Relación entre superficie total (m^2) y precio (MXN, eje logarítmico). Se recortan outliers al percentil 99 para ambas variables y se colorea por tipo de propiedad.

La Figura 2.11 muestra el proceso de normalización aplicado a las variables numéricas del dataset. Este procedimiento asegura que todas las variables tengan la misma escala, lo cual es indispensable para análisis multivariados como el PCA y los algoritmos de agrupamiento. Tras la transformación, los precios y precios por metro cuadrado presentan distribuciones centradas en torno a cero, facilitando la comparación y reduciendo sesgos en los resultados.




Figura 2.11: Normalización de variables numéricas mediante `StandardScaler`. Se observan las distribuciones de precios y precios por m^2 después de la estandarización (media = 0, desviación estándar = 1).

La Figura 2.12 compara la distribución de precios entre diferentes tipos de propiedad. Los resultados muestran que las casas y departamentos presentan una amplia dispersión, con múltiples valores atípicos. Los PH, por su parte, concentran los precios más altos por metro cuadrado, mientras que los locales o tiendas muestran variabilidad intermedia. Este análisis revela que el tipo de inmueble constituye un factor clave en la explicación de los valores observados en el mercado inmobiliario.




Figura 2.12: Comparación de precios por tipo de propiedad. Los diagramas de caja muestran tanto el precio absoluto como el precio por metro cuadrado en escala logarítmica.

La Figura 2.13 presenta la matriz de correlación de las variables numéricas. Los resultados muestran redundancias claras: los precios expresados en diferentes monedas presentan correlaciones cercanas a 1, y la superficie total y cubierta están fuertemente asociadas. El precio por metro cuadrado introduce información adicional, aunque mantiene correlación moderada con los precios absolutos. Este análisis confirma la pertinencia de utilizar PCA para sintetizar la información en un número reducido de componentes principales.




Figura 2.13: Matriz de correlación de variables numéricas mediante el coeficiente de Pearson. Se observa alta correlación entre las variables de precio (en distintas monedas) y entre las variables de superficie, lo que justifica la aplicación de técnicas de reducción de dimensionalidad como PCA.

La Figura 2.14 resume la correlación entre las variables numéricas del dataset. Los resultados evidencian redundancias entre precios y superficies, mientras que los precios por metro cuadrado aportan información adicional para la caracterización de los inmuebles. Este hallazgo fundamenta la necesidad de aplicar el Análisis de Componentes Principales (PCA) como técnica de reducción de dimensionalidad.




Figura 2.14: Mapa de calor de la matriz de correlación de variables numéricas.

Se observan correlaciones perfectas entre precios expresados en distintas monedas y entre medidas de superficie, así como correlaciones moderadas entre precios absolutos y relativos (por metro cuadrado).

La Figura 2.15 muestra los resultados del Análisis de Componentes Principales (PCA). La gráfica de varianza explicada evidencia que los tres primeros componentes concentran más del 85 % de la variabilidad de los datos, lo que permite reducir la dimensionalidad sin pérdida significativa de información. Los **loadings** confirman la influencia de las variables relacionadas con precios y superficies en los primeros componentes, lo que facilita la interpretación y sirve como base para la segmentación posterior.

```

from sklearn.decomposition import PCA

# PCA
pca = PCA()
X_pca = pca.fit_transform(X_scaled)

# Varianza explicada
explained_var = pca.explained_variance_ratio_

print("Varianza explicada por cada componente:")
for i, var in enumerate(explained_var, 1):
    print(f"CP{i}: {var:.4f} ({var*100:.2f}%)")

print("\nVarianza acumulada:", explained_var.cumsum())

# --- Gráfica de varianza individual + acumulada ---
plt.figure(figsize=(8,5))
plt.bar(range(1, len(explained_var)+1), explained_var, alpha=0.7, label="Varianza individual")
plt.plot(range(1, len(explained_var)+1), explained_var.cumsum(), marker="o", color="red", label="Varianza acumulada")
plt.xlabel("Número de componentes")
plt.ylabel("Varianza explicada")
plt.title("Varianza explicada por los componentes principales")
plt.legend()
plt.grid(True, linestyle="---", alpha=0.6)
plt.show()

# --- Loadings ---
num_vars = X.columns # guarda los nombres de las variables originales
loadings = pd.DataFrame(
    pca.components_.T,
    index=num_vars,
    columns=[f"CP{i+1}" for i in range(len(num_vars))]
)

print("\nMatriz de loadings (primeros 5 componentes):")
print(loadings.iloc[:, :5])

# --- Heatmap de loadings ---
plt.figure(figsize=(8,5))
sns.heatmap(loadings.iloc[:, :5], annot=True, cmap="coolwarm", center=0, fmt=".2f")
plt.title("Loadings de las variables en los 5 primeros componentes")
plt.show()

```

Figura 2.15: Varianza explicada por los componentes principales y carga de variables (loadings). Se observa que los tres primeros componentes acumulan más del 85 % de la varianza total, justificando su selección para el análisis.




Figura 2.16: Varianza explicada por los componentes principales del PCA. Los tres primeros componentes acumulan más del 85 % de la varianza total, lo que justifica su selección para los análisis posteriores.

La Figura 2.16 muestra la varianza individual y acumulada explicada por cada componente principal. Los resultados indican que con los tres primeros componentes se alcanza un 87.2 % de la varianza total, suficiente para representar la información del dataset con una dimensionalidad reducida. Esto valida el uso de tres componentes como insumo para las técnicas de segmentación aplicadas en el estudio.




Figura 2.17: Heatmap de los loadings de las variables en los cinco primeros componentes principales. Se observa que el CP1 está dominado por las variables de precio, el CP2 por las superficies, y los CP3 y CP5 por los precios relativos por metro cuadrado.

La Figura 2.17 presenta los pesos de cada variable original en los componentes principales. El CP1 refleja la dimensión económica (precios), el CP2 la dimensión física (superficie), mientras que los CP3 y CP5 capturan variaciones en los precios relativos por metro cuadrado. Esta interpretación confirma que el PCA no solo reduce la dimensionalidad del dataset, sino que genera factores con significado práctico para el análisis del mercado inmobiliario.

```

from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score

# --- Usar las primeras 4 componentes principales ---
X_cluster = X_pca[:, :4]

# Método del codo y silhouette
inertia = []
silhouette = []
K = range(2, 8)

for k in K:
    kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
    kmeans.fit(X_cluster)
    inertia.append(kmeans.inertia_)
    silhouette.append(silhouette_score(X_cluster, kmeans.labels_))

# Gráfica del codo
plt.figure(figsize=(6,4))
plt.plot(K, inertia, marker="o")
plt.xlabel("Número de clusters (k)")
plt.ylabel("Inercia (Suma de distancias)")
plt.title("Método del codo - KMeans (4 CPs)")
plt.show()

# Gráfica de Silhouette
plt.figure(figsize=(6,4))
plt.plot(K, silhouette, marker="o", color="orange")
plt.xlabel("Número de clusters (k)")
plt.ylabel("Silhouette Score")
plt.title("Evaluación con Silhouette (4 CPs)")
plt.show()

# --- Entrenar modelo final con k=3 (ejemplo, depende de lo que muestren las gráficas) ---
kmeans = KMeans(n_clusters=3, random_state=42, n_init=10)
df["cluster"] = kmeans.fit_predict(X_cluster)

print("\nCantidad de propiedades por cluster:")
print(df["cluster"].value_counts())

# --- Resumen comparativo de clusters ---
cluster_summary = df.groupby("cluster")[[
    "price", "surface_total_in_m2", "surface_covered_in_m2", "price_per_m2", "price_usd_per_m2"
]].agg(["mean", "std"])

print("\nResumen comparativo de clusters (medias y desviaciones):")
print(cluster_summary)

# --- Visualización 3D con las primeras 3 CPs (de las 4 usadas en clustering) ---
from mpl_toolkits.mplot3d import Axes3D

fig = plt.figure(figsize=(8,6))
ax = fig.add_subplot(111, projection="3d")

scatter = ax.scatter(
    X_cluster[:,0], X_cluster[:,1], X_cluster[:,2], # CP1, CP2 y CP3 (de las 4)
    c=df["cluster"], cmap="Set2", s=50
)

ax.set_xlabel("CP1")
ax.set_ylabel("CP2")
ax.set_zlabel("CP3")
ax.set_title("Clustering con 4 CPs (visualización en 3D con 3 de ellas)")

plt.legend(*scatter.legend_elements(), title="Cluster")
plt.show()

```

Figura 2.18: Procedimiento de clustering con K-means sobre los componentes principales. Se aplicaron el método del codo y el coeficiente de Silhouette para determinar el número óptimo de clústeres, seleccionándose $k = 3$ como la solución más parsimoniosa y coherente.

La Figura 2.18 presenta el flujo de trabajo para la segmentación de inmuebles mediante K-means. El método del codo y el coeficiente de Silhouette sugieren que tres clústeres constituyen la mejor partición del conjunto de datos. Esta agrupación permitió identificar tipologías diferenciadas de propiedades en la Ciudad de México, principalmente en función de su superficie y precio por metro cuadrado, lo que enriquece la comprensión del mercado inmobiliario.




Figura 2.19: Evaluación del número de clústeres mediante el método del codo (arriba) y el coeficiente de Silhouette (abajo). Ambos criterios sugieren que la partición óptima se encuentra en $k = 3$, balanceando simplicidad y calidad de segmentación.

La Figura 2.19 muestra la evaluación del número de clústeres para el algoritmo K-means. El método del codo indica un punto de inflexión en $k = 3$, mientras que el

coeficiente de Silhouette alcanza su máximo en $k = 2$ pero mantiene un valor alto en $k = 3$. Por lo tanto, se seleccionó $k = 3$ como solución final por ofrecer una segmentación parsimoniosa y con interpretabilidad suficiente para describir tipologías de propiedades en la Ciudad de México.




Figura 2.20: Resultados del clustering con K-means ($k=3$). El resumen estadístico muestra las medias y desviaciones estándar de cada grupo, mientras que la visualización en 3D (con tres componentes principales) ilustra la separación entre los clústeres.

La Figura 2.20 presenta los resultados finales del clustering. El Clúster 0 agrupa la mayoría de las propiedades, caracterizadas por superficies y precios más bajos; el Clúster 1 reúne inmuebles de gran tamaño y alto costo, mientras que el Clúster 2 corresponde a un caso atípico. La visualización en 3D confirma la separación entre los grupos, lo que valida la segmentación propuesta del mercado inmobiliario en la Ciudad de México.

```
# Construir DataFrame con las 4 primeras CPs
pca_df = pd.DataFrame(
    X_pca[:, :4],
    columns=["CP1", "CP2", "CP3", "CP4"]
)

# Agregar la columna de clusters
pca_df["cluster"] = df["cluster"]

# --- Pairplot de las 4 CPs coloreado por cluster ---
sns.pairplot(
    pca_df,
    vars=["CP1", "CP2", "CP3", "CP4"],
    hue="cluster",
    palette="Set2",
    diag_kind="kde",
    plot_kws={"alpha":0.6, "s":50}
)
plt.suptitle("Pairplot de las 4 primeras componentes principales", y=1.02)
plt.show()

# --- Scatterplots individuales ---
fig, axes = plt.subplots(2, 3, figsize=(15,10))

pairs = [
    ("CP1", "CP2"), ("CP1", "CP3"), ("CP1", "CP4"),
    ("CP2", "CP3"), ("CP2", "CP4"), ("CP3", "CP4")]

for ax, (x, y) in zip(axes.flatten(), pairs):
    sns.scatterplot(
        data=pca_df, x=x, y=y, hue="cluster",
        palette="Set2", alpha=0.7, s=50, ax=ax
    )
    ax.set_title(f"{x} vs {y}")

plt.suptitle("Scatterplots entre pares de componentes principales", y=1.02)
plt.tight_layout()
plt.show()
```

Figura 2.21: Distribución de los clústeres en el espacio de los cuatro primeros componentes principales (CP1–CP4). Se muestran un pairplot y scatterplots entre pares de componentes, con los puntos coloreados según el clúster asignado.

La Figura 2.21 presenta la visualización de los clústeres en el espacio de las primeras cuatro componentes principales. El pairplot y los scatterplots revelan que los dos clústeres principales forman agrupaciones diferenciadas, mientras que el tercer clúster corresponde a un caso atípico. Estas representaciones gráficas complementan el análisis cuantitativo y confirman la coherencia de la segmentación realizada con K-means.




Figura 2.22: Pairplot de los cuatro primeros componentes principales (CP1–CP4) coloreado por clúster. Se observa que los clústeres 0 y 1 forman agrupaciones diferenciadas, mientras que el clúster 2 corresponde a un caso atípico.

La Figura 2.22 muestra la distribución de los clústeres en diferentes combinaciones de componentes principales. El Clúster 0 concentra la mayoría de las propiedades, el Clúster 1 agrupa inmuebles de gran valor y superficie, y el Clúster 2 corresponde a un outlier. Esta visualización confirma gráficamente la validez de la segmentación realizada con K-means.




Figura 2.23: Scatterplots entre pares de componentes principales (CP1–CP4) coloreados por clúster. El Clúster 0 concentra la mayoría de los inmuebles, el Clúster 1 agrupa propiedades de mayor tamaño y valor, y el Clúster 2 corresponde a outliers.

La Figura 2.23 presenta la distribución de los clústeres en distintas combinaciones de componentes principales. Los resultados muestran que los clústeres 0 y 1 forman agrupaciones diferenciadas, mientras que el clúster 2 se mantiene como un conjunto aislado de observaciones extremas. Estos gráficos refuerzan la validez de la segmentación obtenida mediante K-means.

```

# Distribución de tipos de vivienda por cluster
print(df.groupby("cluster")["property_type"].value_counts(normalize=True))

# Distribución de lugares por cluster
print(df.groupby("cluster")["places"].value_counts(normalize=True))

```

cluster	property_type	proportion
0	apartment	0.504679
	house	0.475267
	store	0.017380
	PH	0.002674
1	apartment	1.000000
2	apartment	0.738006
	house	0.252972
	store	0.008424
	PH	0.000597

Name: proportion, dtype: float64

cluster	places	proportion
0	MiguelHidalgo	0.483957
	AlvaroObregon	0.181150
	Cuajimalpa	0.165107
	Tlalpan	0.046791
	Coyoacan	0.037433
	Cuauhtemoc	0.030749
	BenitoJuarez	0.018717
	MagdalenaContreras	0.018048
	GustavoAMadero	0.009358
	Azcapotzalco	0.004679
	Iztapalapa	0.002005
	VenustianoCarranza	0.001337
	Tlahuac	0.000668
1	Iztapalapa	1.000000
2	BenitoJuarez	0.216944
	Cuauhtemoc	0.124276
	AlvaroObregon	0.113999
	MiguelHidalgo	0.092191
	Coyoacan	0.072116
	GustavoAMadero	0.061540
	Iztapalapa	0.059569
	Tlalpan	0.058194
	Azcapotzalco	0.043496
	VenustianoCarranza	0.037342
	Cuajimalpa	0.036386
	Iztacalco	0.031427
	MagdalenaContreras	0.019836
	Tlahuac	0.017805
	Xochimilco	0.014758
MilpaAlta	0.000119	

Name: proportion, dtype: float64

Figura 2.24: Distribución de tipos de vivienda y lugares por clúster. El Clúster 0 contiene principalmente casas y departamentos distribuidos en varias alcaldías, mientras que el Clúster 1 está conformado casi exclusivamente por departamentos de alto valor, concentrados en zonas específicas como Iztapalapa, Álvaro Obregón y Cuauhtémoc. El Clúster 2 corresponde a un caso atípico en Iztapalapa.

La Figura 2.24 muestra la distribución de los clústeres por tipo de propiedad y lugar de localización. El Clúster 0 representa el segmento masivo y diverso, el Clúster 1 concentra departamentos de alto valor en ciertas alcaldías, y el Clúster 2 corresponde a un outlier. Este resultado confirma que tanto el tipo de inmueble como la ubicación geográfica son factores determinantes en la segmentación del mercado inmobiliario.



Figura 2.25: Resumen descriptivo de los clústeres generados por K-means. Se presentan medidas de tendencia central, tipo de propiedad predominante, lugar más común y número de observaciones en cada grupo.

La Figura 2.25 resume las características de los clústeres identificados. El Clúster 0 corresponde al grupo masivo, con precios y superficies medias, predominio de departamentos y alta representación en Miguel Hidalgo. El Clúster 1 concentra propiedades de gran

tamaño y alto valor, localizadas principalmente en Iztapalapa. El Clúster 2 es un caso atípico aislado en Benito Juárez. Estos resultados confirman que el mercado inmobiliario en la Ciudad de México se estructura en dos tipologías principales, con un tercer grupo residual.

```
# Si partimos del DataFrame original df
cat_vars = ["property_type", "places"]

# One-hot encoding de categóricas
df_dummies = pd.get_dummies(df[cat_vars], drop_first=True)

# Concatenamos numéricas + dummies
X_all_df = pd.concat([df[num_vars], df_dummies], axis=1)

# Escalamos
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
X_all_scaled = scaler.fit_transform(X_all_df)

# PCA con 4 componentes
from sklearn.decomposition import PCA
pca = PCA(n_components=4)
X_pca = pca.fit_transform(X_all_scaled)
```

Figura 2.26: Incorporación de variables categóricas en el PCA mediante *one-hot encoding*. Se incluyen el tipo de propiedad y la ubicación, combinados con las variables numéricas y reducidos a cuatro componentes principales.

La Figura 2.26 muestra el proceso de integración de variables categóricas al análisis mediante *one-hot encoding*. Este procedimiento permite combinar variables numéricas y cualitativas en un mismo espacio reducido a cuatro componentes principales, lo que aporta una representación más completa del mercado inmobiliario. De esta manera, el PCA captura tanto la dimensión cuantitativa (precio, superficie) como la categórica (tipo de vivienda, ubicación geográfica).

```
# --- Varianza explicada ---
explained_var = pca.explained_variance_ratio_

print("Varianza explicada por cada componente:")
for i, var in enumerate(explained_var, 1):
    print(f"CP{i}: {var:.4f} ({var*100:.2f}%)")

print("\nVarianza acumulada:", explained_var.cumsum())

# --- Gráfica de varianza individual + acumulada ---
plt.figure(figsize=(8,5))
plt.bar(range(1, len(explained_var)+1), explained_var, alpha=0.7, label="Varianza individual")
plt.plot(range(1, len(explained_var)+1), explained_var.cumsum(), marker="o", color="red", label="Varianza acumulada")
plt.xticks(range(1, len(explained_var)+1))
plt.xlabel("Número de componentes")
plt.ylabel("Varianza explicada")
plt.title("Varianza explicada por los 4 componentes principales")
plt.legend()
plt.grid(True, linestyle="--", alpha=0.6)
plt.show()

# --- Loadings ---
num_vars_all = X_all_df.columns # ahora si tenemos las columnas originales
loadings = pd.DataFrame(
    pca.components_.T,
    index=num_vars_all,
    columns=[f"CP{i+1}" for i in range(pca.n_components_)]
)

print("\nMatriz de loadings (4 componentes):")
print(loadings)

# --- Heatmap de loadings ---
plt.figure(figsize=(12,6))
sns.heatmap(loadings, annot=False, cmap="coolwarm", center=0)
plt.title("Loadings de las variables en los 4 componentes principales")
plt.show()
```

Figura 2.27: Varianza explicada y loadings de los cuatro componentes principales obtenidos tras incluir variables numéricas y categóricas mediante *one-hot encoding*.

La Figura 2.27 muestra la proporción de varianza explicada por cada componente y los loadings asociados al PCA extendido. Los resultados indican qué combinación de variables numéricas y categóricas explica la mayor parte de la variabilidad en los datos. De esta manera, el PCA no solo resume la información en términos de precio y superficie, sino que también incorpora la influencia del tipo de vivienda y la ubicación geográfica en los componentes principales.




Figura 2.28: Varianza explicada por los cuatro primeros componentes principales tras incluir variables categóricas (one-hot encoding). La varianza acumulada es del 35.55%, menor a la obtenida con solo variables numéricas.

La Figura 2.28 muestra que la inclusión de variables categóricas mediante one-hot encoding dispersa la varianza entre más dimensiones. Mientras que en el PCA con solo variables numéricas los tres primeros componentes explicaban más del 85% de la varianza, en este caso los cuatro primeros apenas alcanzan el 35.55%. Esto indica que la incorporación de categorías enriquece el análisis, pero incrementa la complejidad y la dimensionalidad del dataset.




Figura 2.29: Matriz de loadings del PCA con variables numéricas y categóricas (one-hot encoding). Los cuatro componentes principales se interpretan como: (1) dimensión económica (precio absoluto), (2) dimensión geográfica/tipológica (ubicación y tipo de propiedad), (3) dimensión física (superficie), (4) dimensión relativa (precio por metro cuadrado).

La Figura 2.29 muestra la contribución de cada variable a los cuatro componentes principales. El CP1 está dominado por los precios, el CP2 por las ubicaciones y tipos de propiedad, el CP3 por las superficies y el CP4 por los precios relativos por metro cuadrado. Este análisis confirma que la reducción de dimensionalidad integra tanto la información económica y física como la categórica y espacial del mercado inmobiliario.

```

from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score

# Usamos las 4 CPs como entrada al clustering
X_cluster = X_pca[:, :4]

# Método del codo y silhouette
inertia = []
silhouette = []
K = range(2, 8)

for k in K:
    kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
    kmeans.fit(X_cluster)
    inertia.append(kmeans.inertia_)
    silhouette.append(silhouette_score(X_cluster, kmeans.labels_))

# Gráfica del codo
plt.figure(figsize=(6,4))
plt.plot(K, inertia, marker="o")
plt.xlabel("Número de clusters (k)")
plt.ylabel("Inercia (Suma de distancias)")
plt.title("Método del codo - KMeans (4 CPs)")
plt.show()

# Gráfica de Silhouette
plt.figure(figsize=(6,4))
plt.plot(K, silhouette, marker="o", color="orange")
plt.xlabel("Número de clusters (k)")
plt.ylabel("Silhouette Score")
plt.title("Evaluación con Silhouette (4 CPs)")
plt.show()

# --- Entrenamos modelo final ---
# Supongamos que k=3 es el mejor (ajusta según gráficas)
kmeans = KMeans(n_clusters=3, random_state=42, n_init=10)
df["cluster"] = kmeans.fit_predict(X_cluster)

print("\nCantidad de propiedades por cluster:")
print(df["cluster"].value_counts())

```

Figura 2.30: Aplicación de K-means con las cuatro primeras componentes principales (incluyendo variables categóricas). Se utilizó el método del codo y el coeficiente de Silhouette para determinar el número óptimo de clústeres, seleccionándose $k = 3$ como la mejor solución.

La Figura 2.30 muestra el procedimiento de clustering aplicado tras el PCA con variables numéricas y categóricas. Los criterios del codo y de Silhouette sugieren que $k = 3$ constituye la solución más parsimoniosa y coherente, lo que permite una segmentación clara del mercado inmobiliario en tres grupos diferenciados.




Figura 2.31: Evaluación del número de clústeres con PCA + categóricas mediante el método del codo (arriba) y el coeficiente de Silhouette (abajo). La mejor solución se encuentra en $k = 3$, lo que permite una partición parsimoniosa del mercado inmobiliario.

La Figura 2.31 muestra que el método del codo sugiere $k = 3$ como número óptimo de clústeres, mientras que el coeficiente de Silhouette alcanza sus valores máximos en $k = 4$ y $k = 5$, aunque con $k = 3$ se mantiene en un nivel aceptable (0.51). Con $k = 3$, la distribución es de 11,138 propiedades en el Clúster 0, 5,125 en el Clúster 2 y una propiedad atípica en el Clúster 1. Estos resultados confirman que la estructura del mercado inmobiliario puede resumirse en dos grupos principales y un tercer grupo residual.

Cuadro 2.1: Promedios descriptivos por clúster (PCA + categóricas, K-means)

Clúster	Precio aprox. (USD)	Superficie total (m ²)	Precio USD/m ²	Nº propiedades
0	267,432	470	1566	11,138
2	74,800,000	65,748	818	5,125
1	597,491	420	1343	1 (outlier)

La Tabla 2.1 resume los promedios por clúster. El Clúster 0 concentra la mayoría de propiedades con precios y superficies moderadas, el Clúster 2 agrupa inmuebles de gran tamaño y altísimo valor económico, y el Clúster 1 corresponde a un caso atípico aislado. En conjunto, se identifican dos tipologías principales del mercado inmobiliario en la Ciudad de México.

```
# Estadísticas descriptivas por cluster
desc_clusters = df.groupby("cluster")[[
    "price", "price_aprox_usd", "surface_total_in_m2",
    "surface_covered_in_m2", "price_usd_per_m2", "price_per_m2"
]].mean().round(2)

print("\nPromedios por cluster:")
print(desc_clusters)

print("\nTamaño de cada cluster:")
print(df["cluster"].value_counts())
```

```
Promedios por cluster:
      price  price_aprox_usd  surface_total_in_m2 \
cluster
0      267432.03      197457.68           470.17
1      748000.00      39418.83      65748000.00
2      597941.21      45700.79           422.25

      surface_covered_in_m2  price_usd_per_m2  price_per_m2
cluster
0              445.97           1566.30      26230.57
1      65748000.00              0.00              0.01
2              403.99           1343.79      21160.50

Tamaño de cada cluster:
cluster
0      13108
2       5125
1           1
Name: count, dtype: int64
```

Figura 2.32: Estadísticos descriptivos de cada clúster: precio, superficie y precio por metro cuadrado. Se observa que el Clúster 0 corresponde a propiedades de nivel medio, el Clúster 2 a inmuebles exclusivos y el Clúster 1 a un caso atípico.




Figura 2.33: Distribución de tipos de vivienda y de lugares más comunes por clúster.

En todos los grupos predominan los departamentos, aunque con distinta localización:

- El Clúster 0 se concentra en zonas céntricas como Benito Juárez y Miguel Hidalgo
- El Clúster 2 se ubica mayoritariamente en alcaldías periféricas como Iztapalapa y Tlalpan.
- El Clúster 1 corresponde a un caso atípico en Cuauhtémoc.

La Figura 2.33 muestra que los departamentos son el tipo de propiedad predominante en todos los clústeres. Sin embargo, su localización varía: el Clúster 0 está dominado por zonas céntricas de alta plusvalía, mientras que el Clúster 2 agrupa propiedades ubicadas en áreas periféricas. El Clúster 1 representa un caso atípico aislado en Cuauhtémoc.

```

# Boxplots de precios por cluster
sns.boxplot(data=df, x="cluster", y="price")
plt.title("Distribución de precios por cluster")
plt.show()

# Boxplots de superficie por cluster
sns.boxplot(data=df, x="cluster", y="surface_total_in_m2")
plt.title("Distribución de superficie total por cluster")
plt.show()

# Countplot de tipo de vivienda
sns.countplot(data=df, x="cluster", hue="property_type")
plt.title("Distribución de tipos de vivienda por cluster")
plt.show()

```

Figura 2.34: Visualización comparativa de clústeres mediante boxplots y countplots. Los precios y superficies confirman que el Clúster 0 corresponde al segmento masivo, el Clúster 2 al segmento exclusivo y el Clúster 1 a un outlier. Los countplots muestran que los departamentos son el tipo de vivienda predominante en todos los grupos.

La Figura 2.34 muestra las diferencias entre clústeres en precio, superficie y tipo de vivienda. Se observa que el Clúster 0 representa propiedades intermedias, el Clúster 2 inmuebles de gran tamaño y alto valor, y el Clúster 1 un caso atípico. Los departamentos predominan en todos los clústeres.




Figura 2.35: Distribución de precios (arriba) y superficie total (abajo) por clúster. El Clúster 0 agrupa propiedades de nivel medio, el Clúster 2 reúne inmuebles de gran superficie y altísimo valor, y el Clúster 1 corresponde a un caso atípico.

La Figura 2.35 muestra la diferencia entre los clústeres en términos de precio y superficie. El Clúster 0 corresponde a propiedades de nivel medio, el Clúster 2 a un segmento exclusivo con valores extremos, y el Clúster 1 a un caso aislado. Estas visualizaciones refuerzan la interpretación de la segmentación realizada con K-means.





Figura 2.36: Distribución de tipos de vivienda por clúster. El Clúster 0 está compuesto principalmente por departamentos, mientras que el Clúster 2 corresponde en su mayoría a casas. El Clúster 1 no presenta representación significativa.

La Figura 2.36 muestra que los departamentos dominan en el Clúster 0 (mercado masivo), mientras que las casas prevalecen en el Clúster 2 (segmento exclusivo). El Clúster 1 corresponde a un caso aislado.

Bibliografía

- Peña, D. (2002). Analisis de datos multivariantes. McGraw-Hill Interamericana de España, S.L.
- k-means. (s/f). Unioviedo.es. Recuperado el 07 de septiembre del 2025, de https://www.unioviedo.es/compnum/laboratorios_py/kmeans/kmeans.html.
- Anderson, T. W. (2003). An Introduction to Multivariate Statistical Analysis (3^a ed.). Wiley.
- Housing Prices in CDMX. Kaggle. Recuperado el 03 de septiembre del 2025, de <https://www.kaggle.com/datasets/renecardoso/housing-prices-in-cdmx>.

Colaboradores



Omar Misael Valero Silva



Karla Anahi Sanchez Morales



Karol Jacqueline Nolasco Reyes



David Mendieta Lopez



Cesar Gabriel Lopez Lopez