



Facultad de Estudios Superiores

Acatlán

Diplomado: Metodos Estadisticos
y Minería de Datos.

Modulo VI: Analisis Multivariado

Tarea 1: Analisis de Conglomerados

07 de Septiembre del 2025

Profesor: Mahil Herrera Maldonado


Integrantes del Equipo 5:



☐ Omar Misael Valero Silva



☐ Karla Anahi Sanchez Morales



☐ Karol Jacqueline Nolasco Reyes



☐ David Mendieta Lopez



☐ Cesar Gabriel Lopez Lopez

índice:

❖ Objetivo	3
❖ Introducción	3
❖ Problemática	4
❖ Técnicas estadísticas utilizadas	4
❖ Resolución	5
➤ Limpieza en los datos	5
➤ Análisis de los datos	6
❖ Conclusión	9
❖ Anexo	9
❖ Bibliografía	12

Objetivo:

Encontrar agrupaciones que no se distinguen a simple vista de la base de datos llamada: **“practica01elecciondeoptativasGrupo30”** y detectar las características que los resaltan entre clusters.

Introducción:



Las **materias optativas** son asignaturas (previamente autorizadas por la coordinación educativa) que forman parte de la mayoría de los planes de estudios de las licenciaturas y los alumnos tienen el derecho de poder cursarlas cumpliendo ciertos requisitos.

Estas materias están diseñadas y apegadas a los aprendizajes y conocimientos que se siembra en el estudio de una carrera universitaria; su

función (además de cursar cierta cantidad de ellas para completar los créditos correspondientes) es el generar la especialización que los estudiantes desean realizar para adentrarse a las áreas principales que sus licenciatura abarca y así poder desempeñarse en el ámbito laboral con más preciso y eficiente.

En **La Facultad de Estudios Superiores Acatlán** las materias optativas son impartidas en los últimos semestres de las carreras, en promedio se complempla entre 4 a 6 optativas a cursar; esta limitación de lugares disponibles contra la inmensa lista de materias que son consideradas para tomar este rol, hace imposible que los alumnos puedan cursar las asignaturas que ellos desean (también está la limitación administrativa y educativa de las facultad para abordar todas la materias).

Por lo que a mitad del periodo semestral, se convoca a todos los alumnos a contestar una encuesta en línea para determinar por mayoría las materias más populares para tomar esos lugares como optativas para cada una de las carreras. Lo más importante de las encuesta es que cada alumno puede indicar cuales son las asignaturas que más desean (tomado un orden de preferencia) que se considere por ser las materias optativas y al final por votación se publican cuáles son las materias seleccionadas para sus previa inscripción en el próximo semestre.



Para la licenciatura de **Actuaría** no es la excepción a esta regla; y de hecho el coordinador de la carrera pudo recolectar de la encuesta del **semestre 2025-2**, las 5 asignaturas que más prefieren los alumnos. Curiosamente la construcción de la base de datos tiene la siguiente forma:

Este una Identificador numerico de cada uno de los alumnos

Con un valor entre 1 – 5 se coloca un orden de preferencia sobre las materias que cada alumno escogio

	A	B	C	D
1	Individuo	Orden de preferencia	Clave	Nombre de la Materia
2		1	5	2030.00 Análisis de datos
3		1	4	2031.00 Análisis Multivariado
4		1	3	2049.00 Evaluación de proyectos
5		1	2	2046.00 Auditoría Actuarial
6		1	1	2047.00 Contabilidad de Seguros

Este es una identificador numerico sobre la materia

El coordinador estaría interesado en observar si se puede agrupar la preferencia de los de los alumnos que no son perceptivas a simple vista....

Problemática:

Algunos puntos problemáticos que podemos detectar de las base de datos llamado: **“practica01elecciondeoptativasGrupo30”** sería 2 aspectos:

- La presencia de valores incoherentes y vacíos a las columnas que son representadas. Por ejemplo:

Individuo	Orden de preferencia	Clave	Nombre de la Materia
3	62	3	2044.00 An=E1lisis de Estados Financieros
9	62	2	2033.00 Derivados
0	62	1	2051.00 Finanzas Internacionales
1	63	5	2043.00
2	63	4	2044.00
3	63	3	2033.00

- Por otra parte; está en tela de discusión si es necesario el utilizar todas las columnas o solo algunas de ellas para **una análisis de clustering** más adelante. Ya que como se había visto, 2 columnas son identificadas y 2 columnas de información.



Técnicas estadísticas utilizadas

Para el análisis y agrupamiento de las materias optativas se aplicaron tres técnicas estadísticas complementarias, cada una implementada mediante código en Python (ver capturas de código en el anexo).

1. Análisis de conglomerados jerárquico (Dendrograma)

Se construyó una tabla pivote con las materias como filas y los alumnos como columnas, utilizando el orden de preferencia como valores. Posteriormente, se aplicó el método de enlace *Ward* para calcular las distancias y generar un dendrograma.

Este gráfico permitió visualizar relaciones de similitud entre materias: las ramas más cercanas indican elecciones con patrones similares, mientras que las ramas más alejadas reflejan baja afinidad. Esto ofreció una primera aproximación visual a posibles agrupamientos.

2. Clustering con K-means

Con la misma tabla pivote, se aplicó el algoritmo K-means con **5 clústeres**, siguiendo el planteamiento inicial de la práctica. Cada clúster representó un grupo de materias con perfiles de preferencia similares.

Se estableció un límite máximo de 5 materias por grupo para mantener la manejabilidad, aunque algunos clústeres presentaron menos de 5 materias, lo cual es esperable, ya que el algoritmo prioriza la similitud más que la uniformidad en el tamaño de los grupos. Los resultados mostraron cierta coherencia con el dendrograma, pero no necesariamente garantizan que las materias se elijan juntas en la práctica.

3. Análisis de co-ocurrencia

Este método contó cuántas veces fueron elegidas en conjunto las materias por los mismos alumnos dentro de sus cinco opciones disponibles. A partir de esta matriz de co-ocurrencia, se identificaron las combinaciones con mayor frecuencia y se formaron hasta 5 grupos, cada uno con un máximo de 5 materias.

A diferencia de K-means, este enfoque detecta **grupos naturales basados en elecciones reales**, ya que parte de un hecho observable: si dos o más materias son elegidas repetidamente por los mismos estudiantes, es probable que sean compatibles para abrirse juntas. Este resultado se consideró más adecuado para el objetivo de la práctica, ya que se basa en evidencia directa de compatibilidad.

En resumen, el dendrograma proporcionó una visión global de las similitudes, K-means ofreció un agrupamiento matemático por perfiles de preferencia, y la co-ocurrencia permitió obtener grupos basados en combinaciones reales observadas en los datos.

Resolución:

1. Limpieza de los datos:

Tenemos un total de 609 registros en la base de datos, de las cuales 124 pertenecen a las respuestas de los alumnos que a lo más de 5 observaciones corresponden a las 5 materias de su preferencia.

A Pesar de que si observamos la base de datos por Excel, podemos ver un caos de los datos, es solo mera estética. Después podemos ver que algunos nombre de las asignaturas están mal escritos por parte del alumnado; por lo que hay que cambiarlos, por medio de la función: **“BUSCARV”** de estaríamos vinculando con los nombres correctos en base a sus claves asociadas (*previamente corregimos los decimales de mas que tenia las claves a ninguna posición decimal por contexto de la información*) de la siguiente manera:

SUMA : ✖ ✔ $\sum$ = MAYUSC(BUSCARV(C2,materias!\$B\$1:\$C\$27,2,0))				
	A	B	C	D
1	Individuo	Orden de preferencia	Clave	Materia
2		1	5	2030
3		1	4	2031 ANÁLISIS MULTIVARIADO

Afortunadamente, el coordinador nos proporcionó la lista de materias que estaban contemplando con sus claves correspondientes (*en otra hoja aparte de la base*) y tan solo con la función: **“Mayusc”** hacemos que los datos estén más presentables. Dándonos como resultado:


Individuo	Orden de preferencia	Clave	Materia
1	5	2030	ANÁLISIS DE DATOS CATEGORICOS
1	4	2031	ANÁLISIS MULTIVARIADO
1	3	2049	EVALUACIÓN DE PROYECTOS
1	2	2046	AUDITORIA ACTUARIAL
1	1	2047	CONTABILIDAD DE SEGUROS
2	5	2035	FINANZAS PÚBLICAS
2	4	2055	SEGUROS DE PERSONAS

Considerando que las claves originales en la base de datos sean la elegidas por el alumnado.


2. Análisis de los datos:

Con el archivo limpio, pasamos a una revisión de los datos sobre el comportamiento de la información utilizando los datos. Para ello vamos a cargar los datos en una plataforma llamada: **SAS Viya** (*programa estadístico para análisis e implementación de modelos utilizando datos*) en el apartado: **Visualización y Exploración....**


Observando la proporción de las materias que participaron son las siguientes:



Entre las materias más populares podemos encontrar que las áreas más populares entre los Actuarios son **las áreas estadística y financieras**; un movimiento que refleja el cambio que ha tenido la carrera desde sus orígenes desde el siglo pasado. Ya que esta carrera se ha centrado en los seguros originalmente y que ha cambiado con el tiempo, dicha área no está presente en las materias menos presentes en sus favoritas que son el 8.9% en otros.....



Después; veamos como es el comportamiento de los preferencia que tienen los estudiantes con respecto a sus materias que si lo vemos por una gráficas de barras que de hecho, no todo los estudiantes marcaron las 5 materias...



La mayoría de los alumnos si marcaron sus 5 materias; pero estaría faltando 11 registros que remarque el orden de materia y es claro ver que orden faltan (*es posible que en la encuesta no haya contestando dichas preguntas en específicos*).


Esto nos recalca el hecho que la mayoría de los estudiantes estan conforme con escoger 5 materias de sus preferencia y en las observaciones atípicas se conforman con solo 2 materias (*posiblemente por no contestar las preguntas con referentes a esta posiciones*)

Como el orden de preferencia tiene más importancia de forma descendente (*de 5 al 1*) Veamos cuales con las 10 materias que más destacan en este posicionamiento:

La mejor asignaturas para ser optativa (con estatus 5):




La asignaturas para ser optativa (con estatus 4):




La asignaturas para ser posible optativa (con estatus 3):



La asignaturas con pocas probabilidades optativa (con estatus 2):



La asignaturas la que menos desean como optativa (con estatus 1):



Conclusión

Después de limpiar y organizar la base de datos, fue posible tener una visión mucho más clara de las preferencias de los estudiantes de Actuaría. Lo primero que llamó la atención es que las materias más solicitadas están relacionadas con las áreas estadística y financiera, lo que confirma la tendencia de la carrera a enfocarse en campos con alta demanda laboral y deja en segundo plano áreas que antes eran más representativas, como la de seguros.

También vimos que la mayoría de los alumnos aprovechó la oportunidad de elegir cinco materias, aunque hubo algunos casos que no llenaron todas las posiciones, probablemente por descuido al contestar la encuesta. Esto indica que, en general, hay un alto interés por participar en la selección de optativas, pero que existen registros atípicos que podrían influir en un análisis más profundo.

En resumen, este trabajo permitió no solo conocer qué materias son las más populares, sino también sentar las bases para un análisis de agrupamiento que ayude a encontrar patrones más ocultos en las preferencias de los estudiantes. Con esta información, el coordinador podrá tomar mejores decisiones para ajustar la oferta de optativas y adaptarla a lo que realmente buscan los alumnos.

Anexo

El código mostrado en la captura siguiente lee la base limpia **optativas_limpio.xlsx**, construye una tabla pivote con las materias como filas y los alumnos como columnas, y calcula las distancias entre materias con el método de enlace Ward. Esto permite agrupar aquellas con patrones de elección más similares. El resultado es un dendrograma, donde las ramas más cercanas presentan alta afinidad y las más altas menor similitud, sirviendo como guía para posibles agrupamientos.


```
[ ] import pandas as pd
import matplotlib.pyplot as plt
from scipy.cluster.hierarchy import dendrogram, linkage

# Leer el archivo
df = pd.read_excel("optativas_limpio.xlsx")

# Crear tabla pivote
pivot = df.pivot_table(index="Materia", columns="Individuo", values="Orden de preferencia", fill_value=0)

# Calcular distancias y linkage
linked = linkage(pivot, method='ward')

# Dibujar dendrograma
plt.figure(figsize=(12, 6))
dendrogram(linked, labels=pivot.index.tolist(), orientation='top', distance_sort='ascending')
plt.title("Dendrograma de Materias Optativas")
plt.xlabel("Materias")
plt.ylabel("Distancia")
plt.xticks(rotation=90)
plt.tight_layout()
plt.show()
```



El código mostrado en la captura siguiente aplica el algoritmo K-means para agrupar las materias en 5 clústers, usando como entrada la base limpia optativas_limpio.xlsx. Primero se construye una tabla pivote con las materias como filas y los alumnos como columnas, donde el valor es el orden de preferencia asignado por cada estudiante (rellenando con 0 cuando no fue elegida).

Con esta matriz, K-means asigna cada materia al clúster cuyo centroide sea más cercano en términos de patrón de preferencias. Posteriormente se ordenan las materias por grupo y se limita la salida a un máximo de 5 materias por clúster, priorizando las más representativas.

```
[ ] import pandas as pd
    from sklearn.cluster import KMeans

    # Leer archivo
    df = pd.read_excel("optativas_limpio.xlsx")

    # Crear tabla pivote
    pivot = df.pivot_table(index="Materia", columns="Individuo", values="Orden de preferencia", fill_value=0)

    # Aplicar K-means con 5 clústers
    kmeans = KMeans(n_clusters=5, random_state=42, n_init=10)
    kmeans.fit(pivot)

    # Asociar materias a grupos
    resultado_kmeans = pd.DataFrame({
        "Materia": pivot.index,
        "Grupo": kmeans.labels_
    }).sort_values(by=["Grupo", "Materia"])

    # Limitar a 5 materias por grupo
    resultado_filtrado = (
        resultado_kmeans
        .groupby("Grupo")
        .head(5)
        .reset_index(drop=True)
    )

    # Mostrar
    print(resultado_filtrado)
```

Los grupos con K-means quedan de la siguiente manera:

	Materia	Grupo
0	ANALISIS MULTIVARIADO	0
1	ANALISIS DE DATOS CATEGORICOS	1
2	ANALISIS DE ESTADOS FINANCIEROS	1
3	ANALISIS ECONOMETRICO	1
4	AUDITORIA ACTUARIAL	1
5	CONTABILIDAD DE SEGUROS	1
6	ANALISIS DE REGRESION	2
7	MODELOS Y SIMULACION	2
8	DERIVADOS	3
9	ESTADISTICA BAYESIANA	4
10	MUESTREO	4

El código mostrado a continuación en la captura aplica un método de agrupamiento basado en co-ocurrencia para identificar materias que fueron elegidas juntas por los mismos alumnos. A partir del archivo `optativas_limpio.xlsx`, se ordenan las materias por alumno y por nivel de preferencia. Posteriormente, se cuentan todas las combinaciones de pares de materias seleccionadas por un mismo estudiante, construyendo así una matriz de co-ocurrencia donde cada celda indica cuántas veces dos materias fueron elegidas en conjunto.

A partir de esta matriz, se forman hasta 5 grupos, cada uno con un máximo de 5 materias, comenzando por las combinaciones más frecuentes y añadiendo las materias que presentan mayor compatibilidad con el grupo ya formado.

Este método tiene la ventaja de identificar grupos naturales basados en elecciones reales, ya que se fundamenta directamente en la coincidencia de materias dentro de las preferencias de los alumnos, lo que permite proponer grupos más coherentes y aplicables en la planificación académica.

```
[ ] import pandas as pd
import numpy as np
from itertools import combinations
from collections import Counter

# Leer archivo
df = pd.read_excel("optativas_limpio.xlsx")

# Agrupar materias por alumno
materias_por_alumno = (
    df.sort_values(by=["Individuo", "Orden de preferencia"], ascending=[True, False])
      .groupby("Individuo")["Materia"]
      .apply(list)
)

# Contar co-ocurrencias
coocurrencias = Counter()
for materias in materias_por_alumno:
    pares = combinations(sorted(set(materias)), 2)
    coocurrencias.update(pares)

# Crear matriz de co-ocurrencia
materias_unicas = sorted(set(df["Materia"]))
idx = {m: i for i, m in enumerate(materias_unicas)}
matriz = np.zeros((len(materias_unicas), len(materias_unicas)), dtype=int)

for (m1, m2), count in coocurrencias.items():
    i, j = idx[m1], idx[m2]
    matriz[i, j] = count
    matriz[j, i] = count
```

```
[ ] df_coocurrencia = pd.DataFrame(matriz, index=materias_unicas, columns=materias_unicas)

# Formar grupos de hasta 5 materias
grupos_optimos = []
materias_usadas = set()

for _ in range(5):
    disponibles = [m for m in df_coocurrencia.index if m not in materias_usadas]
    if len(disponibles) < 2:
        break
    submatriz = df_coocurrencia.loc[disponibles, disponibles]
    m1, m2 = submatriz.stack().idxmax()
    grupo = {m1, m2}
    while len(grupo) < 5:
        candidatos = [m for m in disponibles if m not in grupo]
        if not candidatos:
            break
        puntajes = {m: submatriz.loc[m, list(grupo)].sum() for m in candidatos}
        mejor = max(puntajes, key=puntajes.get)
        if puntajes[mejor] == 0:
            break
        grupo.add(mejor)
    grupos_optimos.append(sorted(grupo))
    materias_usadas.update(grupo)

# Convertir a DataFrame
df_grupos_finales = pd.DataFrame(grupos_optimos).T
df_grupos_finales.columns = [f"Grupo {i+1}" for i in range(len(df_grupos_finales.columns))]

# Mostrar
print(df_grupos_finales)
```

Y los grupos obtenidos con co-ocurrencia son:

	Grupo 1	Grupo 2 \
0	ANALISIS DE REGRESION	ANALISIS DE ESTADOS FINANCIEROS
1	DERIVADOS	AUDITORIA ACTUARIAL
2	EVALUACION DE PROYECTOS	FINANZAS INTERNACIONALES
3	MODELOS Y SIMULACION	FINANZAS PUBLICAS
4	MUESTREO	PLANEACION FINANCIERA

	Grupo 3	Grupo 4 \
0	ANALISIS DE DATOS CATEGORICOS	CONTABILIDAD DE SEGUROS
1	ANALISIS MULTIVARIADO	FINANZAS
2	ESTADISTICA BAYESIANA	MATEMATICAS ACTUARIALES APLICADAS
3	INVESTIGACION DE OPERACIONES II	PRESUPUESTO DE CAPITAL
4	SERIES DE TIEMPO	SEGUROS DE PERSONAS

	Grupo 5
0	ECONOMIA MATEMATICA II
1	ESTADISTICA DE SEGUROS
2	None
3	None
4	None

Bibliografía

- Código utilizado: [Practica 1 Modulo 6.ipynb - Colab](#)
- Analisis de los datos:
<https://vfl-024.engage.sas.com/links/resources/report?uri=%2Freports%2Freports%2Ff0755bd7-4ba1-4ca3-b36d-fa5e57f22a2f>