



Facultad de Estudios Superiores

Acatlán

Diplomado: Metodos Estadísticos
y Minería de Datos.

Modulo VI: Analisis Multivariado

Tarea 2: Componentes Principales

09 de Septiembre del 2025

Profesor: Mahil Herrera Maldonado


Integrantes del Equipo 5:



☐ Omar Misael Valero Silva



☐ Karla Anahi Sanchez Morales



☐ Karol Jacqueline Nolasco Reyes



☐ David Mendieta Lopez



☐ Cesar Gabriel Lopez Lopez

índice:

❖ Objetivo	3
❖ Introducción	3
❖ Problemática	
❖ Técnicas estadísticas utilizadas	
❖ Resolución	
➤ Limpieza en los datos	
➤ Análisis de los datos	
❖ Conclusión	
❖ Anexo	
❖ Bibliografía	

Objetivo:

Encontrar los componentes principales de la base de datos llamada: **“riesgo.xls”** y contestar a una serie de preguntas sobre la implementación de este método.

Introducción:

El **embarazo** es el proceso de gestación que tiene la hembra de la especie para el nacimiento de un nuevo organismo de la misma. En el caso de los seres humanos, las mujeres desempeña esta labor como el resultado de las relaciones sexuales; dicho proceso se tarda aproximadamente en los 9 meses para el nacimiento de un bebé.



Siglos antes; los partos se consideraban un peligro para las mujeres ya que en la mayoría de los casos, causaba la muerte a la madre y posiblemente a los recién nacidos. Conforme la tecnología y los conocimientos en medicina mejoraron, los partos ya eran seguros para ambas partes; sin embargo, conforme se desarrollaba la globalización del último siglo, aspectos tales como:

- Las enfermedades venéreas
- Método anticonceptivos
- Abortos (espontáneos o planificados)
- Embarazos no deseados (por edad o no planificados)

fueron apareciendo en la sociedad; la mayoría de los gobiernos han tratado de analizar, establecer y controlar la natalidad considerando los aspectos anteriores.

Un grupo de **Investigadores demográficos** está interesado en calificar a cada nación que mida el **“riesgo nacional”** sobre las complicaciones y consecuencias que pueda generar el parto; para ello se generó la siguiente base de datos llamada: **“riesgo.xls”**, donde se contempla un total de 118 registros con 12 columnas de datos como se puede observar a continuación:

	pais	nacannual	anticoncep	abort	anemia	atnprenat	partoasit	vihsida	infecun	nacpormuj	muertes	calif
0	Italia	1	78	1	10	100.0	100.0	1	6	1.2	4	6.6
1	Dinamarca	1	78	1	8	100.0	99.0	1	6	1.8	3	6.7
2	Noruega	2	76	1	17	95.0	100.0	1	5	1.8	3	8.1

Problemática:

El problema a abordar es la identificación de las dimensiones principales de variabilidad en los factores de riesgo materno y cómo estas se relacionan con la mortalidad materna y otros problemas asociados al embarazo. A partir de 10 variables cuantitativas, tales como tasas de embarazo adolescente, prevalencia de anticoncepción, atención sanitaria, índices de salud y mortalidad, etc.

- Se observó que una de las principales problemáticas de los datos es la limpieza de los mismos, ya que la columna F llamada 'atnprenat' y la columna 'partoasit' contenían datos vacíos:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 118 entries, 0 to 117
Data columns (total 12 columns):
#   Column          Non-Null Count  Dtype
---  -
0   pais            118 non-null   object
1   nacanual        118 non-null   int64
2   anticoncep      118 non-null   int64
3   abort           118 non-null   int64
4   anemia          118 non-null   int64
5   atnprenat       116 non-null   float64
6   partoasit       116 non-null   float64
7   vihsida         118 non-null   int64
8   infecun         118 non-null   int64
9   nacpormuj       118 non-null   float64
10  muertes         118 non-null   int64
11  calif           118 non-null   float64
dtypes: float64(4), int64(7), object(1)
memory usage: 11.2+ KB
```

Debido a que sólo son 4 registros en nuestra base de datos, decidimos eliminarlos.

Técnicas estadísticas utilizadas:

Para abordar el problema se emplearán las siguientes técnicas y herramientas estadísticas:

- Estadística Descriptiva:** Cálculo de estadísticas resumen (media, mínimo, máximo, desviación estándar) de las variables originales, para entender sus rangos y magnitudes, así como inspección de la matriz de covarianzas y la matriz de correlaciones. Esto incluye examinar las varianzas de cada variable y las correlaciones entre variables, identificando relaciones fuertes o débiles que puedan sugerir multicolinealidad o grupos de variables relacionadas.
- Análisis de Componentes Principales (ACP):** Método multivariante que utiliza álgebra lineal (autovectores y autovalores) para hallar combinaciones lineales de las variables originales que capturen la máxima varianza posible. Se aplicará el ACP a la matriz de correlación (R) de las 10 variables de riesgo (excluyendo la calificación de riesgo). Con el ACP se calcularán:
 - Los autovalores (eigenvalores) y autovectores de la matriz de correlación seleccionada.
 - La varianza explicada por cada componente principal (proporcional a cada

autovalor, dividido entre la varianza total).

- Las cargas factoriales (loadings) de cada variable en los componentes principales, es decir, los coeficientes del autovector que indican el peso de cada variable original en la construcción de la componente.
- Los componentes principales para cada país (scores), obtenidos como las combinaciones lineales de las variables estandarizadas con los coeficientes del autovector correspondiente.
- El ACP permitirá reducir dimensionalidad manteniendo el máximo de información. Se utilizará principalmente para identificación de patrones y para comparar con la variable omitida (índice de riesgo) mediante correlación.
- Visualización y Análisis Gráfico: Se utilizarán gráficos de dispersión bidimensional (plots de CP1 vs CP2, y CP2 vs CP3) para visualizar la distribución de los países en el espacio de las primeras componentes. Esto ayudará a detectar agrupamientos naturales de países con perfiles de riesgo similares, así como valores atípicos (países que se alejan de los grupos). Adicionalmente, se empleará la coloración de puntos según la calificación de riesgo original para verificar si dicha calificación se alinea con la posición en los componentes principales.

A continuación, se procede a describir el análisis en detalle, comenzando con una exploración descriptiva de los datos y luego la implementación del ACP y sus resultados.

Análisis utilizando la técnica:

Para el análisis de componentes principales de la base de datos **"Riesgo nacional"**, enfocada en las complicaciones y consecuencias que pueda generar el parto, lo primero que se realizó fue la depuración y preparación de la información, asegurando que las variables clave estuvieran completas y en formato numérico. Esta base contiene indicadores de salud materna e infantil para distintos países, incluyendo atención prenatal, asistencia en el parto, prevalencia de anemia, uso de anticonceptivos, incidencia de VIH/SIDA, entre otros, así como una calificación global de riesgo (calif).

Para caracterizar estos indicadores y su relación con la calificación de riesgo, se aplicaron varias técnicas estadísticas complementarias, todas implementadas en Python (ver fragmentos de código en el anexo).

1. Preparación y limpieza de datos.


Se cargó el archivo Excel original sin encabezados, asignando nombres de columnas a cada variable (por ejemplo, pais, nacannual, anticoncep, partoasit, etc.).

Posteriormente, se eliminaron los registros con valores faltantes en variables clave como atnprenat y partoasit.

Finalmente, se verificó que todas las variables numéricas estuvieran correctamente tipadas antes de iniciar el análisis.

2. Análisis descriptivo inicial.

- **Matriz de varianzas–covarianzas (S):** se calculó para observar la dispersión conjunta entre cada par de variables en sus unidades originales.



Para saber si las varianzas son del mismo orden, nos fijamos en la diagonal de la matriz. Aquí vemos que:


- Algunas varianzas son muy pequeñas: (orden 10^0 a 10^1).
- Otras están en cientos: (orden 10^2 a 10^3).
- Y una es enorme: (orden 10^5).

Esto indica que **no son del mismo orden de magnitud**; la diferencia llega a varios órdenes (de 10^0 hasta 10^5), lo que sugiere que sería conveniente **escalar o estandarizar** las variables antes de hacer un análisis como PCA, para que ninguna domine debido a su escala.

En resumen, la matriz de covarianzas S no está escalada uniformemente, implicando que si aplicáramos el ACP sobre S, la primera componente principal quedaría dominada por las variables de mayor varianza (especialmente v10). Esto no es deseable si nuestro interés es

dar a todas las variables igual posibilidad de contribuir al análisis. Por ello, suele ser preferible usar la matriz de correlaciones R en lugar de S cuando las variables están en diferentes unidades o escalas, como es nuestro caso.

- **Matriz de correlaciones (R):** se obtuvo para estandarizar las relaciones lineales (valores entre -1 y 1), eliminando el efecto de las escalas distintas.



Con base en la matriz de correlaciones, se puede observar que sí hay correlaciones fuertes, por ejemplo:

Positivas:

- atnprenat – partoasit: $r=0.7996$ → más atención prenatal se asocia con más partos asistidos.
- nacannual – nacpormuj: $r=0.8012$ → mientras más nacimientos por año, más nacimientos por mujer.

Negativas:

- anticoncep – nacpormuj: $r=-0.9409 \rightarrow$ mayor uso de anticonceptivos se asocia con menos nacimientos por mujer.
- anticoncep – nacannual: $r=-0.7469 \rightarrow$ mayor uso de anticonceptivos se asocia con menos nacimientos anuales.
- partoasit – muertes: $r=-0.7727 \rightarrow$ más partos asistidos se asocian con menos muertes.

¿Con cuál de las dos matrices se debe trabajar: S ó R, por qué?

Se recomienda trabajar con la matriz de correlaciones, ya que la matriz S está influenciada por la escala y unidades de cada variable. Como vimos, algunas varianzas están en el orden de 10^0 y otras en 10^5 , lo que implica que variables con valores más grandes dominarán el análisis. La matriz R estandariza las variables (cada una con media 0 y varianza 1), eliminando el efecto de la escala y permitiendo que todas tengan el mismo peso en el análisis.

- **Visualización con mapas de calor:** se empleó *seaborn* para representar gráficamente S y R, facilitando la detección de patrones de asociación y redundancias entre indicadores.

3. Análisis de Componentes Principales (PCA).

Se aplicó el PCA a la matriz de correlaciones con dos enfoques:

- **Cálculo manual:** se obtuvieron eigenvalores y eigenvectores de R usando `numpy.linalg.eig`, identificando la varianza explicada por cada componente (eigenvalores) y las combinaciones lineales de variables que los definen (eigenvectores).

```
Eigenvalores:
[6.03637992 1.35738212 0.6763321 0.54274434 0.04556734 0.11399123
 0.24159459 0.37373678 0.29472657 0.317545 ]

Eigenvectores:
[[ -3.47423910e-01  1.02783058e-01  1.56958869e-02  3.49343332e-01
  -1.43579227e-01  2.69314301e-01 -5.27412342e-01 -2.05073501e-01
   5.63696993e-01  1.23801208e-01]
 [ 3.70435835e-01 -4.63053513e-03 -2.35088167e-02 -4.82730949e-02
   6.07132420e-01  1.29162445e-01 -4.06404329e-01  4.87498087e-01
   9.47362669e-02  2.50572062e-01]
 [-2.70737849e-01 -1.74365343e-01  7.40937458e-01  3.45182647e-01
  -2.99681023e-02 -1.11252492e-01  8.34075830e-02  4.47792835e-01
  -7.32239065e-02 -4.52346675e-02]
 [-3.03618707e-01 -1.57575663e-01  1.23171887e-01 -7.50051250e-01
  -4.28415008e-03  3.91085599e-03 -1.80119934e-01  1.68808617e-01
   2.82065084e-01 -4.05836790e-01]
 [ 3.06508559e-01  3.94965366e-01  3.99627855e-01 -1.42479729e-01
   1.97358655e-02  5.66518802e-01  4.03270290e-01 -1.03073298e-01
   2.73621189e-01 -2.44810710e-02]
 [ 3.63890184e-01  1.30153489e-01  2.08699377e-01  3.90713079e-02
   7.96864928e-02 -7.13694418e-01  1.19655137e-02 -2.08613799e-01
   4.87446124e-01 -9.26592310e-02]
 [-2.33310111e-01  5.74064994e-01  2.33665572e-01 -3.37548050e-01
  -7.94531322e-02 -2.22481282e-01 -2.07957253e-01 -6.14300784e-02
  -2.88891122e-01  5.11066349e-01]
 [-1.83200391e-01  6.52210650e-01 -2.97806146e-01  2.23710797e-01
   7.26077288e-02 -8.78484074e-02  6.15755947e-02  3.86518989e-01
   3.23238815e-03 -4.85937967e-01]
 [-3.79721020e-01 -1.91200561e-04  1.09048940e-01  6.50183255e-02
   7.62333279e-01  2.55516999e-03  1.14861544e-01 -4.62452166e-01
  -1.15586196e-01 -1.34606650e-01]
 [-3.43573879e-01 -7.94599382e-02 -2.76773770e-01 -6.21399833e-02
   1.01895224e-01 -1.04256371e-01  5.42467215e-01  2.64762709e-01
   4.23139825e-01  4.80113216e-01]]
```

- **Escribe a través de fórmulas los 3 primeros componentes Principales**

CP1 = $-0.3474 \cdot \text{nacannual} + 0.3704 \cdot \text{anticoncep} + -0.2707 \cdot \text{abort} + -0.3036 \cdot \text{anemia} +$
 $0.3065 \cdot \text{atnprenat} + 0.3639 \cdot \text{partoasit} + -0.2333 \cdot \text{vihsida} + -0.1832 \cdot \text{infecun} + -$
 $0.3797 \cdot \text{nacpormuj} + -0.3436 \cdot \text{muertes}$

CP2 = 0.1028*nacannual + -0.0046*anticoncep + -0.1744*abort + -0.1576*anemia + 0.3950*atnprenat + 0.1302*partoasit + 0.5741*vihsida + 0.6522*infecun + -0.0002*nacpormuj + -0.0795*muerres


CP3 = 0.0157*nacannual + -0.0235*anticoncep + 0.7409*abort + 0.1232*anemia + 0.3996*atnprenat + 0.2087*partoasit + 0.2337*vihsida + -0.2978*infecun + 0.1090*nacpormuj + -0.2768*muerres

- **Implementación con *sklearn.PCA*:** permitió calcular la proporción de varianza explicada por cada componente, esta se calculó teóricamente como $Var(y_1) = \lambda_1$. La varianza acumulada se calcula como la suma de las varianzas de cada componente y logramos visualizar la gráfica de codo (Scree Plot) para determinar el número óptimo de componentes a retener.

```



Varianza de CP1: 103438.0434 (98.7377%)
Varianza de CP2: 739.2973 (0.7057%)
Varianza de CP3: 272.3110 (0.2599%)
Varianza de CP4: 154.4879 (0.1475%)
Varianza de CP5: 132.4622 (0.1264%)
Varianza de CP6: 16.3508 (0.0156%)
Varianza de CP7: 5.7334 (0.0055%)
Varianza de CP8: 1.2593 (0.0012%)
Varianza de CP9: 0.3402 (0.0003%)
Varianza de CP10: 0.1701 (0.0002%)

```



Dentro de este paso también se obtuvieron:

- **Scores de componentes:** proyecciones de los datos originales sobre los ejes principales, visualizadas en dispersogramas (CP1 vs CP2 y CP2 vs CP3) para detectar agrupamientos o gradientes entre países.



- **Cargas (Loadings):** medidas de correlación aproximada entre cada variable original y los componentes principales, útiles para interpretar qué variables influyen más en cada componente.

	CP1	CP2	CP3	CP4	CP5	CP6	CP7	CP8	CP9	CP10
nacannual	4.399574	-1.879668	-1.176655	-0.877202	0.348295	3.825314	-0.640553	-0.123790	-0.042715	0.001415
anticoncep	-19.508970	13.410443	11.804217	5.152687	-2.542510	0.541944	-0.001395	0.015824	0.027505	-0.007418
abort	0.708161	-0.496466	-0.230873	0.065987	-0.023611	0.228954	-0.408936	1.097960	-0.053302	0.015634
anemia	11.049852	-6.939369	-3.857116	10.916681	3.746831	0.101661	0.070896	-0.010151	-0.004039	-0.001634
atnprenat	-18.283281	14.963807	-10.576387	2.208592	-5.723087	0.009385	-0.149570	-0.013449	-0.004202	-0.005318
partoasit	-23.419609	16.508936	-1.843545	-1.705514	8.858322	0.066318	0.093949	0.021477	0.007116	0.001668
vihsida	0.269259	-0.065387	-0.294580	0.052913	-0.176696	0.184087	0.145169	0.011200	0.235430	0.375896
infecun	0.992128	-0.150728	-0.896760	-0.377837	-0.756648	1.126226	2.253715	0.167776	-0.004846	-0.031564
nacpormuj	1.419081	-1.030306	-0.698605	-0.235502	0.093710	0.232381	-0.138875	0.095992	0.528439	-0.165758
muertes	319.420819	3.158134	0.136695	-0.047457	0.034336	-0.022899	-0.000987	0.000436	0.000276	-0.000115

4. Validación con variable externa

Se calculó la correlación entre el primer componente principal (CP1) y la variable calif, que actúa como criterio externo de evaluación.

Correlación CP1 con calif: 0.8166625362360933

Conclusión

El análisis de componentes principales aplicado a la base "**Riesgo**" permitió reducir un conjunto de once indicadores de salud materna e infantil a un número menor de componentes que retienen la mayor parte de la variabilidad original. Tras comparar la matriz de varianzas-covarianzas (S) y la de correlaciones (R), se optó por trabajar con la **matriz de correlaciones**, dado que las variables estaban medidas en escalas distintas.

El PCA reveló que los primeros componentes explican un porcentaje significativo de la varianza, siendo el primero de ellos el que agrupa indicadores como atención prenatal, asistencia en el parto y cobertura de servicios de salud, mientras que otros componentes capturan factores como incidencia de enfermedades y mortalidad. Las gráficas de dispersión de CP1 vs CP2 y CP2 vs CP3 mostraron ciertos agrupamientos de países con perfiles similares, así como algunos casos atípicos que podrían requerir un análisis particular.

Finalmente, la correlación positiva entre el primer componente y la variable calif sugiere que el índice de riesgo original podría haberse construido ponderando fuertemente las variables relacionadas con acceso y calidad de atención materna, lo que valida el uso del PCA como herramienta para sintetizar la información y facilitar la interpretación de patrones de riesgo a nivel nacional.

Anexo

En este primer paso se asignan nombres a las columnas de la base de datos riesgo.xls, ya que el archivo original no los tenía. Después, se guarda una nueva versión del archivo con los encabezados agregados para trabajar más fácilmente en los siguientes pasos.

```
import pandas as pd

# Definir nombres de columnas
columnas = [
    'pais', 'nacanual', 'anticoncep', 'abort', 'anemia', 'atnprenat',
    'partoasit', 'vihsida', 'infecun', 'nacpormuj', 'muertes', 'calif'
]

# Leer el Excel sin encabezado y asignar columnas
df = pd.read_excel("/content/drive/MyDrive/modulo 6/riesgo.xls", header=None, names=columnas)

# Guardar en un nuevo archivo Excel
df.to_excel("/content/drive/MyDrive/modulo 6/riesgo_header.xlsx", index=False)

print("Archivos guardados: 'riesgo_header.xlsx' y 'riesgo_header.csv'")
```

Luego, con el comando `df.info()` se obtiene un resumen de la información del archivo, como el número de registros, el tipo de datos de cada columna y si hay valores faltantes. Esto sirve para conocer mejor la estructura de los datos antes de comenzar el análisis.

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 118 entries, 0 to 117
Data columns (total 12 columns):
 #   Column                Non-Null Count  Dtype  
---  -
 0   pais                  118 non-null   object  
 1   nacanual              118 non-null   int64   
 2   anticoncep            118 non-null   int64   
 3   abort                 118 non-null   int64   
 4   anemia                118 non-null   int64   
 5   atnprenat            116 non-null   float64  
 6   partoasit            116 non-null   float64  
 7   vihsida               118 non-null   int64   
 8   infecun              118 non-null   int64   
 9   nacpormuj            118 non-null   float64  
10   muertes              118 non-null   int64   
11   calif                118 non-null   float64  
dtypes: float64(4), int64(7), object(1)
memory usage: 11.2+ KB
```

En este paso se carga el archivo riesgo_header.xlsx, que ya contenía los nombres de las columnas.

Después, se eliminan los registros que tenían información faltante en las columnas atnprenat (atención prenatal) y partoasit (parto asistido), ya que estos datos son importantes para el análisis.

Finalmente, se guarda el archivo limpio con el nombre riesgo_relleno.xlsx para trabajar con una base de datos completa en los siguientes pasos.

```
import pandas as pd

# Cargar el archivo
df = pd.read_excel("/content/drive/MyDrive/modulo 6/riesgo_header.xlsx", header=0)

# Eliminar registros con valores faltantes en 'atnprenat' y 'partoasit'
df = df.dropna(subset=['atnprenat'])
df = df.dropna(subset=['partoasit'])

# Guardar en formato xlsx con encabezados
df.to_excel("/content/drive/MyDrive/modulo 6/riesgo_relleno.xlsx", index=False)

print("Archivo guardado como riesgo_relleno.xlsx")
```

En este paso se carga el archivo riesgo_relleno.xlsx, que ya contiene únicamente los registros completos después de la limpieza.

Al mostrar el contenido de df, se puede visualizar la tabla de datos lista para comenzar el análisis estadístico.

```
df = pd.read_excel("/content/drive/MyDrive/modulo 6/riesgo_relleno.xlsx")
df
```

	pais	nacanual	anticoncep	abort	anemia	atnprenat	partoasit	vihsida	infecun	nacpormuj	muertes	calif
0	Italia	1	78	1	10	100	100	1	6	1.2	4	6.6
1	Dinamarca	1	78	1	8	100	99	1	6	1.8	3	6.7
2	Noruega	2	76	1	17	95	100	1	5	1.8	3	8.1
3	Suecia	1	78	1	17	100	100	1	5	2.0	5	8.4
4	Bélgica	1	79	1	17	90	100	1	7	1.6	3	8.7
...	...	...	...	...	...	...	...	...	...	...	...	...
109	Costa de Marfil	23	3	5	56	66	40	3	10	7.4	680	70.0
110	Níger	22	4	5	47	30	15	2	9	7.4	700	70.3
111	Mali	20	5	5	65	31	27	2	8	7.1	1750	71.1
112	Somalia	21	5	5	73	2	2	1	10	7.0	1100	72.8
113	Angola	24	2	5	54	25	15	2	12	6.6	650	73.5

Con el comando `df.info()` se obtiene un resumen de la estructura del archivo `riesgo_relleno.xlsx`.

Aquí se puede ver que la base contiene 114 registros y 12 columnas, que incluyen tanto datos numéricos como de texto (por ejemplo, el nombre del país). También se confirma que no hay valores faltantes, lo que significa que la base está lista para el análisis estadístico.

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 114 entries, 0 to 113
Data columns (total 12 columns):
#   Column          Non-Null Count  Dtype
---  -
0   pais            114 non-null   object
1   nacanual        114 non-null   int64
2   anticoncep      114 non-null   int64
3   abort           114 non-null   int64
4   anemia          114 non-null   int64
5   atnprenat       114 non-null   int64
6   partoasit       114 non-null   int64
7   vihsida         114 non-null   int64
8   infecun         114 non-null   int64
9   nacpormuj       114 non-null   float64
10  muertes         114 non-null   int64
11  calif           114 non-null   float64
dtypes: float64(2), int64(9), object(1)
memory usage: 10.8+ KB
```

Después de tener la base de datos limpia y sin valores faltantes, se procede a cargar el archivo `riesgo_relleno.xlsx` para preparar la información que será utilizada en el Análisis de Componentes Principales (PCA).

Para ello, se eliminan las columnas `calif` (calificación de riesgo) y `pais`, ya que no se incluyen en el cálculo, y se verifica que todas las variables restantes sean numéricas para garantizar un procesamiento correcto.

```

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.decomposition import PCA

# Cargar datos
df = pd.read_excel("/content/drive/MyDrive/modulo 6/riesgo_relleno.xlsx")

# Variables para PCA (todas menos 'calif')
X = df.drop(columns=['calif', 'pais']) # quitamos la última y la de país

# Verificamos que todas sean numéricas
X = X.apply(pd.to_numeric)

X.head()

```

	nacanual	anticoncep	abort	anemia	atnprenat	partoasit	vihsida	infecun	nacpormuj	muerres
0	1	78	1	10	100	100	1	6	1.2	4
1	1	78	1	8	100	99	1	6	1.8	3
2	2	76	1	17	95	100	1	5	1.8	3
3	1	78	1	17	100	100	1	5	2.0	5
4	1	79	1	17	90	100	1	7	1.6	3

Con los datos listos, se calcula la **matriz de varianzas y covarianzas (S)**, que muestra cómo varía cada variable por sí misma (varianza) y cómo se relaciona con las demás (covarianza).

En la parte inferior también se listan las varianzas de cada variable, lo que permite ver si todas están en el mismo orden de magnitud o si hay diferencias grandes entre ellas.

```

#Matriz S (varianzas y covarianzas)

S = X.cov()
print("Matriz de varianzas-covarianzas (S):\n", S)

# Revisar varianzas
print("\nVarianzas de cada variable:\n", np.diag(S))

```

En la matriz S se nota que las varianzas de las variables no son del mismo orden: algunas, como muertes o anticoncep, tienen valores muy altos (del orden de miles o cientos), mientras que otras, como infecun o nacpormuj, presentan varianzas muy pequeñas (menores a 1).

Esto indica que las variables están en escalas distintas, lo cual puede afectar un análisis que use directamente la matriz S y es una de las razones para trabajar con la matriz de correlaciones (R) en lugar de S.

```

Matriz de varianzas-covarianzas (S):
      nacanual  anticoncep  abort  anemia  atnprenat  \
nacanual    40.225198 -128.262459  5.258500  58.270610 -99.918025
anticoncep -128.262459  733.088728 -22.658128 -307.382860  458.449464
abort       5.258500 -22.658128  2.234436  12.775966 -17.605186
anemia      58.270610 -307.382860  12.775966  318.359571 -262.414998
atnprenat   -99.918025  458.449464 -17.605186 -262.414998  707.708120
partoasit   -127.126456  625.248952 -24.677069 -351.648812  640.244372
vihside     2.146483  -8.781789  0.287222  4.508151 -1.680795
infecun     8.615277 -31.375408  0.497594  8.780624 -7.743052
nacpormuj   10.184420 -51.056474  1.844620  23.316069 -35.010154
muertes    1399.184909 -6187.949697  224.593697  3506.718211 -5794.549915

      partoasit  vihside  infecun  nacpormuj  muertes
nacanual   -127.126456  2.146483  8.615277  10.184420  1399.184909
anticoncep  625.248952 -8.781789 -31.375408 -51.056474 -6187.949697
abort      -24.677069  0.287222  0.497594  1.844620  224.593697
anemia     -351.648812  4.508151  8.780624  23.316069  3506.718211
atnprenat  640.244372 -1.680795 -7.743052 -35.010154 -5794.549915
partoasit  905.814082 -8.469415 -29.838690 -47.715999 -7428.441702
vihside    -8.469415  0.449387  1.178233  0.712040  85.747244
infecun    -29.838690  1.178233  8.903276  2.175268  316.271852
nacpormuj  -47.715999  0.712040  2.175268  4.016840  449.944061
muertes   -7428.441702  85.747244  316.271852  449.944061  102039.655954

Varianzas de cada variable:
[4.02251980e+01 7.33088728e+02 2.23443565e+00 3.18359571e+02
 7.07708120e+02 9.05814082e+02 4.49386741e-01 8.90327589e+00
 4.01683978e+00 1.02039656e+05]

```

Se calculó la **matriz de correlaciones (R)** para estandarizar las relaciones entre variables y eliminar el efecto de las diferentes escalas de medición.

En esta matriz, los valores cercanos a **1** o **-1** indican una fuerte relación directa o inversa, respectivamente, mientras que valores cercanos a **0** indican poca o ninguna relación lineal. Se identifican correlaciones altas, por ejemplo, entre partoasit y atnprenat (0.799) o entre nacpormuj y nacanual (0.801), lo que sugiere que estos indicadores tienden a variar en conjunto. También hay correlaciones negativas altas, como entre anticoncep y nacpormuj (-0.940), lo que podría indicar que un mayor uso de anticonceptivos se asocia con menos nacimientos por mujer.

Debido a las diferencias en las escalas de las variables (observadas en la matriz S), esta matriz R fue la elegida para realizar el análisis de componentes principales.


```
R = X.corr()
print("Matriz de correlaciones (R):\n", R)
```

Matriz de correlaciones (R):

	nacannual	anticoncep	abort	anemia	atnprenat	partoasit	\
nacannual	1.000000	-0.746917	0.554663	0.514922	-0.592199	-0.665989	
anticoncep	-0.746917	1.000000	-0.559837	-0.636271	0.636482	0.767282	
abort	0.554663	-0.559837	1.000000	0.479017	-0.442720	-0.548517	
anemia	0.514922	-0.636271	0.479017	1.000000	-0.552844	-0.654833	
atnprenat	-0.592199	0.636482	-0.442720	-0.552844	1.000000	0.799649	
partoasit	-0.665989	0.767282	-0.548517	-0.654833	0.799649	1.000000	
vihsida	0.504857	-0.483832	0.286632	0.376903	-0.094249	-0.419782	
infecun	0.455245	-0.388362	0.111562	0.164927	-0.097546	-0.332266	
nacpormuj	0.801207	-0.940871	0.615717	0.652010	-0.656636	-0.791047	
muertes	0.690624	-0.715458	0.470359	0.615258	-0.681880	-0.772669	
	vihsida	infecun	nacpormuj	muertes			
nacannual	0.504857	0.455245	0.801207	0.690624			
anticoncep	-0.483832	-0.388362	-0.940871	-0.715458			
abort	0.286632	0.111562	0.615717	0.470359			
anemia	0.376903	0.164927	0.652010	0.615258			
atnprenat	-0.094249	-0.097546	-0.656636	-0.681880			
partoasit	-0.419782	-0.332266	-0.791047	-0.772669			
vihsida	1.000000	0.589042	0.529971	0.400429			
infecun	0.589042	1.000000	0.363744	0.331819			
nacpormuj	0.529971	0.363744	1.000000	0.702800			
muertes	0.400429	0.331819	0.702800	1.000000			

En este código se utiliza la librería **Seaborn** para representar gráficamente la matriz de dispersión SSS, que contiene las **varianzas** (en la diagonal) y **covarianzas** (fuera de la diagonal) de las variables analizadas.

```
import seaborn as sns

plt.figure(figsize=(10, 8))
sns.heatmap(S, annot=True, fmt=".2f", cmap="coolwarm", vmin=-1000, vmax=1000)
plt.title("Matriz de dispersión (S) - Varianzas y Covarianzas")
plt.show()
```

Y el resultado, tal como lo vimos anteriormente fue la matriz de dispersión SSS que se representó mediante un **mapa de calor** utilizando la librería **Seaborn** de Python, con una escala de color simétrica en el rango [-1000,1000][1000, 1000][1000,1000]. En la diagonal principal se muestran las varianzas de cada variable y, fuera de la diagonal, las covarianzas.

Esta visualización permitió identificar rápidamente relaciones positivas y negativas entre variables, así como la magnitud de su dispersión.

Para obtener la matriz de correlaciones RRR entre las variables del estudio, se utilizó la librería **Seaborn** de Python, representándola como un **mapa de calor** con valores numéricos y una escala de color que diferencia correlaciones positivas y negativas. Esta visualización facilitó la identificación de relaciones lineales significativas entre variables, las cuales ya se analizaron en la sección de resultados.

```
plt.figure(figsize=(10, 8))
sns.heatmap(R, annot=True, fmt=".2f", cmap="coolwarm")
plt.title("Matriz de dispersión (R) - correlaciones")
plt.show()
```

A partir de la matriz de correlaciones RRR, se calcularon los **valores propios** (*eigenvalues*) y **vectores propios** (*eigenvectors*) utilizando la función `np.linalg.eig()` de *NumPy*.

Este procedimiento es fundamental en el **Análisis de Componentes Principales (ACP)**, ya que:

- Los **valores propios** indican la varianza explicada por cada componente.
- Los **vectores propios** determinan la dirección de cada componente en el espacio de las variables originales.

Los resultados completos se muestran en este anexo como respaldo técnico; su interpretación y selección de componentes ya fueron incluidas en la sección de resultados.

```
#Elegimos la Matriz R de Correlación
```

```
eigvals, eigvecs = np.linalg.eig(R)
```

```
print("Eigenvalores:\n", eigvals)
```

```
print("\nEigenvectores:\n", eigvecs)
```

```
Eigenvalores:
```

```
[6.03637992 1.35738212 0.6763321 0.54274434 0.04556734 0.11399123  
0.24159459 0.37373678 0.29472657 0.317545 ]
```

```
Eigenvectores:
```

```
[[-3.47423910e-01 1.02783058e-01 1.56958869e-02 3.49343332e-01  
-1.43579227e-01 2.69314301e-01 -5.27412342e-01 -2.05073501e-01  
5.63696993e-01 1.23801208e-01]  
[ 3.70435835e-01 -4.63053513e-03 -2.35088167e-02 -4.82730949e-02  
6.07132420e-01 1.29162445e-01 -4.06404329e-01 4.87498087e-01  
9.47362669e-02 2.50572062e-01]  
[-2.70737849e-01 -1.74365343e-01 7.40937458e-01 3.45182647e-01  
-2.99681023e-02 -1.11252492e-01 8.34075830e-02 4.47792835e-01  
-7.32239065e-02 -4.52346675e-02]  
[-3.03618707e-01 -1.57575663e-01 1.23171887e-01 -7.50051250e-01  
-4.28415008e-03 3.91085599e-03 -1.80119934e-01 1.68808617e-01  
2.82065084e-01 -4.05836790e-01]  
[ 3.06508559e-01 3.94965366e-01 3.99627855e-01 -1.42479729e-01  
1.97358655e-02 5.66518802e-01 4.03270290e-01 -1.03073298e-01  
2.73621189e-01 -2.44810710e-02]  
[ 3.63890184e-01 1.30153489e-01 2.08699377e-01 3.90713079e-02  
7.96864928e-02 -7.13694418e-01 1.19655137e-02 -2.08613799e-01  
4.87446124e-01 -9.26592310e-02]  
[-2.33310111e-01 5.74064994e-01 2.33665572e-01 -3.37548050e-01  
-7.94531322e-02 -2.22481282e-01 -2.07957253e-01 -6.14300784e-02  
-2.88891122e-01 5.11066349e-01]  
[-1.83200391e-01 6.52210650e-01 -2.97806146e-01 2.23710797e-01  
7.26077288e-02 -8.78484074e-02 6.15755947e-02 3.86518989e-01  
3.23238815e-03 -4.85937967e-01]  
[-3.79721020e-01 -1.91200561e-04 1.09048940e-01 6.50183255e-02  
7.62333279e-01 2.55516999e-03 1.14861544e-01 -4.62452166e-01  
-1.15586196e-01 -1.34606650e-01]  
[-3.43573879e-01 -7.94599382e-02 -2.76773770e-01 -6.21399833e-02  
1.01895224e-01 -1.04256371e-01 5.42467215e-01 2.64762709e-01  
4.23139825e-01 4.80113216e-01]]
```

A partir de los vectores propios obtenidos de la matriz de correlaciones RRR, se construyeron las ecuaciones de los tres primeros **Componentes Principales (CP)**.

Cada ecuación expresa el componente como una combinación lineal de las variables originales, ponderadas por los coeficientes (cargas) correspondientes:

- **CP1, CP2 y CP3** muestran la contribución relativa de cada variable al respectivo componente.
- Los coeficientes positivos indican relación directa con el componente; los negativos, relación inversa.
- La magnitud del coeficiente refleja la importancia relativa de la variable en ese componente.

Las ecuaciones completas se incluyen aquí como respaldo técnico; la interpretación y relevancia de cada componente se desarrolló en la sección de resultados.

```
for i in range(3):
    componente = ""
    for j in range(len(X.columns)):
        print(f"CP{i+1} = {componente}")
        componente += f"+ {X.columns[j]} * {eigvecs[j, i]:.4f}"

CP1 = -0.3474*nacanal + 0.3704*anticoncep + -0.2707*abort + -0.3036*anemia + 0.3065*atnprenat + 0.3639*partoasit + -0.2333*vihsida + -0.1832*infecun + -0.3797*nacpormuj + -0.3436*muertes
CP2 = 0.1028*nacanal + -0.0046*anticoncep + -0.1744*abort + -0.1576*anemia + 0.3950*atnprenat + 0.1302*partoasit + 0.5741*vihsida + 0.6522*infecun + -0.0002*nacpormuj + -0.0795*muertes
CP3 = 0.0157*nacanal + -0.0235*anticoncep + 0.7409*abort + 0.1232*anemia + 0.3996*atnprenat + 0.2087*partoasit + 0.2337*vihsida + -0.2978*infecun + 0.1090*nacpormuj + -0.2768*muertes
```

Se aplicó el método **PCA** (*Principal Component Analysis*) conservando los tres primeros componentes, a partir de la matriz de datos estandarizada XXX.

- `pca.fit_transform(X)`: transforma los datos originales a su representación en el nuevo espacio definido por los componentes principales.
- Se generaron gráficos de dispersión para visualizar:
 - **CP1 vs CP2**
 - **CP2 vs CP3**

Estas representaciones permiten observar la distribución de las observaciones en función de los componentes seleccionados y detectar patrones, agrupamientos o separaciones relevantes.

```
pca = PCA(n_components=3)
X_pca = pca.fit_transform(X)

plt.figure(figsize=(6,5))
plt.scatter(X_pca[:,0], X_pca[:,1])
plt.xlabel('CP1')
plt.ylabel('CP2')
plt.title('CP1 vs CP2')
plt.grid(True)
plt.show()

plt.figure(figsize=(6,5))
plt.scatter(X_pca[:,1], X_pca[:,2])
plt.xlabel('CP2')
plt.ylabel('CP3')
plt.title('CP2 vs CP3')
plt.grid(True)
plt.show()
```

Se utilizó la clase PCA de *scikit-learn* para calcular la varianza asociada a cada componente principal y el porcentaje que representa sobre la varianza total de los datos:

- `explained_variance_`: devuelve los valores propios asociados a cada componente, equivalentes a la varianza que explica.
- `explained_variance_ratio_`: devuelve el porcentaje de la varianza total explicada por cada componente.

En este caso, el **CP1** concentra la mayor parte de la varianza (98.7377%), mientras que el resto de los componentes explican porcentajes significativamente menores.

```

from sklearn.decomposition import PCA

pca = PCA()
pca.fit(X)

# Varianza de cada CP (eigenvalores)
varianzas_cp = pca.explained_variance_

for i, (var, ratio) in enumerate(zip(varianzas_cp, pca.explained_variance_ratio_), 1):
    print(f"Varianza de CP{i}: {var:.4f} ({ratio:.4%})")

```

```

Varianza de CP1: 103438.0434 (98.7377%)
Varianza de CP2: 739.2973 (0.7057%)
Varianza de CP3: 272.3110 (0.2599%)
Varianza de CP4: 154.4879 (0.1475%)
Varianza de CP5: 132.4622 (0.1264%)
Varianza de CP6: 16.3508 (0.0156%)
Varianza de CP7: 5.7334 (0.0055%)
Varianza de CP8: 1.2593 (0.0012%)
Varianza de CP9: 0.3402 (0.0003%)
Varianza de CP10: 0.1701 (0.0002%)

```

Se sumaron las varianzas explicadas por cada componente principal para obtener la **varianza total** de los datos originales:

- La varianza total es **104760.456**, valor que coincide con la suma de las varianzas de todos los componentes principales calculados por el modelo PCA.
- Este valor sirve como referencia para verificar que la suma de las proporciones de varianza explicada ($\sum \text{explained_variance_ratio_} = 1$) sea consistente con la varianza total de los datos.

Este cálculo se incluye como parte del respaldo metodológico del análisis de componentes principales.

```

# Varianza total
varianza_total = sum(varianzas_cp)
print("Varianza total:", varianza_total)

Varianza total: 104760.45559152302

```

Se calculó la **varianza acumulada** a partir de los valores de **explained_variance_ratio_** obtenidos en el modelo PCA, utilizando **np.cumsum()**.

- Este cálculo muestra el porcentaje acumulado de varianza explicada conforme se van incorporando los componentes principales.
- En este caso, con el **primer componente** ya se explica el **98.7377%** de la varianza total; con los **dos primeros**, el 99.4433%; y con los **tres primeros**, el 99.7033%.
- Esto respalda la decisión de reducir la dimensionalidad conservando únicamente los primeros componentes, ya que los restantes aportan una cantidad mínima de información adicional.

```
var_exp_acum = np.cumsum(pca.explained_variance_ratio_)
print("Varianza acumulada:", var_exp_acum)

Varianza acumulada: [0.9873768  0.99443383 0.99703319 0.99850787 0.9997723  0.99992838
 0.99998311 0.99999513 0.99999838 1.          ]
```

Se generó la **gráfica de codo** (*Scree Plot*) a partir de la varianza explicada por cada componente principal:

- En el eje **X** se muestra el número de componente principal (CP).
- En el eje **Y** se representa la proporción de varianza explicada.
- Se utilizaron marcadores circulares y línea azul para visualizar la tendencia decreciente de la varianza explicada conforme aumenta el número de componentes.

Este gráfico permite identificar el **punto de inflexión** donde la adición de más componentes deja de aportar varianza explicada significativa. En este caso, el codo se produce en el **primer componente**, lo que confirma que CP1 explica la mayor parte de la varianza (98.7377%), y que los demás componentes aportan porcentajes mucho menores.

```
import matplotlib.pyplot as plt
from sklearn.decomposition import PCA

# Suponiendo que X está definido y contiene tus variables numéricas
pca = PCA()
pca.fit(X)

varianzas_cp = pca.explained_variance_
varianza_ratio = pca.explained_variance_ratio_

# Imprimir varianzas y proporciones
for i, (var, ratio) in enumerate(zip(varianzas_cp, varianza_ratio), 1):
    print(f"Varianza de CP{i}: {var:.4f} ({ratio:.4%})")

# Gráfica de codo
plt.figure(figsize=(8,5))
plt.plot(range(1, len(varianza_ratio) + 1), varianza_ratio, 'o-', color='blue')
plt.title('Gráfica de Codo (Scree Plot)')
plt.xlabel('Número de Componente Principal')
plt.ylabel('Proporción de Varianza Explicada')
plt.xticks(range(1, len(varianza_ratio) + 1))
plt.grid(True)
plt.show()
```

```
Varianza de CP1: 103438.0434 (98.7377%)
Varianza de CP2: 739.2973 (0.7057%)
Varianza de CP3: 272.3110 (0.2599%)
Varianza de CP4: 154.4879 (0.1475%)
Varianza de CP5: 132.4622 (0.1264%)
Varianza de CP6: 16.3508 (0.0156%)
Varianza de CP7: 5.7334 (0.0055%)
Varianza de CP8: 1.2593 (0.0012%)
Varianza de CP9: 0.3402 (0.0003%)
Varianza de CP10: 0.1701 (0.0002%)
```

Se calcularon las **cargas** (*loadings*) de cada variable original sobre los Componentes Principales (CP) mediante la fórmula:

$$\text{loadings} = \text{componentes}^T \times \sqrt{\text{varianza explicada}}$$

Pesos positivos: indican que la variable aumenta cuando el componente aumenta.

- **Pesos negativos:** indican que la variable disminuye cuando el componente aumenta.
- La magnitud del valor refleja el grado de contribución de la variable al componente.

Esta matriz permite interpretar el significado de cada componente principal en función de las variables originales. Por ejemplo, *muertes* presenta una carga muy alta en **CP1** (319.420819), lo que indica una fuerte influencia de esta variable en ese componente.

La interpretación detallada de estos patrones se presenta en la sección de resultados; aquí se incluye el cálculo como respaldo metodológico.

```
# correlación (loadings) entre las variables originales y los componentes principales (CP)

loadings = pca.components_.T * np.sqrt(pca.explained_variance_)
pd.DataFrame(loadings, index=X.columns, columns=[f'CP{i+1}' for i in range(loadings.shape[1])])
pd.DataFrame(loadings, index=X.columns, columns=[f'CP{i+1}' for i in range(loadings.shape[1])])

# Pesos positivos → variables que aumentan juntas en el componente.
# Pesos negativos → variables que disminuyen cuando las positivas aumentan.
```

	CP1	CP2	CP3	CP4	CP5	CP6	CP7	CP8	CP9	CP10
nacannual	4.399574	-1.879668	-1.176655	-0.877202	0.348295	3.825314	-0.640553	-0.123790	-0.042715	0.001415
anticoncep	-19.508970	13.410443	11.804217	5.152687	-2.542510	0.541944	-0.001395	0.015824	0.027505	-0.007418
abort	0.708161	-0.496466	-0.230873	0.065987	-0.023611	0.228954	-0.408936	1.097960	-0.053302	0.015634
anemia	11.049852	-6.939369	-3.857116	10.916681	3.746831	0.101661	0.070896	-0.010151	-0.004039	-0.001634
atnprenat	-18.283281	14.963807	-10.576387	2.208592	-5.723087	0.009385	-0.149570	-0.013449	-0.004202	-0.005318
partoasit	-23.419609	16.508936	-1.843545	-1.705514	8.858322	0.066318	0.093949	0.021477	0.007116	0.001668
vihsida	0.269259	-0.065387	-0.294580	0.052913	-0.176696	0.184087	0.145169	0.011200	0.235430	0.375896
infecun	0.992128	-0.150728	-0.896760	-0.377837	-0.756648	1.126226	2.253715	0.167776	-0.004846	-0.031564
nacpormuj	1.419081	-1.030306	-0.698605	-0.235502	0.093710	0.232381	-0.138875	0.095992	0.528439	-0.165758
muertes	319.420819	3.158134	0.136695	-0.047457	0.034336	-0.022899	-0.000987	0.000436	0.000276	-0.000115

Se calculó la correlación entre los puntajes del **primer componente principal (CP1)** y la variable calif utilizando la función `np.corrcoef()`.

- **Resultado:** 0.81666, lo que indica una **correlación positiva fuerte** entre CP1 y la calificación.
- Este valor sugiere que las variaciones captadas por CP1 están fuertemente asociadas con los valores de calif.

```
cp1_scores = X_pca[:,0]
cor_cp1_calif = np.corrcoef(cp1_scores, df['calif'])[0,1]
print("Correlación CP1 con calif:", cor_cp1_calif)

Correlación CP1 con calif: 0.8166625362360933
```


Bibliografía

- Código utilizado: [Practica 2 Modulo 6](#)