

Tarea 3: Resultados de un Analisis de discriminante.

25 de Septiembre del 2025

Profesor: Mahil Herrera Maldonado


Integrantes del Equipo 5:



☐ Omar Misael Valero Silva



☐ Karla Anahi Sanchez Morales



☐ Karol Jacqueline Nolasco Reyes



☐ David Mendieta Lopez



☐ Cesar Gabriel Lopez Lopez

índice:

❖ Objetivo	3
❖ Introducción y Problemática	4
❖ Práctica e Implementación	5
❖ Conclusiones	7

Objetivo:

Aplicar un análisis de discriminante sobre una base de datos llamado: “estados.xlsx” de forma que se demuestre que podemos como equipo interpretar el modelo y sus resultados.



Introducción y Problemática:

El objetivo básico del análisis discriminante es producir una regla o un esquema de clasificación que nos permita predecir la población más probable de la cual proviene la nueva observación.

En la clase #7 del diplomado se pidió a los equipos que analizan un conjunto de datos para poder averiguar si el modelo es eficiente y eficaz al clasificar nuevas observaciones en el grupo correspondientemente.

	A	B	C	D	E	F	G
1		Empleado	Jorn/Peón	Trab. particular	Patrón	Trabaj. Familiar	No específico
2	Aguascalientes	66.98	10.71551	15.40225	2.683116	1.698019	2.517363
3	Baja California	70.5487	7.139181	14.93834	3.975447	0.531238	2.86699
4	Baja California Sur	63.22	11.05164	18.11644	3.574243	1.217364	2.818134
5	Campeche	48.412	11.34661	30.55812	2.216917	2.536287	4.929892
6	Chiapas	69.8491	8.873098	14.88437	2.66529	1.025308	2.702822
7	Chihuahua	59.5621	14.01096	18.72949	2.641712	1.595067	3.460599
8	Coahuila	25.7968	14.10685	47.13139	1.382178	5.651758	5.748461
9	Colima	65.14163	7.341223	18.95071	2.754494	2.557495	3.25443
10	Distrito Federal	77.238	1.331007	16.07237	2.895756	0.482285	1.980548
11	Durango	54.0125	12.7219	22.95673	1.954646	4.47052	3.883665
12	Guanajuato	55.868	13.54071	20.77628	2.232662	3.240758	4.341558
13	Guerrero	39.9181	11.65221	36.77354	1.555197	4.088074	6.012864
14	Hidalgo	43.15842	22.60624	24.94491	1.326333	2.894702	5.069377
15	Jalisco	62.7424	7.940113	20.8958	2.82732	2.131145	3.463168
16	México	68.8555	5.689491	19.02868	1.867474	1.341709	3.217083
17	Michoacán	40.14248	16.46187	30.00942	2.157818	4.243092	6.985299
18	Morelos	54.08044	15.88054	22.977	2.44835	1.663236	2.950421
19	Nayarit	41.65922	19.21201	27.0721	2.675965	3.714163	5.666523

Si observamos los registros podemos ver que hay 33 observaciones y conformado con 7 columnas que son los estados de la república mexicana

Si bien toda la base de datos perfecta los datos; la problemática recae en el hecho de que es necesario colocar a cada registro una indicador remarcando a qué grupo pertenece y por ende debemos de establecer los grupos convenientes para estos datos....

Práctica e Implementación:

- **Paso 1: Crear una nueva variable para agrupar a los registros.**

Nosotros decidimos agrupar a los datos con base en una variable llamada 'Región', la cual

agrupa a los estados (registros) con base en la siguiente regla:

```
# Crear variable Región
datos$Region <- with(datos,
  case_when(
    Estado %in% c("Baja California", "Baja California Sur", "Chihuahua",
                  "Coahuila", "Durango", "Nuevo León", "Sonora", "Tamaulipas") ~ "Norte",
    Estado %in% c("Aguascalientes", "Colima", "Guanajuato", "Jalisco", "Michoacán",
                  "Morelos", "Querétaro", "San Luis Potosí", "Zacatecas") ~ "Centro",
    Estado %in% c("Campeche", "Chiapas", "Guerrero", "Oaxaca", "Puebla",
                  "Quintana Roo", "Tabasco", "Veracruz", "Yucatán") ~ "Sur",
    Estado %in% c("Distrito Federal", "Hidalgo", "México", "Tlaxcala",
                  "Nayarit", "Sinaloa") ~ "Este",
    TRUE ~ "Otro"
  )
)
```

Curiosamente la forma que lo clasificamos fue por medio de las regiones que conforman a la república mexicana dado por su geografía.

- **Paso 2: Verificamos la distribución que tenían los datos al agruparlos por esta nueva variable.**

```
> # Verificar distribución
> table(datos$Region)

Centro  Este  Norte   Sur
      9      6      8      9
>
```

- **Paso 3: Sacamos un resumen del modelo.**

```
> # Resumen del modelo
> modelo_lda
Call:
lda(Region ~ Empleado + Jorn_Peon + Trab_particular + Patron +
    Trabaj_Familiar + No_especifico, data = datos)

Prior probabilities of groups:
  Centro   Este  Norte   Sur 
0.28125 0.18750 0.25000 0.28125 

Group means:
      Empleado Jorn_Peon Trab_particular Patron Trabaj_Familiar No_especifico
Centro 55.68302 12.88479    22.57124 2.334470    3.235434    4.179497
Este  55.03900 13.90650    22.81442 2.040115    2.187765    4.012173
Norte 59.44437 10.82032    21.54818 2.706079    2.062218    3.395708
Sur   48.87874 12.65955    28.71795 2.084143    3.165129    4.493621

Coefficients of linear discriminants:
      LD1      LD2      LD3
Empleado -0.1757816 -0.17583074 0.16743480
Jorn_Peon -0.2232982 -0.19208703 0.25001261
Trab_particular -0.2876181 0.04310399 0.15425194
Patron 1.6257850 1.32704136 0.08963484
Trabaj_Familiar 1.1764747 -0.44013622 -0.28082793
No_especifico -0.5195190 -0.69001163 -0.24387402

Proportion of trace:
      LD1      LD2      LD3 
0.5341 0.3263 0.1396
```

donde podemos ver un resumen de este función que se ejecutó en R y esta se conforma por las siguiente parte:

- **Prior probabilities of groups:** refleja el porcentaje de casos por grupo de región en el conjunto de datos.
- **Group means:** los promedios de cada variable predictora en cada grupo (Región).
- **Coefficients of linear discriminants:** son los pesos de cada variable en los ejes

discriminantes....

- LD1 es el primer eje que mejor separa los grupos (Región).
- LD2 y LD3 son ejes secundarios, cada uno explicando menos varianza que el anterior.
- **Proportion of trace:** explica cuánta varianza entre los grupos (en este caso, regiones) es capturada por cada discriminante lineal (LD1, LD2, LD3).

Llegados a este punto, no preguntamos una sola cosa:

¿por qué fueron 3 discriminantes lineales únicamente?

Esto se debe a una restricción matemática del Análisis Discriminante Lineal (LDA); El número máximo de discriminantes lineales posibles es:

$$\min(p, g - 1)$$


donde:

- p = número de variables predictoras (*en nuestro caso: 6 variables*).
- g = número de grupos en la variable dependiente (*Región tiene 4 regiones: Centro, Este, Norte, Sur*).

Entonces: $\min(6, 4 - 1) = \min(6, 3) = 3$

Cada uno representa un eje nuevo que separa las categorías de Región maximizando la separación entre grupos y minimizando la varianza interna.

● **Paso 4: graficamos los discriminantes:**



Podemos observar las agrupaciones discriminantes. Pero por los datos anteriores, el par más informativo es LD1 y LD2, porque:

LD1 y LD2 explican juntos el 86% de la varianza entre grupos: (LD1: 53.4%, LD2: 32.6%).

- **Paso 5: Imprimimos la matriz de confusión, la cual nos dice las predicciones correctas y los errores del modelo.**

```

      Predicho
Real   Centro Este Norte Sur
Centro    7    0     2    0
Este     1    4     1    0
Norte    1    0     6    1
Sur      2    0     1    6
> # Precisión total (porcentaje de aciertos)
> precision <- sum(diag(matriz_confusion)) / sum(matriz_confusion)
> print(paste("Precisión:", round(precision * 100, 2), "%"))
[1] "Precisión: 71.88 %"
```

A pesar de que no es una matriz de confusión clásica (*sino es una matriz de confusión multiclase*); se trata de ver si un valor que clasificó el modelo concuerda con el valor original en cada una de las observaciones. Para este ocasión solo no interesa la diagonal de la matriz (*ya que son los resultados que coinciden*)...

- Suma de aciertos:
 - Centro: 7
 - Este: 4
 - Norte: 6
 - Sur: 6

Total de aciertos: 23

- Suma de observaciones:
 - Fila Centro: 9
 - Fila Este: 6
 - Fila Norte: 8
 - Fila Sur: 9

Total de observaciones: 32

Calculando la precisión del modelo para determinar qué tan eficiente es el modelo al clasificar las observación; consta de dividir los casos de éxito entre todo los casos:

$$\frac{23}{32} = 0.7187 = 71.87\%$$

Conclusión:

- Lo que indica que aproximadamente **7 de cada 10 estados** fueron correctamente clasificados por el modelo según su región.
- Existen patrones laborales que no van de la mano con la división regional que tiene la república mexicana (*que es precisamente geográfica*), lo que genera confusión en la clasificación. Por lo que a pesar de la forma tan rudimentaria de crear los grupos; debemos de aplicar algún modelo de clustering para determinar adecuadamente el número de grupos y los registros que pertenecen a ellos.
- Otra razón por la que el análisis por discriminantes no funcionó como se esperaba fue más en la cantidad de filas de información que en a groso modo son insuficientes para que un modelo pueda ser entrenado por una parte de “train” y probado por una parte de “test”.